東北農業大學

本科毕业论文

基于深度学习的事件相关电位识别技术研究

Enhancing P300 Classification in Brain-Computer Interfaces Using Deep Learning and Attention Mechanisms

所在学院：电气与信息学院

所在班级：物联 2103

学生姓名：代阳

学生学号：A07210177

指导教师：张宇 綦宏志

研究方向：物联网智能算法

2025 年 06 月

摘要

随着物联网智能算法在各类人机交互系统中的广泛应用，脑机接口（BCI）作为其中的重要技术方向，在物联网智能终端与控制系统中使用广泛。随着脑机接口技术的不断发展，基于事件相关电位（ERP）中 P300 信号的识别精准度已然成为提高字符拼写效率的关键要点，事件相关电位是脑电信号（俗称“脑波”）中常用的一种分类特征。但是传统分类器（如 LDA）在处理低信噪比、个体差异十分突出的 EEG 信号时存在性能方面的限制，需要更强大的模型来呈现更优的特征提取能力，以此提升 ERP 信号的识别成效。

为此本研究构建了基于深度学习的 P300 识别办法，采用了 EEGNet 和 ShallowConvNet 两种深度学习模型，同时分别引入 SE 和 CBAM 注意力机制提高特征提取能力。此外，本文也对 Transformer 架构在 P300 分类任务进行了研究。模型的实验是在 BCI Competition III 的 Wadsworth 数据集上完成，在两名受试者之间进行对比实验，所有的深度学习模型都使用 t-SNE 可视化和消融分析来评估模型各个模块的贡献。

实验结果表明，EEGNet+SE 模型在 III-A 和 III-B 数据集上的 ERP 识别率分别达到 73.85%和 78.52%，均较 LDA 提升超过 2%；ShallowConvNet+SE 模型也实现了较好的性能改进。此外，进行 t-SNE 可视化和消融实验验证了模型中不同结构在区分类别中的有效性，说明本文所提方法能够更加准确地提取 P300 信号特征，对提升特征提取能力效率的实用性具有重要意义。

关键词：脑机接口；事件相关电位；P300 信号；深度学习

Enhancing P300 Classification in Brain-Computer Interfaces Using Deep Learning and Attention Mechanisms

Abstract

With the widespread application of intelligent algorithms in various IoT-based human-computer interaction systems, Brain-Computer Interface (BCI), as a key technological direction, has been widely used in intelligent IoT terminals and control systems.With the continuous development of brain-computer interface (BCI) technology, the recognition accuracy of P300 signals in event-related potential (ERP) has become a key point to improve the efficiency of character spelling. However, traditional classifiers (such as LDA) have performance limitations when processing EEG signals with low signal-to-noise ratio and prominent individual differences. More powerful models are needed to present better feature extraction capabilities to improve the recognition effect of ERP signals.

To this end, this study constructed a P300 recognition method based on deep learning, designed two deep learning models, EEGNet and ShallowConvNet, and introduced SE and CBAM attention mechanisms to improve feature extraction capabilities. In addition, this paper also discusses the Transformer architecture in the P300 classification task. The model uses the Wadsworth dataset of BCI Competition III, and a comparative experiment is conducted between two subjects. All deep learning models use t-SNE visualization and ablation analysis to evaluate the contribution of each module of the model.

The experimental results show that the ERP recognition rates of the EEGNet+SE model on the III-A and III-B datasets reached 73.85% and 78.52%, respectively, both of which were more than 2% higher than LDA; the ShallowConvNet+SE model also achieved good performance improvements. In addition, t-SNE visualization and ablation experiments verified the effectiveness of different structures in the model in distinguishing categories, which shows that the method proposed in this paper can more accurately extract P300 signal features, which is of great significance to the practicality of improving the efficiency of feature extraction capabilities.

Key words: Brain-Computer Interface; Event-Related Potential; P300 Signal;Deep Learning

目录

摘要 I
Abstract II
1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 3
1.3 论文主要研究内容与结构安排 4
2 数据预处理与 LDA 分类 6
2.1 数据预处理与叠加平均原理 6
2.1.1 带通滤波器设计 6
2.1.2 叠加平均和 R^2 系数原理 6
2.1.3 叠加平均结果分析与关键电极选择 7
2.2 线性判别分析（LDA）分类 9
2.3 本章小结 11
3 基于深度学习的 P300 分类模型设计与性能分析 12
3.1 EEGNet 模型及其性能分析 12
3.2 ShallowConvNet 模型及其性能分析 13
3.3 注意力机制原理与在 P300 分类任务中的贡献分析 14
3.4 两种模型的比较与分析 15
3.5 Transformer 架构在 P300 脑机接口中的应用与评估 17
3.5.1 Transformer 架构概述 17
3.5.2 Transformer 网络结构 17
3.5.3 Transformer 模型在 P300 数据集上的应用与结果 19
3.6 本章小结 20
4 模型可视化分析与结构消融 21
4.1 t-SNE 特征可视化分析 21
4.1.1 EEGNet 特征分布可视化 21
4.1.2 ShallowConvNet 特征分布可视化 23
4.1.3 Transformer 特征分布可视化 24
4.2 模型结构消融实验 27
4.2.1 EEGNet 结构消融与性能分析 27
4.2.2 ShallowConvNet 结构消融与性能分析 29
4.2.3 Transformer 结构消融与性能分析 30
4.3 本章小结 31
5 总结与展望 32
5.1 总结 32

5.2 展望 32
参考文献 34
致　谢 37
学位论文原创性声明 38
学位论文版权授权书 38

1 绪论

1.1 研究背景及意义

随着脑机接口技术的不断发展，P300 信号在智能家居、可穿戴设备等物联网众多应用领域中展现出重要价值。本文从脑机接口概述、ERP 与 P300 信号应用场景以及基于 P300 的 BCI 拼写器系统三个方面，对研究背景和实际意义进行了阐述。

脑机接口，即 Brain-Computer Interface，属于一种直接人机交互技术，此技术并不依赖外周神经系统，而是借助解析脑电信号来达成对外部设备的控制[1]。脑机接口有着诸多应用领域，举例来说，在工业自动化与控制范畴，脑机接口技术借助 BCI 提升生产效率以及操作安全性[2-3]。在娱乐领域，BCI 技术正推动着沉浸式与交互式体验的发展，让用户可凭借脑电信号直接操控游戏或者虚拟环境，以此提高用户于虚拟环境里的沉浸感[4-7]。在智能家居控制领域，针对老年人和残疾人而言，借助 BCI 技术可让用户对家具的控制更为便利，提升生活的便捷程[8-10]。在军事方面，脑机接口技术是其中的关键部分，它有希望改变武器系统，提高军事人员的认知与体能，还可在军事环境中开展目标检测，将依靠 BCI 技术设计的无人机应用于军事作战[11-15]。医学诊疗是脑机接口极为常见的应用领域，借助监测、修复、改善、替代、提高等功能，为严重的神经与精神疾病给予关键的干预手段。脑机接口已成为全球科技布局的焦段我国“十四五”规划和 2035 年远景目标纲概括了脑机接口作为科技前沿领域攻关，也是科技创新 2030——“脑科学与类脑研究”重大项目的布局重点之一[16]。因此，脑机接口在各个领域的应用变得越来越广泛，有着十分广阔的应用前景，由此可见，无论是在科研领域还是在实用领域，脑机接口都具有重要的研究价值和意义。

事件相关电位也就是 Event-RelatedPotential，简称为 ERP，它是大脑在面对特定刺激或者事件之时产生的、在时间上呈现锁定状态的脑电反应，在认知神经科学以及脑机接口领域有着广泛的应用[17]，ERP 反映出大脑在如感知、注意、记忆以及决策等过程里对外部事件的响应情况，被称作是“观察大脑高级认知活动的窗口”。ERP 信号一般在刺激事件之后的特定时间窗内呈现为一系列电位波形成分，其空间分布以及时间特性可把不同的认知加工阶段揭示出来。

在脑机接口系统当中，事件相关电位即 ERP，由于其响应时间比较短、不需要用户主动进行运动并且对刺激的反应较为明确，成为关键的控制信号。其中 P300 是 ERP 里研究较为深入、应用较为广泛的正向波成分，一般在刺激出现之后大约 300ms 的时候出现，并且其幅度跟目标刺激的稀有性、注意程度有着紧密的关联[18]，P300 信号有时间一致性比较强、个体间差异相对较小等优点，特别适用于无创 BCI 系统里的目标检测以及信息传输任务。例如，利用 P300 电位的缺陷来预测青春期前抑郁障碍有着良好的效果，而且早期干预治疗的效果和这一神经特征有着密切的联系[19]。把 P300 信号和也可以和电刺激系统结合到一起，实现了适用于慢性卒中患者的上肢运动功能康复方法，该方法对于患者运动能力恢复方面有着良好的临床效果[20]。在日常生活方面，P300 信号广泛应

用于智能家居领域，实现了不同场景下的智能家居控制，让脑机接口与物联网相结合，在民生方面有着较大贡献[21]。在安全管理方面，P300 信号还广泛应用于身份认证，由于每个人在特定刺激下产生的 P300 脑电波具有高度个体特异性，所以在身份认证任务中个体识别中表现出较好的分类性能[22]。在神经科学领域，P300 成分是衡量复杂声学环境下语音理解能力的重要神经指标，有助于揭示不同年龄段人群在听觉认知加工方面的差异[23]。

在诸多应用中，基于 P300 的字符拼写系统范式是最具代表性的。1988 年，Farwell 和 Donchin 提出了经典的 P300Speller 范式[24]，该系统通过闪烁的矩阵字符行和列来诱导用户注视目标字符时发生的 P300 信号，从而无需语言或动作即可实现文本输入和交流。该方法显著提高了重度运动障碍患者的沟通能力，也因此成为 P300 脑机接口研究的标准模型。

P300 拼写器系统通常采用一个 6×6 的字符矩阵作为输入，它包含了日常打字最常见的 36 个字符。P300 拼写器是基于经典的 Oddball 范式。字符矩阵的行列会按照一定的频率进行随机闪烁，在闪烁的 6 行中只有一行对应这个目标字符所在的行，每六列也会只有一列对应这个目标字符所在的列。目标刺激的事件远远小于非目标刺激的事件。在含有目标刺激的行或列被点亮时，会使被试者的大脑产生显著的 P300 反应。

通过对每次行列闪烁后用户脑电信号的分析，系统可以检测出哪些行和列引发了 P300，从而确定用户所注视的字符。该拼写方法实现了不需要语言和肢体运动的意图表达方式，是目前脑机接口技术中研究最成熟的拼写方案之一。

在本研究中，所采用的数据集来源于 BCI Competition III（2004）提供的 WadsworthBCI 数据集[25]。由于记录了两位受试者（SubjectA 和 SubjectB）在 P300 拼写范式下的脑电信号。本文将其划分为两个子集，即数据集 III-A 和 III-B。

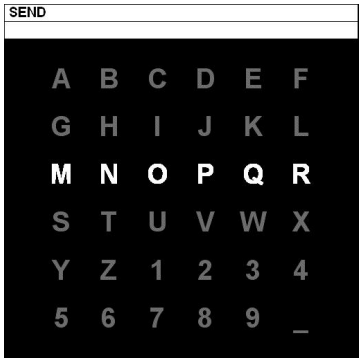

图 1-1 6×6 的字符矩阵

WadsworthBCIDataset 是一个用于脑机接口（BCI）研究的 P300 诱发电位数据集，采集自两位受试者在 P300 拼写范式下的脑电信号。实验中，受试者需要专注于一个 6×6 字符矩阵中的特定目标字符，如图 1-1 所示，矩阵的六行和六列会以 5.7Hz 的频率随机闪烁，含有该字符的行或列闪烁时，受试者的大脑会产生 P300 电位，由于在六行中只有一行含有目标字符，六列中只有一列含有目标字符，所以在一个刺激的循环中（六次行闪烁和六次列闪烁）会出现两个 P300 电位事件和十个非 P300 电位事件。由于 ERP

单次识别并不显著，本实验进行了 15 次叠加来提高正确性。

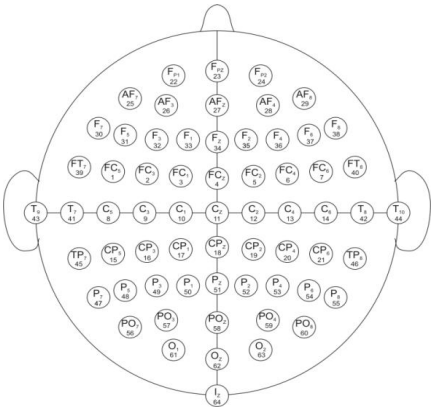

图 1-2 数据集采用的 64 个脑电通道

EEG 数据集的电极通道是 64 个（图 1-2），采样率是 240HZ，经过 0.1-60HZ 的带通滤波。数据集被划分为训练集（85 个字符）和测试集（100 个字符），每位受试者各有一组数据，存储为 Matlab 文件，包含信号矩阵（Signal）、闪烁标记（Flashing）、刺激编码（StimulusCode）、目标类型（StimulusType）以及训练集的正确字符标签（TargetChar）。

该数据集的目标是通过训练数据建立模型，预测测试集中受试者关注的字符序列。这一数据集主要用于研究 P300 脑机接口的字符识别性能，为脑电信号解码算法的发展提供基准。

1.2 国内外研究现状

P300 任务的分类性能评估依赖于 BCI Competition III（2004）提供的 WadsworthBCI 数据集[25]。根据官方报告显示，表现最好的参赛方案 ERP 识别率仅在 65%-70%之间。这一结果与 Farwell 和 Donchin[24]早期研究中报道的 P300 拼写系统性能基本吻合。这样的结果证明了 P300 数据集在采集时信噪比较大，个体差异性明显，影响 ERP 识别率。Krusienski 等人[26]使用了 P300 信号较强的时间窗口（300-500ms）同时采用了中线电极组合，如 CZ 和 PZ 通道，是脑电任务中较为重要的通道。在 LDA 分类器可以达到约 70%的 ERP 识别率。Rakotomamonjy 和 Guigue[27]采用支持向量机（SVM）的分类器，该分类器在一小部分可用数据上进行训练，并为其执行了通道选择程序。在该数据集上获得了 68.5%的 ERP 识别率，相比于 LDA 方法提高约 3 个百分点。虽然其已经在当时的 BCI 竞赛 III 的数据集 II 上进行了评估，并取得了竞赛中的最佳性能。但是现在来看这个结果并不是令人满意，ERP 识别率依然没有超越 70%。这样的结果进一步证实了该数据集的挑战性。

近年来，深度学习技术在 EEG 信号处理中展现出显著优势。Lawhern 等人[28]引入了 EEGNet 模型，一个用于基于脑电图（EEG）的脑机接口（BCI）的紧凑型卷积神经网络，构建了一个特定于脑电图的模型，该模型囊括了脑机接口（BCI）中众所周知的脑电图

特征提取概念。此模型在更大规模数据集上表现出色，但在 Wadsworth 数据集上的基准测试结果显示，其 ERP 识别率仍维持在 70%左右。后续人们也在不断地在基本模型中进行扩展，对各种深度学习模型中不同模块的组合和搭建。例如，Cecotti[29]等首次在该数据集上测试了 3 层 CNN 架构（包含 1 个卷积层和 2 个全连接层）。他们提出了多个单通道与多通道的卷积神经网络分类器，并在不同结构中进行测试，虽然最终的字符准确率最高可以达到 95.5%，但是在 5 折交叉验证中，其单次 ERP 识别率仅为 63.7%（SubjectA:65.2%，SubjectB:62.1%），这样的结构和传统 LDA 方法对比来说优势并不明显。也说明即使使用 CNN 模型，在此数据集中 P300 的单次检测性能仍然未能超越传统方法。为了解决个体差异较大，少数受试者的实验表现非常差的问题，Flamary 等人[30]提出的基于混合范数正则化的脑解码方法，这种方式可以使表现较差的受试者的 ERP 识别率明显提高，从实验结果来看，相对于传统的 LDA 分类器和 SVM 分类器来说，的确可以将少数表现很差的受试者的 ERP 识别率有了较好的提升，但是整体 ERP 水平提升幅度很低，仍然难以突破 70%的瓶颈。这样的结果并没有取得很好的改进。

基于此情况，研究者们在之前的基础模型上使用更深度的模型并融入其他模块进行改进。Roy 等人[31]的综述表明，针对 P300 这种信噪比较低、噪声明显的信号，传统的深度学习模型无法进行很有效的特征提取，但是注意力模块在这类任务中可以很有效的抑制噪声，增强模型的特征提取能力，所以在综述中提到了将注意力机制融入深度学习模型中可以有效的提升特征提取能力，强调了不同的注意力机制与传统模型结合应用在 EEG 中，为后续的模型改进提供了思路。Vaswani 等[32]提出了一种 Transformer 网络架构，该架构和卷积神经网络（CNN）或循环神经网络（RNN）不同，此模型不需要卷积操作，完全基于注意力机制进行，应用于两个机器翻译任务上。在两个机器翻译任务上的实验表明，这些模型不仅质量卓越，而且可并行化程度更高，训练时间也显著缩短。这种模型为提升 P300 分类任务准确性提供了启发。Song 等[33]通过实验证明，Transformer 在运动想象数据集效果较好，但对 P300 这类低信噪比的信号效果并不明显。当前研究结果表明，不管是传统分类器方法还是深度学习技术，在该数据集上的单次 ERP 识别率都在 60%-70%之间，和其他数据集相比这个结果并不好。这种现象是因为本研究所使用的数据集和其他脑电数据集相比噪声较大、P300 信号不够明显。

1.3 论文主要研究内容与结构安排

鉴于现有研究中无论是传统方法，还是深度学习方法，在 P300 脑机接口任务中均有识别率不高的问题。特别是在经典的 Wadsworth 数据集上，ERP 识别率始终在 70%以下，所以本文的目标是使用深度学习模型对 P300 分类任务进一步改善，提高 ERP 识别率。

本研究的主要研究内容为：先对数据进行预处理，将数据进行滤波和叠加平均操作，再使用传统分类器 LDA 进行分类。再使用深度学习的模型对其进行改进。本文构建了 EEGNet 和 ShallowConvNet 两种深度学习模型进行改进，并同时引入 SE 和 CBAM 注意力机制进行强化。此外也对 Transformer 模型进行实验，观察其在 P300 数据集上应用效果是否可以超越 LDA 分类。本文也同时做 t-SNE 可视化分析和消融实验，观察分类任

务中不同的卷积模块的贡献，为以后的研究中不同卷积模块的组合和搭建提供了基础。

本文共分为五章，具体结构如下：

第一章为绪论，对 P300 脑机接口的研究背景与意义进行阐述，介绍 P300 拼写器的原理和目前对于本文的数据集研究现状，总结现有方式的局限性，并提出本文的创新点。

第二章为数据预处理与 LDA 分类：详细介绍了对 Wadsworth 数据集的处理流程，包括带通滤波处理，叠加平均及 R2 系数分析，再通过 LDA 分类器验证传统方式的分类器的性能。

第三章为用深度学习的方式改进 LDA 分类。本文采用了 EEGNet 和 ShallowConvNet 模型，结合 SE 与 CBAM 注意力机制，对比分析两类模型在 P300 信号分类中的效果。此外还对 Transformer 架构在 P300 脑机接口中的应用进行评估，对 Transformer 架构的进一步优化进行了展望。

第四章为消融实验与 t-SNE 可视化分析，通过逐层的消融实验与 t-SNE 降维可视化，验证网络中对特征提取的贡献。

第五章为总结，总结本研究的成果，分析了在 P300 分类任务中深度学习模型的优势，并对未来进行展望。

2 数据预处理与 LDA 分类

2.1 数据预处理与叠加平均原理

在处理脑电信号时，对数据进行预处理至关重要，因为噪声和伪信号会对数据产生很大影响，预处理主要包括滤波和叠加平均。由于 III-A 和 III-B 的预处理和叠加平均过程相同，这里只对 III-A 的处理进行论述。

2.1.1 带通滤波器设计

原始数据集的信号在 0.1Hz 至 60Hz 范围内，这显然不好，P300 信号通常位于 0.1Hz 至 30Hz 的频率范围内，所以本文采用了带通滤波器用于去除低频和高频噪声来增强信号质量。我们采用了频率为 0.1Hz 至 30Hz 的 5 阶带通滤波器，这样可以有效去掉低频和高频噪声干扰且适用于 240Hz 采样率的数据集。滤波器的参数设计参考了 Delorme 等[34]开发的 EEGLAB 工具箱标准。滤波器具体设计参数如下：

由于原始采样频率为 240Hz,则奈奎斯特频率（Nyquist Frequency）为 120Hz。将目标低截止频率为 0.1/120，高截止频率为 30/120。我们使用 Python 中的 scipy.signal.butter 函数构建 5 阶带通滤波器系数，随后通过 scipy.signal.filtfilt 函数对每个试次（trial）与每个通道（channel）进行双向零相位滤波处理。filtfilt 函数经过前后向两次滤波，能够使滤波后的信号不会发生时间偏移，在事件相关电位（ERP）相关的信号数据应用广泛。

通过滤波处理后的训练数据集和测试数据集信噪比将会大幅提升，会使后续的叠加平均操作和使用分类器训练的效果更加明显。滤波处理在本研究中是非常重要的任务，因为数据的质量影响着后面的所有的叠加平均处理过程，甚至对后续深度学习模型的应用性能也有很大的影响。

2.1.2 叠加平均和 R^2 系数原理

在 P300 脑机接口（BCI）研究中，单次 EEG 试验包含大量噪声，而 P300 作为诱发电位（ERP）的一种，需要通过叠加平均提高信号质量。叠加平均处理是预处理中十分关键的步骤，叠加平均可以显著的提高信噪比，将刺激成分增强，从而在 ERP 波形图中可以十分清晰的观察到目标与非目标的波形区别。叠加平均处理是整个研究的基础步骤，可以使后面分类器更加高效的识别，避免因为信号不强而影响整体的 ERP 识别率。在本研究中，针对数据集中目标刺激（Target）和非目标刺激（Non-Target）分别提取 EEG 片段，并对多个试验的相同类别信号求均值，以增强信噪比（SNR）。其数学表达如下：

目标刺激的叠加平均：

$$target_avg = \frac{1}{NT}\sum_{i=1}^{NT} X_T^i \tag{1-1}$$

非目标刺激的叠加平均：

$$non_target_avg = \frac{1}{NN}\sum_{i=1}^{NN} X_N^i \tag{1-2}$$

其中：X_T^i表示第 i 个目标刺激的 EEG 片段。

X_N^i表示第 i 个目标刺激的 EEG 片段。

NT 为目标刺激的总数。

NN 为非目标刺激的总数。

通过对目标和非目标 EEG 片段分别求均值，获得目标 P300 和非目标 ERP 的典型响应。

R^2（决定系数）是统计学中衡量数据集与模型拟合优度的一种常用指标[35]，常用于回归分析中。在 P300 的分析中，R^2 作为一个衡量目标刺激与非目标刺激之间信号差异度的统计量，可以帮助我们了解这两类刺激之间在 EEG 信号上有多大的区别。

在本研究中，R^2 计算公式如下：

$$R^2 = \frac{\sqrt{NT \cdot NN} \cdot |\bar{X}_T - \bar{X}_N|}{(NT + NN) \cdot std(NT \cup NN)} \tag{1-3}$$

其中：$\bar{X}_T$ $\bar{X}_N$是目标和非目标刺激的均值。

$std(NT \cup NN)$ 是目标和非目标刺激合并后的标准差。

通过这个公式，可以量化目标刺激与非目标刺激之间的区分度。

较大的 R^2值表示目标刺激和非目标刺激之间的区别较明显；

较小的 R^2值则表示目标与非目标之间的差异不大。

本研究根据 Flashing 矩阵中的闪光事件标记（下降沿触发），截取[-24，216]采样点（对应-100ms 至 900ms 时间窗）的 EEG 片段。根据实验标记将响应分为两类：当 StimulusType 值为 1 时判定为目标刺激（用户注视字符），其余情况归为非目标刺激。经统计，最终获得有效目标试次 2550 次，非目标试次 12750 次，符合 P300 范式目标/非目标刺激的 1:5 标准比例。此特征被提取在一个三维矩阵中，（试次*时间点*通道数），进行平均后的维度为（时间点*通道数）。

2.1.3 叠加平均结果分析与关键电极选择

在做完数据的预处理与叠加平均处理后，需要对脑电信号 ERP 图和 R^2 系数进行观察与分析，在 P300 的任务中，ERP 图最关键的成分就是 P300 的波形，在受到外界刺激时，在大约 300ms 时会产生一个正向的波形，表现为一种正向的波动。每个脑电通道都会有其独特的响应特性。

在以往的研究中，通过对大量受试者的实验观察发现，在这 64 个 EEG 通道中，不同通道反应的 P300 信号结果不同，在中线电极（中央区（Cz）、顶区（Pz）、额区（Fz）和枕区（Oz））表现较强于其他电极。这些区域是 P300 信号最强的区域，在受到目标刺激时会产生更高的振幅变化。因此，在 P300 相关的研究中都会将中线电极作为关键电极进行分析。

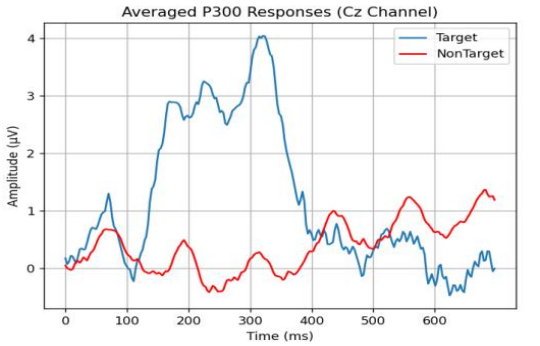

a) Cz 通道 ERP 叠加平均图

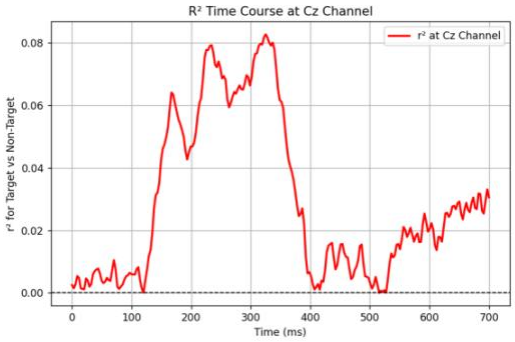

b) Cz 通道 R^2 系数图

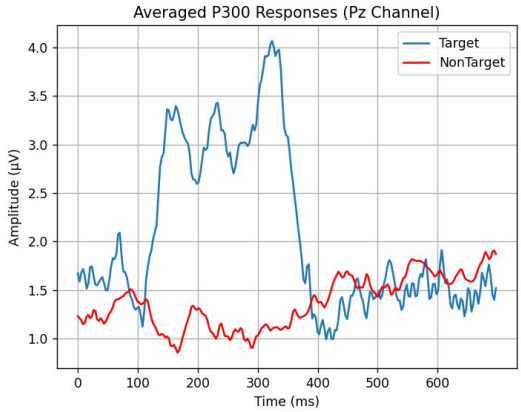

c) Pz 通道 ERP 叠加平均图

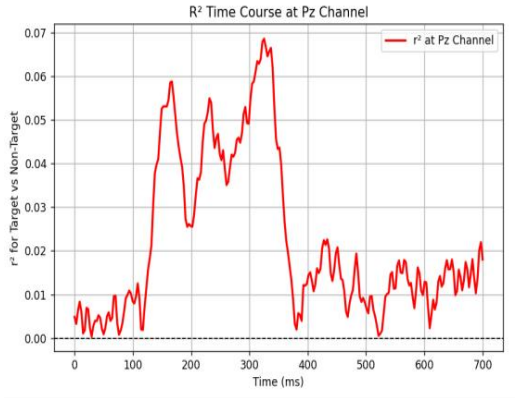

d) Pz 通道 R2 系数图

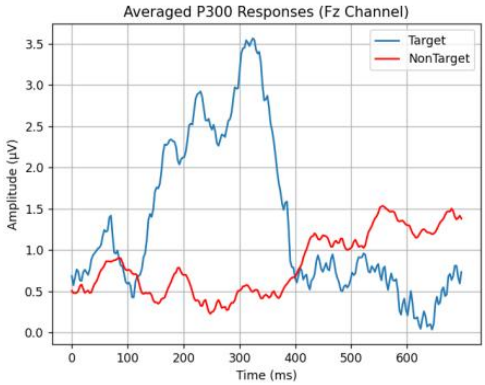

e) Fz 通道 ERP 叠加平均图

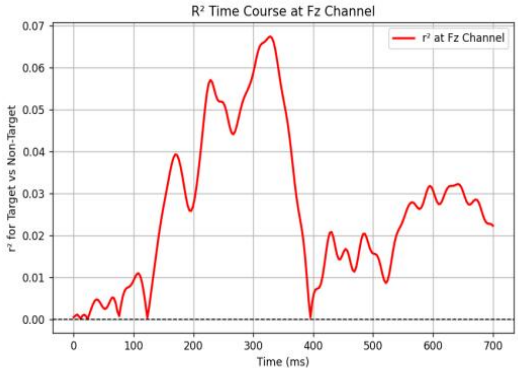

f) Fz 通道 R2 系数图

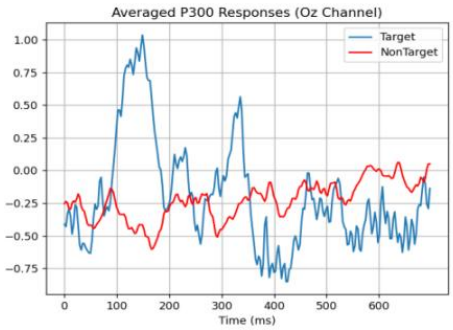

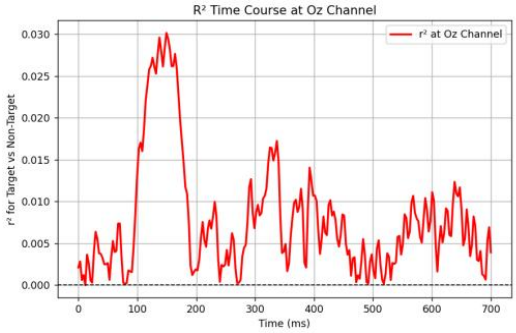

g) Oz 通道 ERP 叠加平均图　　h) Oz 通道 R2 系数图

图 2-1 不同中线电极通道的 ERP 叠加平均与 R^2系数分布（III-A 数据集）

如图 2-1 所示，由于中线电极信号较强，信噪比高，更容易观察 P300 信号的波形，因此本文选取了 P300 信号最强的中线电极作为典型 ERP 叠加平均图和 R^2 系数图进行阐述。

如图 2-1 中的 a 和 b 所示，Cz 通道在 300ms 附近表现出明显的正向波形，其 R^2 系数在此时段达到了 0.08，在 300ms 目标类和非目标类达到了非常明显的区分。说明 Cz 通道能够清晰地区分目标与非目标刺激。该通道常被认为是 P300 信号较强的分布区域之一，是进行 ERP 特征提取的重要通道。

如图 2-1 中的 c 和 d 所示，Pz 通道同样在 300ms 附近表现出明显的正向波形，R^2 系数也达到了比较高的效果，但相较于 Cz 略微偏弱。说明 Pz 对目标刺激的响应虽略逊于 Cz，但仍具有较好的判别力。作为 ERP 研究中的标准通道，Pz 在增强信噪比、辅助分类等方面发挥了重要作用。

如图 2-1 中的 e 和 f 所示，在 Fz 通道中，ERP 信号和 R^2 系数不如 Pz 和 Cz 明显，但在 300ms 左右效果仍然不错。说明 Fz 在目标与非目标之间的差异相比 Pz 和 Cz 不够显著。但由于额叶区域与注意力和认知控制相关，Fz 仍可为理解 P300 的认知机制提供一定的信息。

如图 2-1 中的 g 和 h 所示，Oz 通道表现出不同于其他通道的特性，其在 100ms 到 200ms 之间出现了明显的早期视觉诱发波形，这部分可能对应 P1 或 N1 成分，而在典型的 300ms 窗口并未呈现出清晰的 P300 波形。其 R^2 系数的变化也多集中在早期时间窗，提示 Oz 更可能反映的是视觉刺激初期的加工过程，说明其在 P300 检测中作用有限，但对早期视觉处理的研究具有参考价值。

2.2 线性判别分析（LDA）分类

线性判别分析（LinearDiscriminantAnalysis，LDA）是一种经典的分类算法[36]，基本原理是对两类分类较难的样本找到一个最佳投影方向，这样可以把样本之间不同类的差异放得最大，并且在相同类型的样本之间差异最小化。

在 LDA 分类前，先对数据集进行降维处理，将原始采样频率 240Hz 降到 20Hz，降采样后，结合 EEG 的 64 个通道，这样就可以得到目标刺激特征矩阵（目标刺激次数，

64*20）和非目标刺激特征矩阵（非目标刺激次数，64*20）。数据经过降采样与特征提取后，训练集包含 2550 个目标刺激（Target）和 12750 个非目标刺激（Non-Target），测试集中包含 100 个字符，每个字符闪烁 15 轮，共 3000 个目标刺激和 15000 个非目标刺激。最终，所有 EEG 片段被转换为形如（样本数×1280）的矩阵用于分类。

在 P300-Speller 任务中，每个字符由 6 行+6 列共 12 次闪烁决定。由于 P300 特有的低信噪比特性，单次的刺激对于字符的识别效果很差，数据集中采用 15 次重复来提高准确性，所以使用 LDA 分类得到的概率分数也是需要用叠加平均的方式进行字符的预测，对于每个目标字符，本研究计算其每个行列刺激的累积决策值，然后选择决策值最高的行和列进行交叉索引，最终确定识别的字符。

如图 2-2 和图 2-3 所示，在单次循环的方式下，字符识别的准确率很低，但是随着重复次数的增加，字符识别率的准确性逐渐变得让人满意。虽然字符识别率是衡量系统整体性能的重要指标，但其核心仍依赖于事件相关电位（ERP）识别率的提升。传统 P300-Speller 任务通常通过字符级别的准确率评估系统表现，即统计目标字符被正确识别的概率。然而，字符识别的最终结果是 ERP 识别率在多次重复刺激后的累积效应，由于累加的方式类似于一种投票机制，依赖最后累计的最大决策值来确定最后的识别字符，这样可能会有“碰运气”的情况存在，有一定的不确定性，容易掩盖模型在单次刺激下的实际能力，不容易反映分类器的效果。因此，仅依赖字符识别率可能无法全面反映分类器对单次 EEG 片段的分类能力。相对于字符识别率，ERP 识别率是评估单次行列刺激下的分类性能，更能真实的反映分类器的分类性能，可以有效避免叠加决策值阶段“碰运气”的干扰，此外，ERP 识别率也是字符识别率的基础性能指标，ERP 识别率高，字符识别率也会高。于是，本研究进一步关注其 ERP 识别率，其思路是：对于一个字符来说，会有 12 次刺激（6 行+6 列），在 6 行刺激中会有 1 个是目标行，在 6 列刺激中会有一个是目标列，如果在 6 行找到目标行或 6 列中找到目标列，说明本轮的识别就是正确的，即 ERP 识别率就是识别正确多少个轮次（round）。

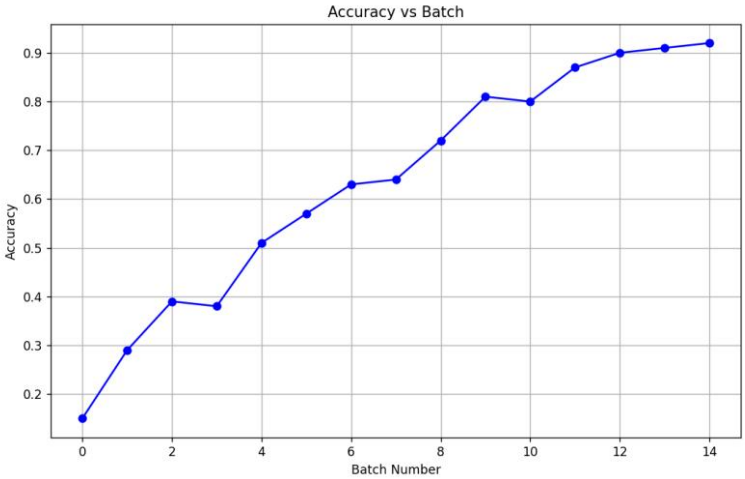

图 2-2 III-A 字符识别率随着重复的增加而上升

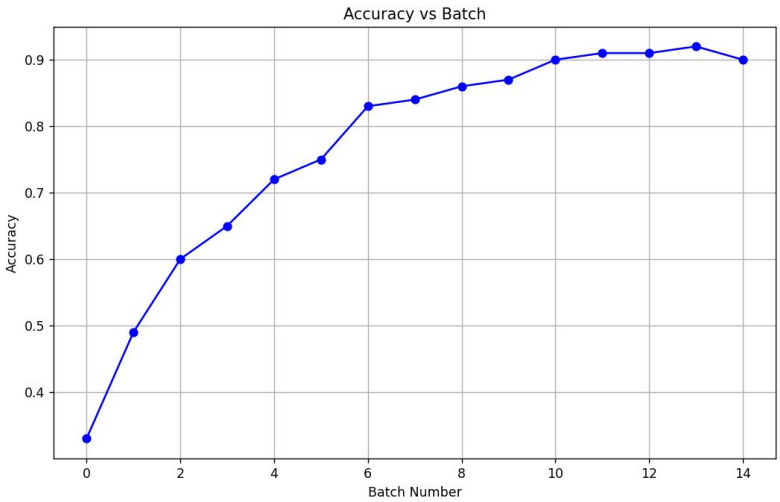

图 2-3 III-B 字符识别率随着重复的增加而上升

如表 2.1 所示，此研究的 LDA 分类在 III-A 数据集取得了 72.70%的正确率，III-B 数据集取得了 75.97%的正确率。

表 2.1 LDA 分类准确率

数据集	ERP 准确率（%）
III-A	72.70
III-B	75.97

2.3 本章小结

本章对脑电数据集的预处理过程和叠加平均原理进行了详细描述，并介绍了传统分类器 LDA 的实现原理和在 P300 分类任务的实现过程。其中，将四个信号最强的中线电极（Cz、Pz、Fz、Oz）作为实验分析的电极，观察 P300 信号的 ERP 波形和 R^2 系数。通过波形图和 R^2 系数图表明，通过滤波和叠加平均操作，有效的提高了 P300 信噪比。同时，本章使用线性判别分析（LDA）方法对预处理后的数据进行分类，取得了较好的 ERP 识别率，此外也展示了在 15 次叠加过程中字符识别准确率的曲线，体现了 LDA 分类器在 P300 分类任务中取得的效果良好。

3 基于深度学习的 P300 分类模型设计与性能分析

在上一章节，通过 LDA 的识别的结果来看，结果即使还算比较满意，但是仍然可以继续改进。线性判别分析（LDA）虽是一种经典的分类方法，但在处理复杂的 EEG 信号时，LDA 的分类还是存在着一定的局限性，尤其是在信噪比较低的情况下。Schirrmeister 等[37]通过实验证明，CNN 能自动学习 EEG 信号的时空特征，Kumar 等[38]在运动想象 EEG 分类中验证了 CNN 自动提取时空特征的有效性，其研究表明，通过卷积方式可以很好地提升分类效果。所以本研究通过深度学习的方法对传统分类器进行改进，主要通过卷积神经网络（CNN）的方式对 ERP 信号进行有效的特征提取与分类，从而改善 LDA 的性能。本研究主要实现了两种深度学习模型作为基本模型：EEGNet 和 ShallowConvNet 模型，并在这两个模型基础上与注意力机制结合，以进一步提高分类性能。实验结果表明，通过深度学习的方式改进 LDA，可以对 ERP 的识别率进行比较有效的提升。

3.1 EEGNet 模型及其性能分析

EEGNet 模型在 P300 分类任务中非常常见。模型由时间卷积层、空间卷积层和可分离卷积层构成，可分离卷积由时间卷积和逐点卷积构成。本研究先对基本 EEGNet 进行实验，再将 SE（Squeeze-and-Excitation）注意力机制和 CBAM（ConvolutionalBlockAttentionModule）机制引入。SE 可以使模型明白哪些通道更为重要，CBAM 的独特之处在于它还引入了空间注意力机制，下面是 EEGNet 结构进行详细介绍（表 3.1）：

EEGNet 模型的第一层结构是时间卷积层，时间卷积层主要通过提取 P300 的时间特征，通过反复实验得出最佳的实验卷积核是（1，4），卷积核过大会导致信息处理不完全，过小会导致时间扭曲，都会导致 ERP 识别率的下降。

EEGNet 的第二层结构是空间卷积层，由于数据集是 64 个 EEG 通道，所以使用（64，1）的卷积核进行空间特征的提取。在这层后面使用注意力机制，对通道赋予不同的权重，这个通道指的是卷积后的特征通道，而不是脑电的 64 个电极通道。这样模型就可以判断哪些通道更为重要，对更加重要的通道的特征提取就会增强，对很多没有意义的通道则会忽略。

EEGNet 的第三层结构是逐点卷积层，逐点卷积层包括时间卷积和逐点卷积，时间卷积核还是采用（1，4）进行时间维度的特征提取，逐点卷积采用（1，1）的卷积核，虽然这样的操作不改变数据的维度，但是可以将前面提取过的特征进行整合，进一步地提高分类准确性。

在本研究中，EEGNet 被用来对降采样后的 EEG 数据进行分类。通过将数据形状调整为（batch_size，1，64，40），64 是 EEG 通道数，40 是降采样后的时间步长。使其符合 CNN 的输入需求，EEGNet 能够有效地提取信号的时空模式，并通过卷积操作学习到复杂的特征。

表 3.1 EEGNet 模型

层名称	计算操作	输入维度	输出维度
输入层	原始 EEG 数据	（batch，1，64，40）	（batch，1，64，40）
时间卷积	Conv2D（1×4）+padding	（batch，1，64，40）	（batch，16，64，41）
平均池化	AvgPool2D（1×2）	（batch，16，64，41）	（batch，16，64，20）
深度卷积（空间）	DepthwiseConv2D（64×1）	（batch，16，64，20）	（batch，16，1，20）
SE/CBAM 注意力	通道 or 空间注意力	（batch，16，1，20）	（batch，16，1，20）
可分离卷积（时间+逐点）	Conv2D（1×4）+Conv2D（1×1）	（batch，16，1，21）	（batch，16，1，21）
展平	Flatten	（batch，16，1，21）	（batch，336）
全连接	FC	（batch，336）	（batch，2）

3.2 ShallowConvNet 模型及其性能分析

ShallowConvNet 和 EEGNet 相比，是一种结构相对简洁的卷积神经网络结构，它主要由时间卷积层和空间卷积层两部分组成。这种轻量级的模型对 P300 数据量较小的数据集非常适用。ShallowConvNet 主要提取关键时间和通道信号特征，训练时间较短。在本研究中，我们使用 ShallowConvNet 对降采样后的 EEG 数据进行分类，对其分类结果进行分析和评估，为了增强模型的分类性能，在 ShallowConvNet 的原始模型中也同时引入了 SE 和 CBAM 两种注意力机制，下面对于 ShallowConvNet 结构进行详细介绍（表 3.2）：

ShallowConvNet 的第一层为时间卷积层，和 EEGNet 模型相同，也采用了（1，4）的时间卷积核，对较短时间片段的 EEG 信号进行时间卷积，精确捕捉短暂而显著的 EEG 信号片段。

ShallowConvNet 的第二层为空间卷积层，也使用了（64，1）的空间卷积对 64 个通道信息进行信息整合。同样地，也是在这一层的后面加入了两种注意力机制，对不同的特征通道赋予不同的权重。

ShallowConvNet 模型和 EEGNet 模型相比没有可分离卷积，模型的结构更加简单，但是在特征提取方面与 EEGNet 模型相比稍逊色。

在本研究中，同样地，ShallowConvNet 模型也被用来对降采样后的 EEG 数据进行分类。数据形状也为（batch_size，1，64，40）。ShallowConvNet 也能够有效地提取信

号的时空模式，虽然效果不如 EEGNet 模型，但是训练速度明显加快。

表 3.2 ShallowConvNet 模型

层名称	计算操作	输入维度	输出维度
输入层	原始 EEG 数据	（batch，1，64，40）	（batch，1，64，40）
时间卷积	Conv2D（1×4）+padding	（batch，1，64，40）	（batch，16，64，41）
平均池化	AvgPool2D（1×2）	（batch，16，64，41）	（batch，16，64，20）
空间卷积	DepthwiseConv2D（64×1）	（batch，16，64，20）	（batch，16，1，20）
SE/CBAM 注意力	通道 or 空间注意力	（batch，16，1，20）	（batch，16，1，20）
展平	Flatten	（batch，16，1，20）	（batch，320）
全连接	FC	（batch，320）	（batch，2）

3.3 注意力机制原理与在 P300 分类任务中的贡献分析

在深度学习模型进行训练时，在卷积的过程中会生成多个特征通道，这些通道的重要性是不一致的，如果默认将所有通道的重要性归为一致，可能会导致关键特征削弱，非关键特征增强，影响分类效果。在使用传统的深度学习网络模型时，模型对所有的通道的关注度都是相同的，无法判断哪些通道更为重要。为了解决这个问题，本研究在传统的深度学习模型中，引入了注意力机制对更为重要的通道更为关注，进一步提高 ERP 识别率。

本研究引入了两种注意力机制，分别是 SE（Squeeze-and-Excitation）机制与 CBAM（Convolutional Block Attention Module）机制。SE 注意力机制是通道注意力机制，在全局范围内观察各个通道的通道的重要性，通过评估其贡献对不同的通道进行加权调整，这样模型就能够发现哪些通道更为重要，从而增强特征提取能力。CBAM 机制是在 SE 机制的基础上，同时增加了空间注意力机制，深度学习模型融合 CBAM 注意力机制后，不仅可以发现哪些通道更为重要，而且能判断通道中的哪些位置更为重要，对数据的空间分布提取更加细致。

如图 3-1 所示，EEGNet 模型和 SE 注意力机制结合在两个数据集上均有性能提升，在 III-A 数据集中提升约 0.32%，III-B 数据集提升约 0.48%，表明 SE 注意力机制可以明显增强 EEGNet 模型的特征提取能力，进而提高了 ERP 识别率。EEG 模型和 CBAM 注意力机制结合在 III-A 数据集也有一定提升（约 0.14%），但是在 III-B 数据集反而略有下降，此结果说明，EEGNet 模型结合 CBAM 机制效果不如 SE 机制稳定，ERP 识别率

提升不如 SE 机制明显。

对于 ShallowConvNet 模型，结合两种注意力模型也有一定的性能提升，特别是结合 CBAM 注意力机制在在 III-A 数据集中提升了约 0.9%，效果十分明显，此结果表明 ShallowConvNet 模型更加适合与 CBAM 注意力机制进行特征提取。

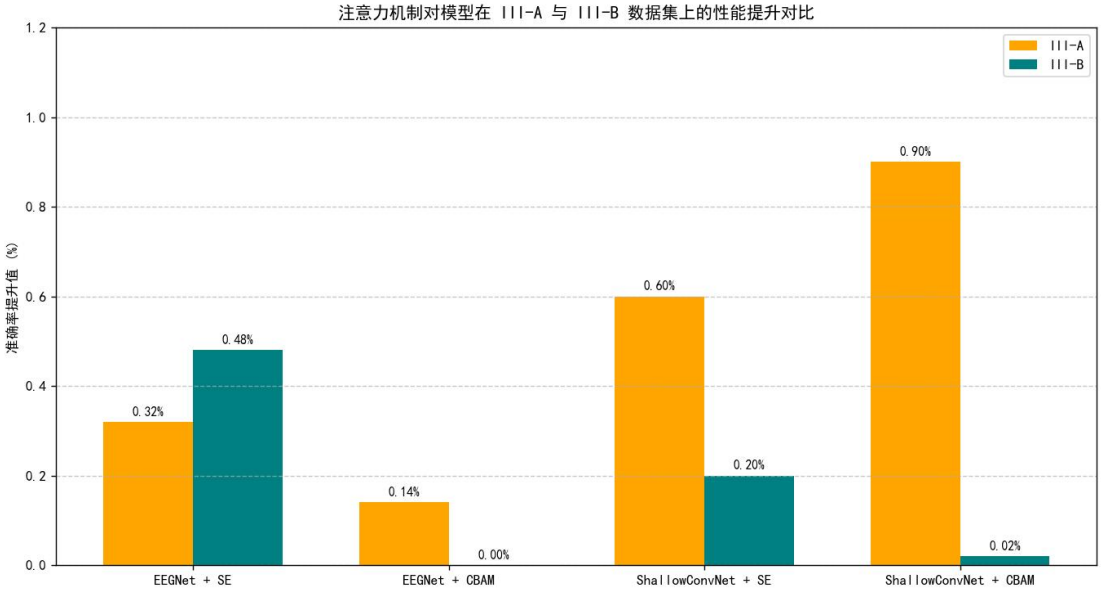

图 3-1 注意力机制对模型的性能提升对比

3.4 两种模型的比较与分析

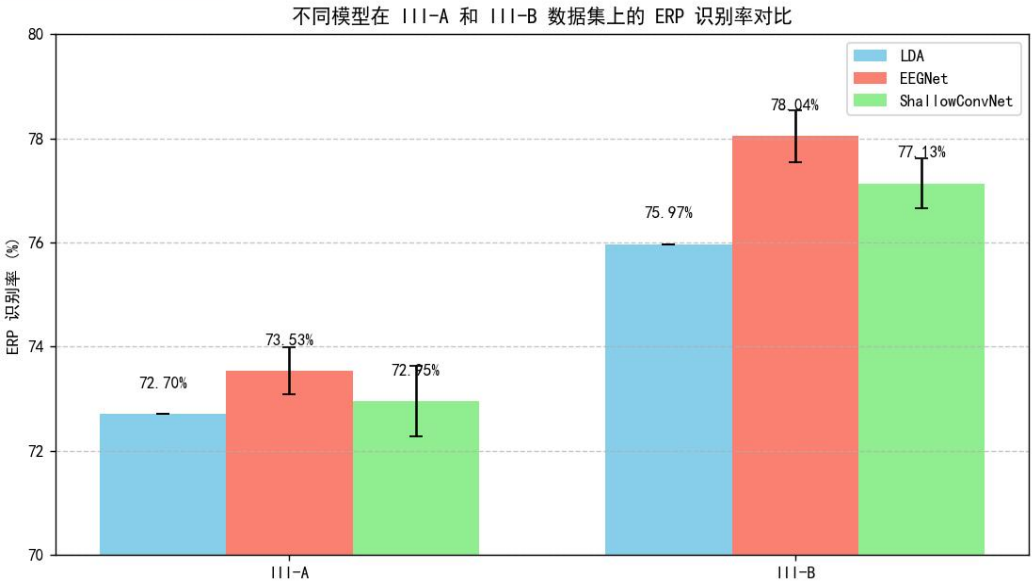

图 3-2 不同模型在两个数据集上的 ERP 识别率

表 3.3 LDA 与基本深度学习模型在两个数据集上的 ERP 识别率对比

模型名称	数据集 III-A（%）	数据集 III-B（%）
LDA	72.70	75.97
EEGNet	73.53	78.04
ShallowConvNet	72.95	77.13

为了比较传统分类器与深度学习模型方法的性能，如图 3-2 和表 3.3 所示，从实验结果可以看出，LDA 分类器在两个数据集上的 ERP 识别率分别为 72.70%和 75.97%。使用 EEGNet 模型在两个数据集上的 ERP 识别率分别为 73.53%和 78.04%，使用 ShallowConvNet 模型在两个数据集上的 ERP 识别率分别为 72.95%和 77.13%。

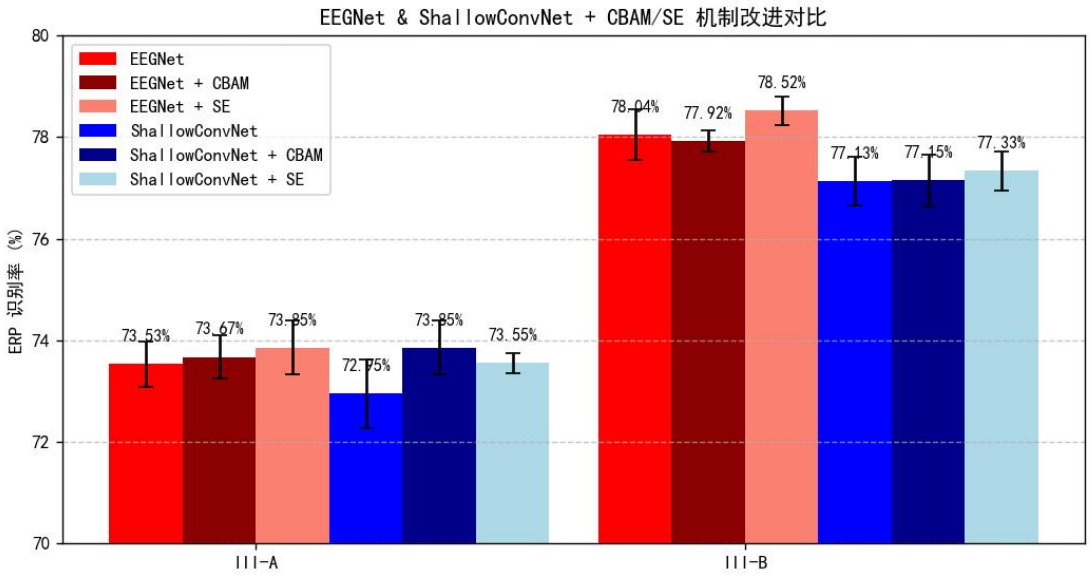

图 3-3 两种深度学习模型和自注意力机制结合在两个数据集上的 ERP 识别率

表 3.4 引入注意力机制后不同模型的 ERP 识别率对比

模型名称	数据集 III-A（%）	数据集 III-B（%）
EEGNet+SE	73.85	78.52
EEGNet+CBAM	73.67	77.92
ShallowConvNet+SE	73.55	77.33
ShallowConvNet+CBAM	73.85	77.15

如图 3-3 和表 3.4 所示，从实验结果可以看出，在 III-A 数据集中，EEGNet 模型结合 SE 自注意力机制的识别率为 73.85%，EEGNet 模型结合 CBAM 自注意力机制的识别率为 73.67%，ShallowConvNet 模型结合 SE 自注意力机制的识别率为 73.55%，ShallowConvNet 模型结合 CBAM 自注意力机制的识别率为 73.85%。在 III-B 数据集中，EEGNet 模型结合 SE 自注意力机制的识别率为 78.52%，EEGNet 模型结合 CBAM 自注意力机制的识别率为 77.92%，ShallowConvNet 模型结合 SE 自注意力机制的识别率为

77.33%，ShallowConvNet 模型结合 CBAM 自注意力机制的识别率为 77.15%。

通过以上的结果可以分析出结论，无论在 III-A 数据集还是在 III-B 数据集上，深度学习模型相比于传统 LDA 分类器在 p300 识别任务上取得了更好的效果。说明卷积神经网络在提取复杂的时空特征方面具备比 LDA 更强的能力。同时也可以发现，在这两个深度学习模型中，EEGNet 的整体识别效果要好于 ShallowConvNet，这可能由于 EEGNet 模型更为复杂，在时域和空间域上的特征提取能力更强。相反 ShallowConvNet 模型是一种轻量级的模型，模型结构比较简单，捕捉特征的能力不如 EEGNet 模型。在引入自注意力机制后，两种模型的性能进一步提高。但不同的注意力机制在不同的模型表现效果不同。在 III-B 数据集中，EEGNet 结合 SE 注意力机制的识别率达到了 78.52%，效果非常明显，比原始的 EEGNet 模型提升了 0.48%；ShallowConvNet 结合 SE 机制后的提升也较为显著（提升了 0.20%）。CBAM 注意力也对普通模型进行了较为有效的提升，但是效果不如 SE 注意力机制显著。

3.5 Transformer 架构在 P300 脑机接口中的应用与评估

3.5.1 Transformer 架构概述

Transformer 是一种新型的网络架构，它通过注意力机制将输入数据编码为强大的特征。Transformer 最初被应用于自然语言处理，如今已在 BCI 领域取得显著进展，其独特的自注意力机制能够巧妙地处理脑信号的时间动态变化。Song 等[33]使用注意力转换策略有效地利用了空间和时间特征。在 EEG 多分类问题上达到了当前最佳水平，并且参数更少。Song 的研究是该领域首次基于 Transformer 思想提出详细而完整的方法。该方法对推动脑机接口（BCI）的实用化具有良好的潜力。尽管 Transformer 在其他领域表现优越，但在本研究发现 Transformer 模型在 P300 二分类中的性能中不如 EEGNet 模型和 ShallowConvNet 模型，甚至逊色于传统的 LDA 分类方式。

3.5.2 Transformer 网络结构

如表 3.3 所示，Transformer 的第一层结构是 PatchEmbedding 层，它是 Transformer 的输入处理模块，主要负责把输入的 EEG 信号转换成适合于 Transformer 处理的形式。首先通过时间卷积提取时间特征，再通过空间卷积提取通道特征，然后通过归一化和激活函数处理，使用 1×1 卷积将特征投影到指定维度，最后为序列中的每个 token 添加时序位置信息。

Transformer 的第二层结构是多头注意力层，需要说明的是，此处所采用的多头注意力机制（Multi-HeadSelf-Attention）属于 Transformer 架构中的标准组成部分，与前文中提到的 SE（Squeeze-and-Excitation）和 CBAM（ConvolutionalBlockAttentionModule）等通用于卷积神经网络中的注意力机制在结构与应用目的上均有所不同。它主要通过多个注意力头从不同的子空间中学习输入序列中不同部分之间的依赖关系，从而增强模型的表示能力。多头注意力层在 Transformer 模型中是最为重要的结构。在本研究中，多头注意力机制采用了如下计算流程：

对于输入的特征序列 $X \in R^{B\times N\times d}$ 其中 B 表示 batch_size 的大小，N 表示 token 数量（即 Patch 数，本文为 4），d=64 表示特征维度（embeddingsize），通过线性映射分别生成查询（Query）、键（Key）、值（Value）向量：

$$Q = XW^{Q}, K = XW^{K}, V = XW^{V} \tag{3-1}$$

$W^{Q}, W^{K}, W^{V} \in R^{d\times d}$ 是可学习的线性变换矩阵。在多头机制下，上述 Q、K、V 会被拆分为 h=4 个头，每个头的维度 dh=d/h=16，并进行如下注意力计算：

$$Attention(Q,K,V) = Softmax\left(\frac{QK^{T}}{\sqrt{d_h}}V\right) \tag{3-2}$$

注意力头的输出随后在最后一个维度拼接后再通过一个线性变换映射回原始维度：

$$MultiHead(Q,K,V) = Concat(head_1,\ldots,headh_h)W^{O} \tag{3-3}$$

$W^{O} \in R^{d\times d}$ 是输出投影矩阵。

采用这样的结构可以同时关注 P300 信号中不同时间片与通道之间的潜在关联，可精准捕捉 ERP 信号中的关键特征时段。

Transformer 的第三层结构是前馈神经网络层，它由两个全连接层组成，通过激活函数引入非线性。第一层将输入维度扩展四倍，再通过第二层转换成原来的维度。在 P300 信号处理中，该层能将注意力层输出的特征进一步表达，将复杂的时空模式进行更细致的捕捉。

Transformer 的第四层结构是编码器层，此层由多头注意力子层和前馈神经网络子层构成，每个子层都采用了残差连接和归一化处理。这样可以使模型通过堆叠多个编码器层将进行更深度的特征提取，并且可以避免梯度消失的问题。在本研究中采用 2 层的编码器结构，因为网络过深会导致数据量并不是很大的数据集过拟合，从而导致模型的性能下降。

Transformer 的第五层结构是分类头层，本层先对 Transformer 编码器层的输出进行全局平均池化，再通过两个全连接层进行最后的二分类。这种设计模型能够有效地提取特征，在全连接层之后并进行高效的分类决策，同时可以有效的防止数据过拟合。进而提升模型的性能表现。

表 3.5 Transformer 模型

模块	操作描述	输入维度	输出维度
PatchEmbedding	时间卷积（1×20）	（B，1，64，40）	（B，64，64，21）
	空间卷积（64×1）	（B，64，64，21）	（B，64，1，21）
	1×1 卷积+rearrange	（B，64，1，21）	（B，21，64）
	添加位置编码	（B，21，64）	（B，21，64）

表 3.5 Transformer 模型-续表

模块	操作描述	输入维度	输出维度
MultiHeadAttention	Q、K、V 线性映射	（B，21，64）	Q/K/V:（B，4，21，16）
	注意力输出（拼接头）	（B，4，21，16）	（B，21，64）
	最终 projection	（B，21，64）	（B，21，64）
FeedForwardBlock	两层全连接层，维度扩展再压缩	（B，21，64）	（B，21，64）
EncoderBlock×2	多头注意力+残差	（B，21，64）	（B，21，64）
Classifier	Reduce 平均池化+FC	（B，21，64）	（B，64）→（B，2）

3.5.3 Transformer 模型在 P300 数据集上的应用与结果

如图 3-4 和表 3.6 所示，从实验结果可以看出，Transformer 模型在数据集 III-A 只有 70.40%的正确率，在数据集 III-B 只有 72.20%的正确率，ERP 识别率不如深度学习模型，甚至并不如传统的 LDA 分类的方式。由于 P300 信号比较稀疏而且信噪比低，各类脑电活动的区分度较小，而且 Transformer 模型的复杂性较高，它需要更多的训练数据以及较长的训练时间，并不完全适用 P300 信号。因此即使 Transformer 在其他任务中，特别是运动想象任务中表现良好[39]，但是它在 P300 任务中的优势并不显著。在未来的研究中，可以进一步探索如何优化 Transformer 架构，或结合其他神经网络结构，以更好地适应 P300 脑机接口任务的需求。

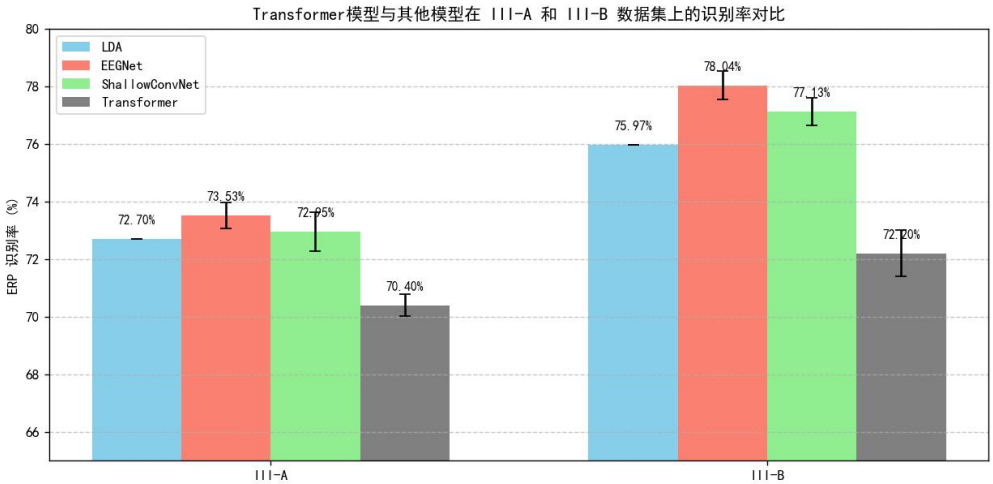

图 3-4 Transformer 模型与其他模型在两个数据集上的对比

表 3.6 Transformer 模型在 III-A 与 III-B 数据集上的 ERP 识别率

数据集	ERP 识别率（%）
III-A	70.40
III-B	72.20

3.6 本章小结

本章引入了深度学习技术，对传统分类器 LDA 进行改进，重点介绍了 EEGNet 与 ShallowConvNet 两种深度学习模型，同时将 SE 注意力机制和 CBAM 注意力机制和深度学习模型结合在一起，增强模型的特征提取能力。实验结果表明，采用深度学习模型在 P300 分类任务中取得了较好的改进，融入注意力机制后的模型性能更加。此外，本章对 Transformer 架构在 P300 信号分类中的应用进行了深入研究，即便实验结果不尽人意，但不同于 SE 注意力机制和 CBAM 注意力机制，Transformer 架构的自注意模块为以后 P300 分类研究中提供了宝贵的经验，为未来的 Transformer 架构应用于低信噪比的脑电信号研究打下了基础。

4 模型可视化分析与结构消融

4.1 t-SNE 特征可视化分析

t-SNE（t-DistributedStochasticNeighborEmbedding）是将数据点之间的欧式距离转换为数据，主要思想是条件概率的方式表示高维数据点中的相似性。t-SNE 目前在很多领域已被成功应用于特征空间的可视化分析 [36]。在本研究中将深度学习模块中的不同卷积层进行 t-SNE 可视化分析，将高维的数据进行降维可视化，最后可以在二维图中看到目标刺激和非目标刺激的两类样本在不同卷积层的区分度。通过 t-SNE 的结果可以清晰的看到各个卷积模块在特征提取发挥出的贡献。

4.1.1 EEGNet 特征分布可视化

本节选取了不加注意力机制的 EEGNet 模型，在 III-A 和 III-B 两个数据集上分别进行 t-SNE 降维可视化分析。t-SNE 能够将高维特征映射至二维平面，帮助观察目标刺激（Target）与非目标刺激（Non-Target）样本在特征空间中的聚类与区分情况。

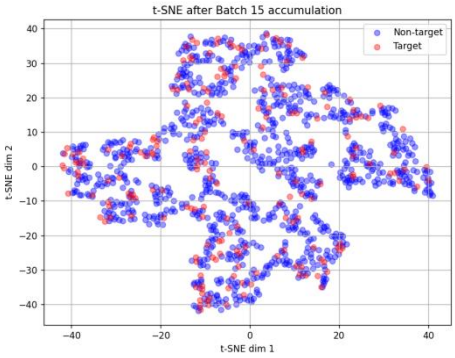

a) 原始输入

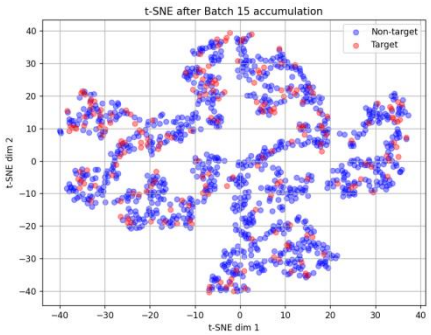

b) 第一层卷积

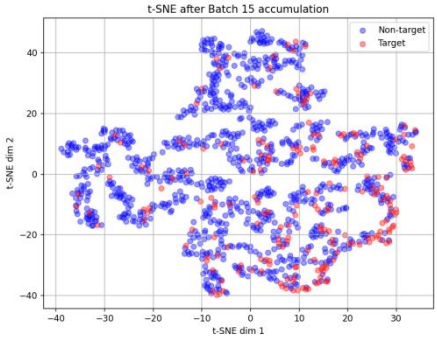

c) 第二层卷积

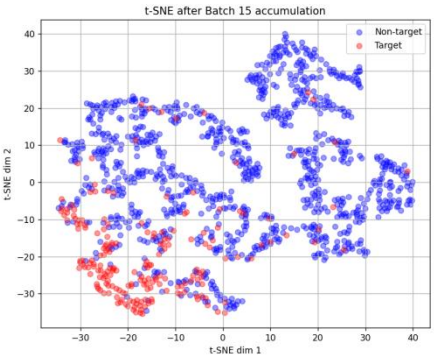

d) 第三层卷积

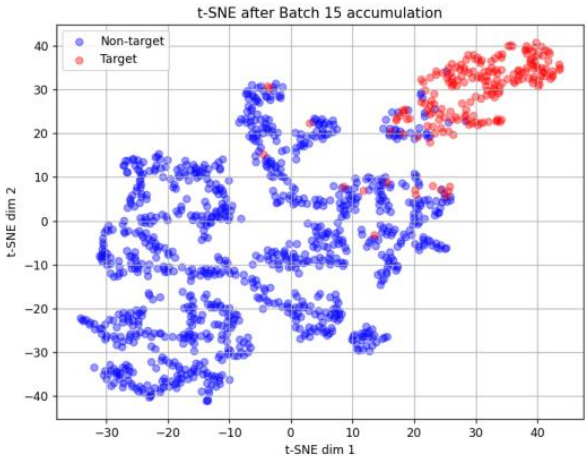

e) 全连接层

图 4-1 EEGNet 模型在 III-A 数据集上不同卷积层的 t-SNE 特征分布可视化

如图 4-1 中 a 所示，首先将原始数据进行 t-SNE 可视化，可以看到数据在未经过卷积操作的特征空间中，目标和非目标分布非常杂乱，表明原始数据并没有区分两类样本。

如图 4-1 中 b 所示，随着网络的深入，特征空间逐渐变得更加结构化。在第一个卷积层后，t-SNE 结果表现出一定的聚集性，目标和非目标字符开始有一定的分离，但仍存在较大的重叠。

如图 4-1 中 c 所示，进入第二层卷积后，特征空间的分布进一步改进，目标和非目标字符的分离更加明显。

如图 4-1 中 d 所示，经过第三层卷积后，t-SNE 结果显示目标字符与非目标字符的分布有了显著的区分，目标和非目标字符分开的非常明显，表明经过三层卷积后提取的特征具有较好的判别能力。

如图 4-1 中 e 所示，最终，在全连接层之后，t-SNE 可视化结果表现出目标和非目标字符的明显分离，说明网络在高层具有较强的判别特征提取能力。

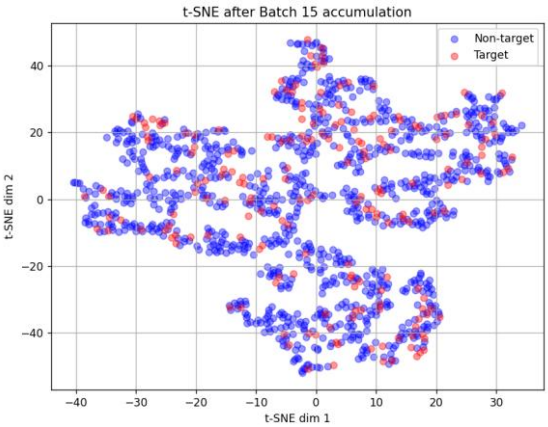

a) 原始输入

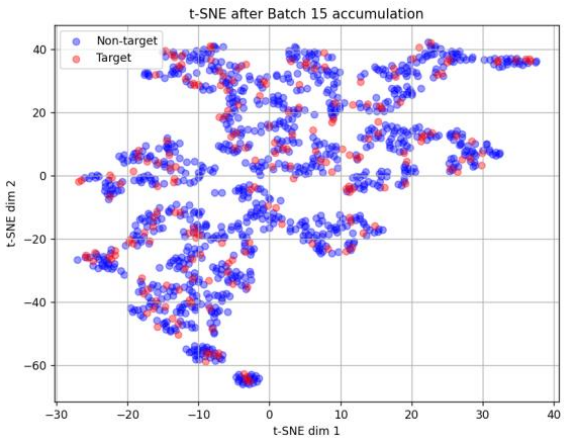

b) 第一层卷积

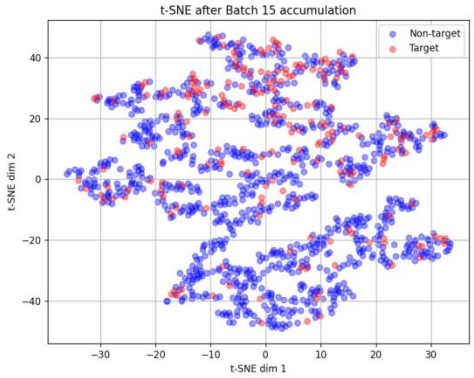

c) 第二层卷积

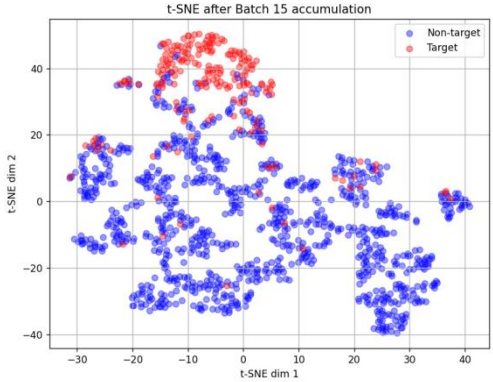

d) 第三层卷积

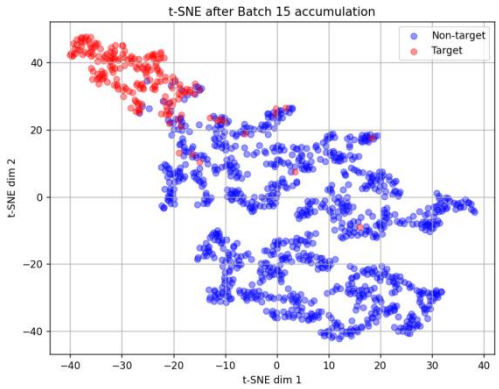

e) 全连接层

图 4-2 EEGNet 模型在 III-B 数据集上不同卷积层的 t-SNE 特征分布可视化

如图 4-2 所示，在 III-B 数据集上也进行了同样的 t-SNE 可视化流程。在图 4-2 中 a 所示，原始数据的目标和非目标两类样本分布非常杂乱，没有任何区分度。

如图 4-2 中 b 所示，经过第一层卷积后，同类样本相互聚集在一起，但是两类样本没有分离。

如图 4-2 中 c 所示，经过第二层卷积后，两类样本自身相互聚集的程度变得较明显，但是分离程度不够明显。

如图 4-2 中 d 所示，经过第三层卷积后，两类样本的分离程度较为明显，说明经过了三层卷积后，两类样本的区分程度效果较好。

如图 4-2 中 e 所示，经过全连接层后，非目标和目标样本出现了明显的分离，说明模型在 III-B 数据集取得了很好的分类效果。

4.1.2 ShallowConvNet 特征分布可视化

本节选取了不加注意力机制的 ShallowConvNet 模型，在 III-A 和 III-B 两个数据集上分别进行 t-SNE 降维可视化分析。不同于 EEGNet 的深层结构，ShallowConvNet 的结构相对更加简单，主要依靠浅层卷积结构对 EEG 信号中的关键时空特征进行捕捉。

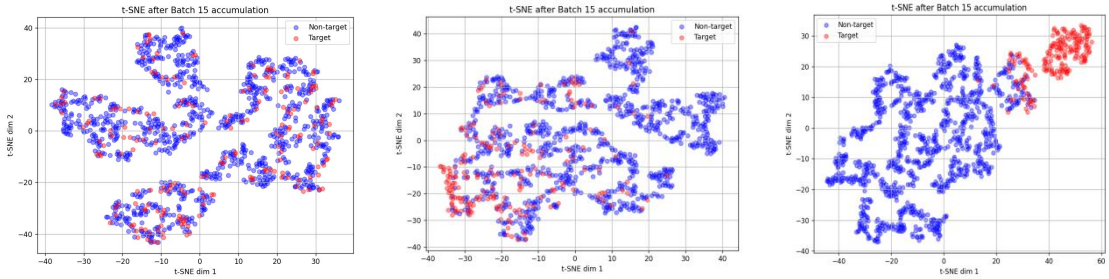

a) 第一层卷积　　b) 第二层卷积　　c) 全连接层

图 4-3 ShallowConvNet 模型在 III-A 数据集上不同卷积层的 t-SNE 特征可视化

如图 4-3 中 a 所示，在 III-A 数据集上，第一层时间卷积层的输出已经开始呈现出初步的类别聚类趋势，非目标和目标初步聚集在一起，但是目标与非目标样本仍存在重叠。

如图 4-3 中 b 所示，经过第二层空间卷积操作后，样本间的分离度明显增强，目标与非目标刺激在二维平面上形成相对独立的聚集区域，但二者还是有较多混淆。

如图 4-3 中 c 所示，最终全连接层的输出展现出更加清晰的类间边界，反映出 ShallowConvNet 尽管层次较浅，仍能取得较为不错的分类效果。

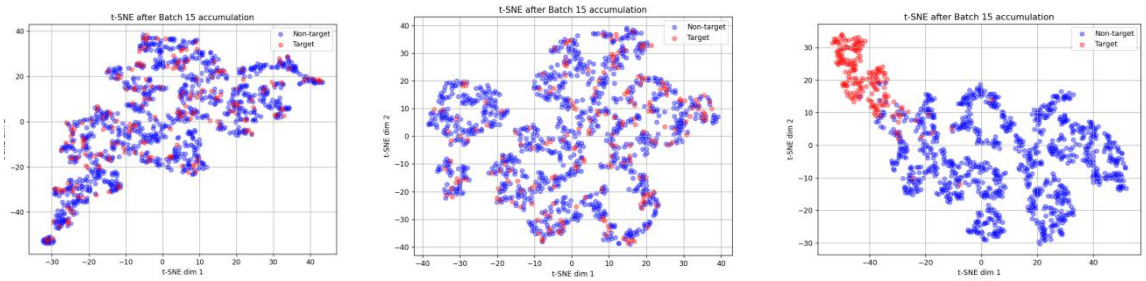

a) 第一层卷积　　b) 第二层卷积　　c) 全连接层

图 4-4 ShallowConvNet 模型在 III-B 数据集上不同卷积层的 t-SNE 特征可视化

如图 4-4 中 a 所示，在 III-B 数据集上，第一层的 t-SNE 可视化结果呈现出与 III-A 类似的特征分离趋势。相同类型的样本聚集在一起，但是不同类样本还是混在一起，没有呈现很好的分离效果。

如图 4-4 中 b 所示，III-B 第二层的结构后 t-SNE 可视化结果并不如 III-A 效果好。两类样本即使聚在一起，但是两类样本的区分程度很差。

如图 4-4 中 c 所示，在全连接层后，两类样本的区分度变得十分明显，同类样本相互聚集，两类样本相互区分，这证明了 ShallowConvNet 模型在 P300 任务中取得了比较不错的效果。

4.1.3 Transformer 特征分布可视化

本节选取了不加注意力机制的 Transformer 模型，在 III-A 和 III-B 两个数据集上分别进行 t-SNE 降维可视化分析。不同于 EEGNet 和 ShallowConvNet 以卷积结构为主的模型，Transformer 架构依赖多头自注意力机制对时间序列建模，更容易捕捉长距离依赖关系。通过对其各编码层输出的可视化，能够从全局建模的角度区分两类样本。

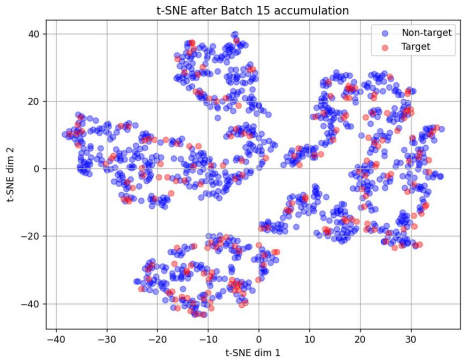

a) PatchEmbedding

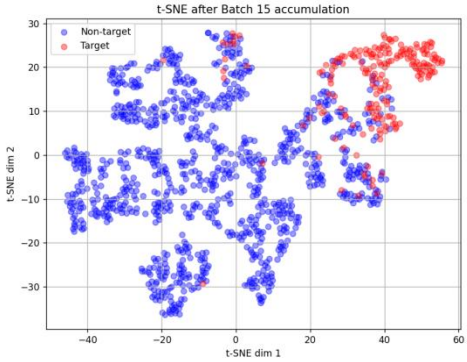

b) Attention

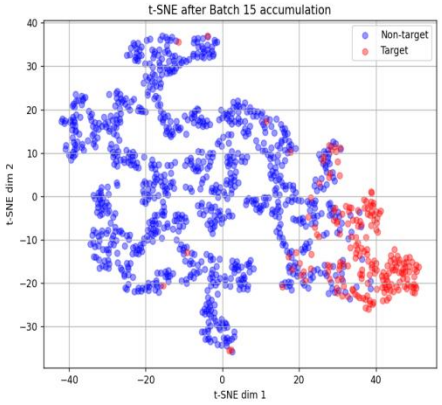

c) FFN

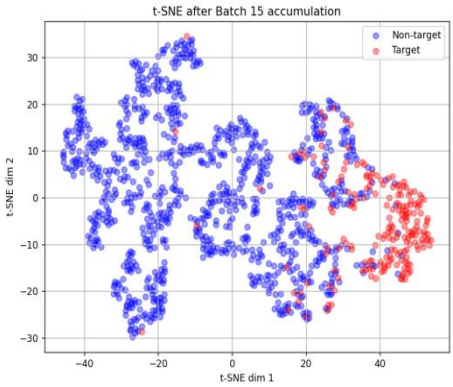

d) EncoderBlock

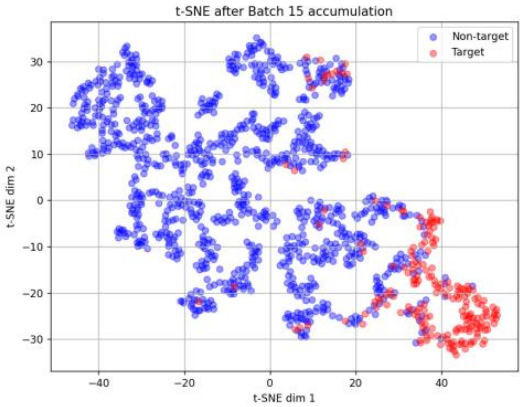

e) Classifier

图 4-5 Transformer 在 III-A 数据集上各模块 t-SNE 可视化

如图 4-5 中 a 所示，在 III-A 数据集上，经过 PatchEmbedding 层后，同类样本在二维的特征空间中初步表现成聚集在一起，说明该层对特征进行了初步的特征提取，但是重叠较大，两类样本没有较好的分离。

如图 4-5 中 b 所示，在多头注意力层后，目标和非目标的区分程度较为明显，两类样本呈现出较为清晰的边界，说明了注意力层很好的提取了数据的特征，对不同类别的

判定起了十分重要的作用，虽然两类样本仍有一部分重叠，但是相比于 Patch Embedding 层，两类样本的分离能力显著提高，这也证明了多头注意力层是 Transformer 架构中的核心结构。

如图 4-5 中 c 所示，在前馈神经网络层后，两类样本的分离度进一步提高，特征分布更加紧凑且边界更加清晰。该层通过多层的非线性变换增强了判别特征的表达能力，使目标和非目标的差异更加明显，进一步提升了模型的判别能力，对样本的类别结构起到了显著优化作用。

如图 4-5 中 d 和 e 所示，在编码器层和分类头层，特征空间的可分性提升趋于平稳，相较于第三层并未带来明显的改善，部分情况下甚至出现了两类样本边界的轻微混合，两类样本的区分度甚至不如之前清晰。可以表明在该模型架构下，此模型在前三层已基本完成特征提取的有效信息，后面两层更偏向于对已有特征的细节调整与保持，而对类间区分的贡献较小。这一现象也可以说明，在某些情况下，模型过于深入、过多的层数堆叠不仅不会增强提取能力，甚至会导致混淆，导致区分能力退化。特别是对于 P300 信号这种比较低的信噪比的数据集，过于复杂的模型和过多的层数堆叠对识别反而起到负面效果。

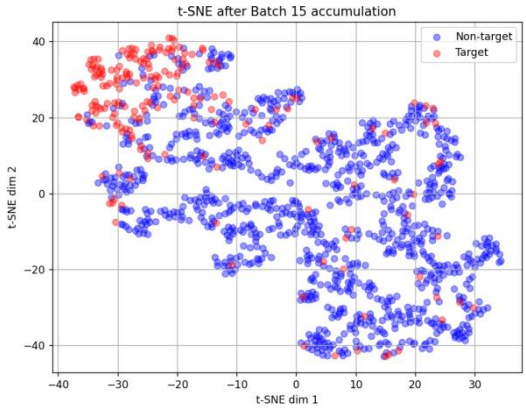

a) PatchEmbedding

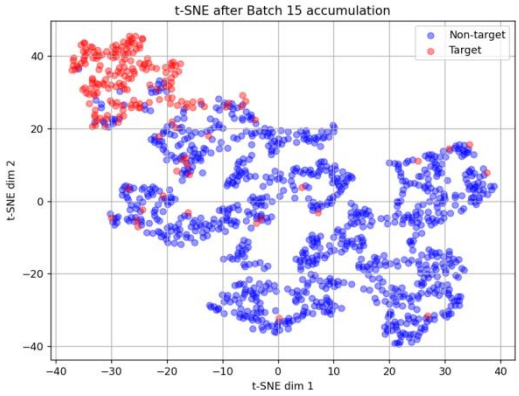

b) Attention

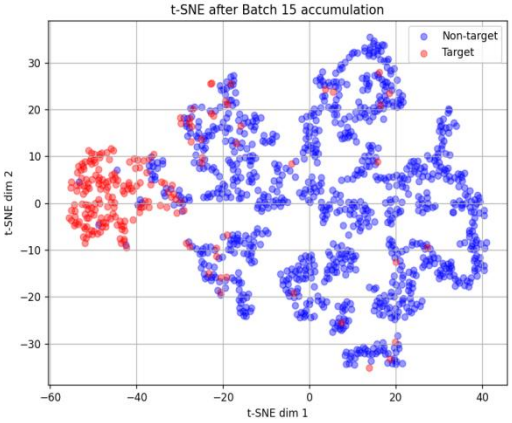

c) FFN

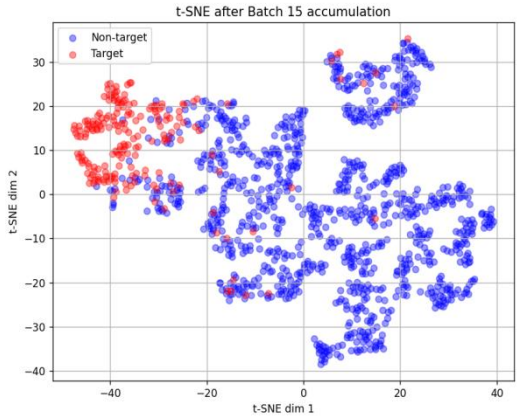

d) EncoderBlock

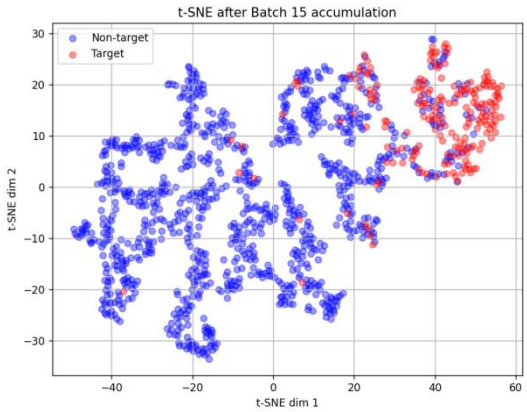

e) Classifier

图 4-6 Transformer 在 III-B 数据集上各模块 t-SNE 可视化

如图 4-6 中 a 所示，在 III-B 数据集上，经过 PatchEmbedding 层后，相较于 III-A 数据集在相同层级的表现，III-B 数据集两类样本已经取得了较好的区分，说明 III-B 数据集在早期阶段就展现出了更高的可分性与清晰度。

如图 4-6 中 b 所示，在自注意层后，III-B 数据集目标和非目标的分离度已经区分的比较明显，综合两类数据集来看，Transformer 架构的自注意层在 P300 分类任务中取得了较为关键的作用。

如图 4-6 中 c 所示，在前馈神经网络层后，III-B 数据集两类样本区分的更加明显，重叠部分相对于自注意层也有了明显的减少。

如图 4-6 中 d 和 e 所示，在编码器层和分类头层后，两类样本的区分和上一层相比相差不大，说明在有前三层结构时，后面两层只对信息进行了整合，并没有对分类效果有更好的改善。

总体来看，无论是在 III-A 还是 III-B 数据集上，Transformer 架构在 t-SNE 可视化中的类别区分度不如 EEGNet 和 ShallowConvNet，证明此架构在 P300 信号判别任务中的效果相对有限。

4.2 模型结构消融实验

为了深入理解在深度学习模型中各个卷积模块对 P300 信号识别的贡献，本研究进行消融实验，通过逐步移除模型的不同结构模块，观察其对分类准确率的影响，进而得到每个模块对 P300 实验的贡献。具体来说，实验分别对可分离卷积层（仅针对于 EEGNet 模型）、全连接层、全连接层和时间卷积层、全连接层和空间卷积层、全连接层和可分离卷积层（仅针对于 EEGNet 模型）这几个模块进行消融实验。此外，对 Transformer 的多头注意力层和前馈神经网络层也进行了消融实验。对由于需要避免单次实验导致的误差，最终的准确率以平均值呈现，并附加标准差表示模型的稳定性。

4.2.1 EEGNet 结构消融与性能分析

如图 4-7 和表 4.1 所示，在完整结构下，EEGNet 模型在 III-A 和 III-B 数据集上的分

类准确率分别为 73.53%和 78.04%，表明该模型具备良好的 ERP 信号识别能力，能够有效捕捉 P300 脑电信号的关键特征。

当去除可分离卷积层后，III-A 数据集准确率下降至 72.95%，III-B 数据集下降至 77.13%，说明该结构对模型整体性能的影响较小。在 III-A 数据集上，去除可分离卷积后，EEGNet 的结构与 ShallowConvNet 的准确性相差无几。

当继续去掉全连接层后，III-A 与 III-B 数据集的准确率分别下降至 63.57%和 63.38%，两组模型在两个数据集的正确率都有很大的下降幅度。说明全连接层对模型的 ERP 识别率影响巨大。

在去掉全连接层的基础上，再去除时间卷积层，III-A 准确率降至 56.30%，而 III-B 准确率降至 56.97%，说明时间卷积对于时间特征的提取不可或缺。

在去掉全连接层的基础上，再去除空间卷积层，III-A 和 III-B 准确率分别为 58.25%与 58.82%，两者均出现明显性能退化，说明没有通道卷积无法对 EEG 通道进行有效整合。

最后，当同时去除全连接层与可分离卷积层时，III-A 和 III-B 的准确率分别为 65.75%和 64.18%，和仅去除全连接层时相差不大，说明在缺少全连接层的支持下可分离卷积层其作用被显著削弱。

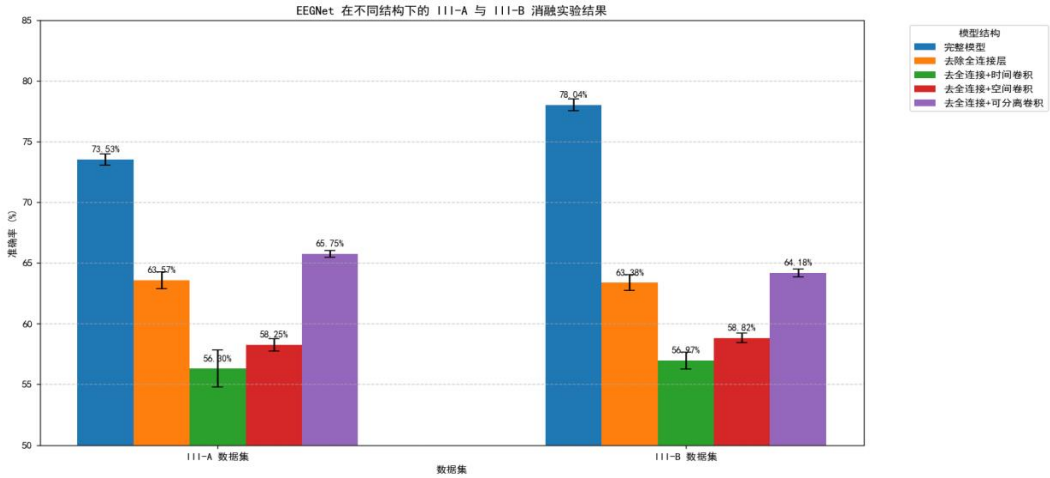

图 4-7 EEGNet 模型在两个数据集上的消融实验结果

表 4.1 EEGNet 模型结构消融实验结果

消融设置	III-A 准确率（%）	III-B 准确率（%）
完整模型	73.53	78.04
去除可分离卷积层	72.95	77.13
去除全连接层	63.57	63.38
去除时间卷积层+全连接层	56.30	56.97
去除空间卷积层+全连接层	58.25	58.82
去除可分离+全连接层	65.75	64.18

4.2.2 ShallowConvNet 结构消融与性能分析

如图 4-8 和表 4.2 所示，ShallowConvNet 在完整结构下，在 III-A 和 III-B 数据集上分别达到了 72.95%与 77.13%的准确率，显示出其在结构简洁的前提下也具有良好的 ERP 识别能力，尤其在 III-B 数据集上表现更为出色。

当去除全连接层后，III-A 数据集准确率降至 64.36%，III-B 数据集降至 63.66%，表现出与 EEGNet 类似的趋势，即全连接层对两类数据中关键特征的整合起到了重要作用。

进一步去除时间卷积层后，III-A 的准确率为 63.94%，而 III-B 数据集的准确率为 62.49%，相比 EEGNet 的下降幅度较小，说明 ShallowConvNet 本身在时序建模方面的能力较弱，更多依赖空间维度的特征提取。

当去除空间卷积层时，模型性能出现明显退化，III-A 与 III-B 准确率分别降至 58.67%和 58.96%，这说明 ShallowConvNet 对空间结构的依赖性较强，空间卷积在模型特征提取中扮演了核心角色。

对比不同结构消融的表现可以看出，ShallowConvNet 更依赖空间卷积结构，而对时间卷积的敏感度较低，符合其原始模型以空间特征为主的理念。此外，在 III-B 数据集中的整体表现普遍优于 III-A，可能与数据本身的噪声水平、刺激设计或被试状态等实验条件差异有关。

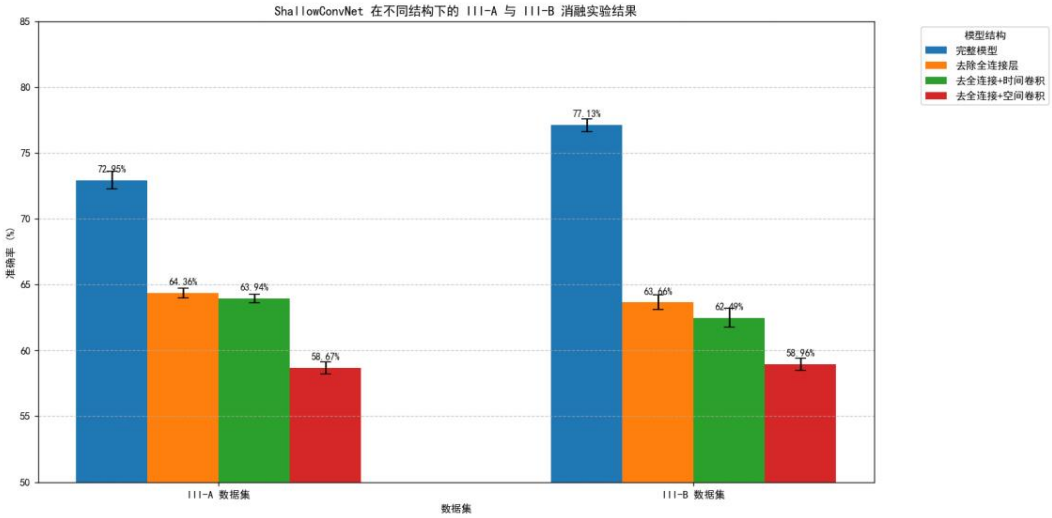

图 4-8 ShallowConvNet 模型在两个数据集上的消融实验结果

表 4.2 ShallowConvNet 模型结构消融实验结果

消融设置	III-A 准确率（%）	III-B 准确率（%）
完整模型	72.95	77.13
去除全连接层	64.36	63.66
去除时间卷积层+全连接层	63.94	62.49
去除空间卷积层+全连接层	58.67	58.96

4.2.3 Transformer 结构消融与性能分析

如图 4-9 和表 4.3 所示，当去除多头注意力模块后，III-A 数据集准确率降至 70.06%，III-B 数据集降至 70.96%。这一变化表明，虽然注意力机制确实对性能有促进作用，但其对模型整体性能的提升作用相对温和。说明 PatchEmbedding 和后续结构在一定程度上仍能保留输入信息的表达能力。

进一步去除前馈神经网络层（FFN）后，即 Transformer 仅保留了 PatchEmbedding 和编码器堆叠的框架，III-A 的准确率进一步略降至 70.05%，III-B 则达到 71.70%，下降幅度依旧不大，说明前馈模块对结构性建模的影响在 ERP 任务中并不如分类任务中显著。

当仅保留 PatchEmbedding 与分类头层（即去除 Transformer 的主要中间部分）时，III-A 准确率竟略微上升至 70.47%，III-B 更是上升至 73.04%，达到全部结构中的最高值。这一现象说明，在 ERP 信号任务中，深度堆叠的 Transformer 层并不一定带来更强的表达能力，甚至可能因过拟合或冗余建模而降低性能，反而是较浅的结构更容易泛化。

保留前三层结构（PatchEmbedding+Attention+FFN），即去除编码器堆叠与分类头以外的层，III-A 准确率为 70.34%，III-B 准确率为 71.62%，只使用前三层的结果整体表现与完整结构相近，这个结果在之前的可视化步骤也进行的说明。

通过以上实验结果可以看出，在 Transformer 模型中，PatchEmbedding 层、多头注意力层和前馈神经网络层已经取得了很好的效果，在同时拥有前三层时，编码器层和分类头层的作用微乎其微，甚至在有些情况还会反而导致性能下降。无论如何进行各个模块的整合，Transformer 架构的 ERP 识别率都不如其他模型，说明 Transformer 架构对本 P300 二分类识别任务效果不够明显。

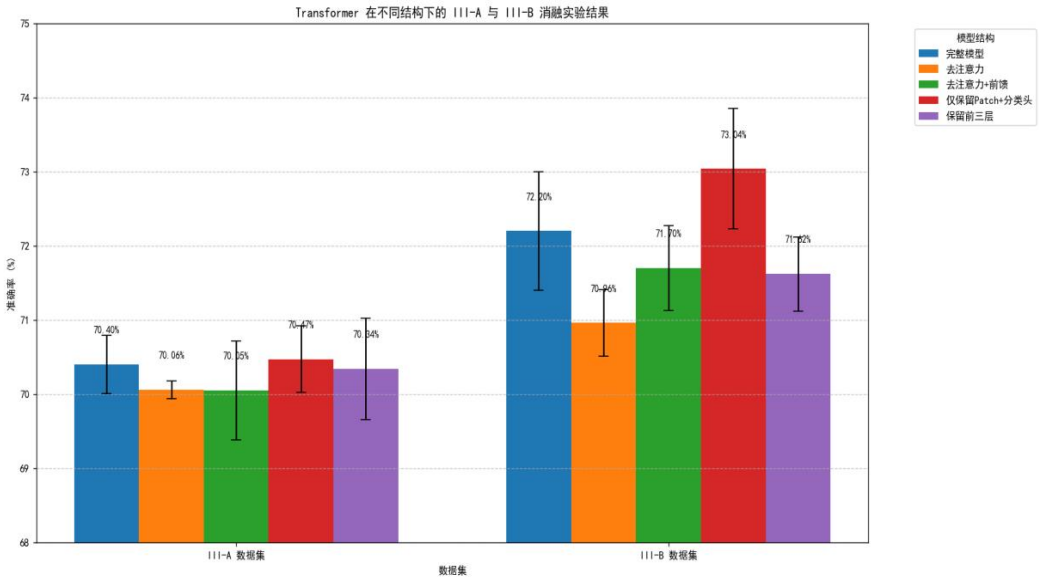

图 4-9 Transformer 模型在两个数据集上的消融实验结果

表 4.3 Transformer 模型结构消融实验结果

消融设置	III-A 准确率（%）	III-B 准确率（%）
全部结构（原始）	70.40	72.20
去除注意力机制	70.06	70.96
去除前馈神经网络层（FFN）	70.05	71.70
仅保留 PatchEmbedding+分类头	70.47	73.04
仅保留前三层	70.34	71.62

4.3 本章小结

本章主要了 t-SNE 降维可视化和消融实验，将上一章的各个深度学习模型的不同卷积模块进行逐个分析，在 t-SNE 降维可视化中，能够清晰的观察到，随着卷积网络不断深入，在二维平面中同类样本聚集得越紧密，不同类样本区分得越明显。这直观的展示了在深度学习模型中经过逐步卷积操作后两类目标分离的过程。在消融实验中，逐步对不同卷积模块进行消融，观察不同的消融操作对 ERP 准确率的影响，实验结果表明，不同模型对不同的卷积模块依赖不同，但是都必须兼顾全连接层对特征的整合。本章的 t-SNE 降维可视化与消融实验和上一章节的模型相对应，对模型的不同结构的贡献进行了详细评估。

5 总结与展望

5.1 总结

本文聚焦于解决脑机接口中的 P300 分类问题展开研究，提出了一种结合深度学习技术和注意力机制的改进方法，提高 P300 信号的分类精度。传统的 P300 分类方法如 LDA 在面对个体差异性和复杂时空特征时，往往局限性较大。由此本文采用了 EEGNet 和 ShallowConvNet 等深度学习模型，利用其自动提取脑电信号时空特征的能力，较为显著的改进了 P300 信号的识别。本文实现的具体成果主要体现在以下几个方面：

（1）本文对已经被带通滤波器滤波过的数据进行叠加平均处理，将传统 LDA 分类方法在 P300 识别任务中进行实验，对 LDA 传统分类性能进行验证，同时指出了其存在的局限性。同时以 LDA 分类器的结果做对照实验，为后文深度学习模型改进提供了参照。

（2）采用了 EEGNet 和 ShallowConvNet 两种深度学习模型对 LDA 进行改进，实验结果表明，两种深度学习模型对 LDA 有着很好的改进效果，其中 EEGNet 模型较为复杂，特征提取能力更强；ShallowConvNet 模型结构较浅，更轻量级，展现了更快的训练速度。在现有的深度学习模型的基础上，引入了 SE（Squeeze-and-Excitation）和 CBAM（Convolutional Block Attention Module）两种注意力机制。通过对不同的特征通道赋予不同的权重，使模型可以更加关注更为重要的通道，忽略信号不强的通道，从而提高模型分类性能。通过深度学习技术结合注意力机制在本研究中取得了显著的效果。

（3）本文对 Transformer 架构进行评估，Transformer 的自注意机制在许多领域都展现了十分显著的性能。虽然 Transformer 模型在脑电识别的许多方面展现了比较大的成功，尤其在运动想象任务中取得了很好的效果。但在本研究中，Transformer 模型的优势发挥的不够明显，ERP 识别率不如其他深度学习模型，甚至不如传统 LDA 分类器，通过实验数据和后面的可视化与消融实验分析，任务 Transformer 模型较复杂，更重量级，在信噪比较低的 P300 信号中特征提取能力发挥不明显。

（4）利用 t-SNE 可视化和消融实验去验证不同模型中不同模块的贡献，将深度学习模型的不同模块进行降维可视化和消融，t-SNE 可视化展示了不同卷积层在特征空间上对目标与非目标刺激样本不断区分的过程，消融实验展示了各个模块对特征提取能力的影响。这些分析为后续搭建其他网络结构进行特征提取提供了依据。

5.2 展望

本文通过引入深度学习模型改进 LDA 分类器，在 P300 信号分类任务中的识别取得了很好的效果，但在研究过程仍有些不足之处，需要在未来的研究工作中进一步改进和完善。

首先，论文采用的 BCI Competition III 数据集，此数据集信噪比较低，特征不够明显，因此在以往的研究中，ERP 识别率普遍较低。在本研究中，深度学习模型的发挥不

够明显，在以后的研究中可以采用其他数据集进行实验。

其次，在深度学习模型方面，本文主要引入了 SE 和 CBAM 两种注意力模块，虽然取得了较好的效果，但是注意力机制过于单一，由于脑电信号较为复杂，未来的研究中可以考虑更先进的注意力机制增强特征提取能力，提升 ERP 识别率。

另外，Transformer 模型结构没有取得较好的分类效果，未来的研究可以对传统 Transformer 模型进行改进，通过更轻量级的 Transformer 模型使其适用信噪比较低 P300 分类任务。

参考文献

[1] Wolpaw J, Wolpaw E W (eds.). Brain-Computer Interfaces: Principles and Practice. Oxford University Press, 2012.

[2] Maiseli B, Abdalla A T, Massawe L V, et al. Brain - computer interface: trend, challenges, and threats[J]. Brain informatics, 2023, 10(1): 20.

[3] Islam M T, Sepanloo K, Woo S, et al. A Review of the Industry 4.0 to 5.0 Transition: Exploring the Intersection, Challenges, and Opportunities of Technology and Human–Machine Collaboration[J]. Machines, 2025, 13(4): 267.

[4] Peksa J, Mamchur D. State-of-the-art on brain-computer interface technology[J]. Sensors, 2023, 23(13): 6001.

[5] Jayaraj L, Wood J, Reifer A, et al. Experience in a VR Cricket Game Using Brain Computer Interaction (BCI)[C]//2025 IEEE International Conference on Artificial Intelligence and eXtended and Virtual Reality (AIxVR). IEEE, 2025: 248-251.

[6] Zhang H. Neurotechnology and Ethics: Reflections on Brain-Computer Interface Technology[J]. Science Progress and Humanity, 2025, 1(1): 14-19.

[7] Subasi A, Mian Qaisar S, Kumar Bhoi A, et al. Artificial Intelligence Applications for Brain–Computer Interfaces[J]. 2025.

[8] 成苈委, 张倩, 梁栗炎, 等. 面向脑机接口的高速通信需求及相关应用场景[J]. 信息通信技术与政策, 2024, 50(5): 12.

[9] Al-Mohammadi M, Al-Nuaimi A, Farah L B. Smart home based on BCI for disabled people: A state-of-the-art review[C]//AIP Conference Proceedings. AIP Publishing, 2024, 3232(1).

[10] Arachchige M D J, Nafea M. Brainwave and head motion control of a smart home for disabled people[M]//Signal Processing Strategies. Academic Press, 2025: 195-215.

[11] Gielas A M. Soldier Enhancement through Brain–Computer Interfaces: The Risks of Changing the Human Condition[J]. The RUSI Journal, 2025, 170(1): 32-47.

[12] Won E, Lim S, Kim Y, et al. Real-Time BCI System for Target Detection[C]//2024 12th International Winter Conference on Brain-Computer Interface (BCI). IEEE, 2024: 1-4.

[13] Bi Z, Mikkola A, Ip A W H, et al. Brain–Computer Interface for Shared Controls of Unmanned Aerial Vehicles[J]. IEEE Transactions on Aerospace and Electronic Systems, 2024, 60(4): 3860-3871.

[14] Prewitt R. EEG/AR-Controlled Surveillance Drones: Advantages and Challenges in Military Combat Applications[D]. Virginia State University, 2024.

[15] Glavas K, Tzimourta K D, Angelidis P, et al. Brain-Computer Interface Controlled Drones: A Systematic Review[J]. IEEE Access, 2024.

[16] 琪陈, 天蔚袁, 丽雯张, 等. 脑机接口医学应用的研发现状与趋势[J]. Sheng Wu Yi

Xue Gong Cheng Xue Za Zhi= Journal of Biomedical Engineering, 2023, 40(3): 566.
[17] 宫铭鸿.事件相关电位与视觉诱发电位融合的异步脑机接口[D].河北工业大学,2020.
[18] Mak J N, et al. Optimizing the P300-based brain-computer interface: current status, limitations and future directions. J Neural Eng. 2011;8(2):025003.
[19] Santopetro N J, Luby J L, Barch D M, et al. Association Between Early Childhood P300 Deficits and Risk for Preadolescence Depressive Disorder Mediated by Responsiveness to PCIT-ED Treatment[J]. Research on Child and Adolescent Psychopathology, 2025: 1-14.
[20] Ríos-Rincón A M, Flores Parra L M, Torres de la Cruz A M, et al. Functional electrical stimulation therapy controlled by a P300-based brain‐computer interface, as a therapeutic alternative for upper limb motor function recovery in chronic post-stroke patients: A non-randomized pilot study[J]. Frontiers in Neurology, 2023, 14: 1221160.
[21] Vega C F, Quevedo J, Escandón E, et al. Fuzzy temporal convolutional neural networks in P300-based Brain–computer interface for smart home interaction[J]. Applied Soft Computing, 2022, 117: 108359.
[22] Bernal E L, Bernal S L, Pérez G M, et al. Evaluation of data processing and machine learning techniques in P300-based authentication using brain-computer interfaces[J]. arXiv preprint arXiv:2311.05270, 2023.
[23] Pearson D V, Shen Y, Hetrick W P, et al. P300 as an index of speech-in-noise understanding in complex acoustic environments in young and older adults[J]. Frontiers in Neuroscience, 2025, 19: 1497781.
[24] Farwell LA, Donchin E.Talking off the top of your head.Electroencephalogr Clin Neurophysiol,1988;70(6):510-523.
[25] Blankertz B, et al.BCI Competition III: Dataset II. 2004.
[26] Krusienski DJ, et al. A comparison of classification techniques for the P300 Speller. J Neural Eng. 2006;3(4):299-305.
[27] Rakotomamonjy A, Guigue V. BCI competition III: dataset II-ensemble of SVMs for BCI P300 speller. IEEE Trans Biomed Eng. 2008;55(3):1147-1154.
[28] Lawhern VJ, et al. EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces. J Neural Eng. 2018;15(5):056013.
[29] Cecotti H, Graser A. Convolutional neural networks for P300 detection with application to brain-computer interfaces[J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 33(3): 433-445.
[30] Flamary R, Jrad N, Phlypo R, et al. Mixed‐Norm Regularization for Brain Decoding[J]. Computational and mathematical methods in medicine, 2014, 2014(1): 317056.
[31] Roy Y, Banville H, Albuquerque I, et al. Deep learning-based electroencephalography analysis: a systematic review[J]. Journal of neural engineering, 2019, 16(5): 051001.
[32] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention is all you need. Advances

in Neural Information Processing Systems, 30, 5998-6008.
[33] Song Y, Jia X, Yang L, et al. Transformer-based spatial-temporal feature learning for EEG decoding[J]. arXiv preprint arXiv:2106.11170, 2021.
[34] Delorme, A., & Makeig, S. (2004). EEGLAB: an open source toolbox for analysis of single-trial EEG dynamics including independent component analysis. Journal of Neuroscience Methods, 134(1), 9-21.
[35] Gao P, Huang Y, He F, et al. Improve P300-speller performance by online tuning stimulus onset asynchrony (SOA)[J]. Journal of Neural Engineering, 2021, 18(5): 056067.
[36] Ge X, Pan Y, Wang S, et al. Improving intention detection in single-trial classification through fusion of EEG and eye-tracker data[J]. IEEE Transactions on Human-Machine Systems, 2022, 53(1): 132-141.
[37] Schirrmeister, R.T., Springenberg, J.T., Fiederer, L.D.J., et al. (2017). Deep learning with convolutional neural networks for EEG decoding and visualization. Human Brain Mapping, 38(11), 5391-5420.
[38] Kumar S, Sharma A, Mamun K, et al. A deep learning approach for motor imagery EEG signal classification[C]//2016 3rd Asia-Pacific World Congress on Computer Science and Engineering (APWC on CSE). IEEE, 2016: 34-39.
[39] Song Y, Zheng Q, Liu B, et al. EEG conformer: Convolutional transformer for EEG decoding and visualization[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2022, 31: 710-719.
[40] Wang D, Wei Q. SMANet: A Model Combining SincNet, Multi-branch Spatial-Temporal CNN and Attention Mechanism for Motor Imagery BCI[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2025.

致　谢

在论文即将完成之际，我满怀感激之情，向在我学术生涯中给予我悉心指导和无私帮助的老师、同学、家人和朋友们表达我最真挚的感谢。

首先，我要向我的导师张宇老师致以最诚挚的感谢。张老师是我大学时期的引路人，在我本科阶段就给予了我很多学术上的启发和指导。张老师热心，有耐心，对学生的关怀无微不至，在本科期间，张老师不仅是严谨治学的导师，更像是一位亦师亦友的长者，为我的学业发展提供了极大的帮助。我由衷地感谢张宇老师对我的培养和指导。

同时，致以最诚挚的感谢我的恩师綦宏志老师。我在第一次接触脑机接口这个方向时，感觉十分迷茫，我没有太好的编程基础，也没有很强的学习能力，是綦老师带着我一步一步地从综述文献开始，让我了解这个领域的发展，再通过研究类文献让我理解整个研究过程，最后再到指导我完成毕业设计。在这个过程中，綦老师总是毫无保留地分享自己的经验和见解，耐心地指导我代码实现的细节，从数据预处理、特征提取到模型训练和优化，每一个环节都细致入微。无论是模型算法的选择，代码的优化，还是调试过程中遇到的难题，綦老师总是能耐心解答并给予最中肯的建议，甚至不厌其烦地帮我分析每一步的输入输出维度，找出问题所在，并指导我一步步解决。如果没有綦老师的指导，我难以想象自己能取得如今的成果。将要成为綦老师的学生，我深感荣幸，綦老师科研态度认真，工作效率极高，凡事亲力亲为，能有这样的老师是我的幸运，他也将是我一生学习的榜样。

感谢实验室的师兄师姐们，在我遇到困难时给予我帮助，不仅耐心帮我检查代码，解决技术问题，还教会我如何使用各种实验软件，让我的研究工作得以顺利进行。

最后希望自己在未来的研究生生涯开心快乐。

学位论文原创性声明

本人郑重声明：所提交的毕业论文是本人在导师指导下独立进行研究工作所取得的成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明，其它未注明部分不包含他人已发表或撰写过的研究成果，不存在购买、由他人代写、剽窃和伪造数据等学术不端行为。

本人愿为此声明承担法律责任。

作者签名：　　日期：　　年　　月　　日

学位论文版权授权书

本学位论文作者同意授予东北农业大学对本论文全部内容的信息网络传播权、汇编权、发行权、转授权与复制权，具体包括但不限于将学位论文上传到有关数据库，影印、缩印或扫描等手段保存、查阅、借阅、汇编等。

（保密的学位论文在解密后适用本授权书）

作者签名：　　日期：　　年　　月　　日

任务书

学生姓名	代阳	学号	A07210177	班级	物联 2103
题目	基于深度学习的事件相关电位识别技术研究				

毕业论文（设计）要求

1.了解当前脑机接口市场的发展需求，按时完成基于深度学习的事件相关电位识别技术研究，并按规定时间完成毕业论文的撰写。

2.完成检测 P300 事件及字符识别任务，并通过深度学习算法进行改进，提供源代码。

3.按照要求提交毕业论文，字数不少于 10000 字，结构清晰、符合学校毕业论文要求。

毕业论文（设计）内容与技术参数

本研究主要探索深度学习技术在事件相关电位（ERP）识别中的应用，特别是针对 P300 成分的检测。通过深度学习技术的方式来改进传统浅层学习算法，高效地处理脑电图（EEG）信号,准确区分由特定刺激引发的 P300 波形和其他背景活动。并且提高 ERP 识别的准确性和效率，从而有效提高 P300 字符拼写系统的性能。

对比与优化模型：将深度学习模型与传统 LDA 模型对比，分析在信息传输效率等方面的差异，依据结果优化模型，提升系统整体性能。

毕业论文（设计）工作计划

第一阶段：项目准备与调研（1 月 21 日 - 2 月 4 日）：深入调研脑机接口技术尤其是 P300 ERP 识别文献，把握研究现状与瓶颈，完成开题报告与任务书撰写。

第二阶段：数据处理与传统模型构建（2 月 5 日 - 2 月 25 日）：对 EEG 信号去噪、滤波预处理，提取并选择特征；以 LDA 为基准分类器，训练模型并评估性能。

第三阶段：深度学习模型开发（2 月 26 日 - 3 月 18 日）：设计合适深度神经网络架构，如 CNN、RNN 及其变体；通过多种方法调优超参数，利用 GPU 加速训练，探索高级策略提升性能。

第四阶段：对比分析与优化（3 月 19 日 - 4 月 5 日）：对比深度学习与传统 LDA 模型，分析信息传输效率等差异，针对问题优化模型，尝试新预处理技术、特征工程方法或调整网络结构。

第五阶段：总结与收尾（4 月 6 日 - 4 月 20 日）：按学术标准撰写论文；准备答辩。

技术参数：

1.开发语言:python 语言

2.开发工具：pycharm

接受任务日期：2024 年 12 月 01 日　**要求完成日期：**2025 年 05 月 08 日

学　　生：代阳

指 导 教 师：张宇

东北农业大学毕业论文（设计）开题报告

学生姓名	代阳	学号	A07210177	班级	物联 2103
题目	基于深度学习的事件相关电位识别技术研究				

题目研究的目的和意义

脑-机接口技术形成于 20 世纪 70 年代，是一种涉及信息技术、认知科学、计算机科学、生物医学工程、神经科学等多学科的交叉技术。随着科技的不断进步，脑机接口（Brain-Computer Interface, BCI）技术作为一种新兴的人机交互方式，逐渐成为研究热点。BCI 系统通过直接读取大脑信号并将其转化为控制指令，为运动障碍患者提供了一种与外界交流的新途径。在众多 BCI 系统中，一种的基于事件相关电位的 P300 speller 在思维解码性能方面有非常大的优势，得到了广泛关注。然而，现有的 P300-BCI 系统在临床应用需求方面仍存在一些问题和挑战，如系统效率有待提高、个体差异影响系统性能、校准过程繁琐等，还有较大的提升空间。

题目研究方案和主要内容

本研究主要探索深度学习技术在事件相关电位(ERP)识别中的应用,特别是针对 P300 成分的检测。通过深度学习技术的方式来改进传统浅层学习算法，高效地处理脑电图（EEG）信号，准确区分由特定刺激引发的 P300 波形和其他背景活动。并且提高 ERP 识别的准确性和效率，从而有效提高 P300 字符拼写系统的性能。

探索深度学习在 ERP 识别中的应用：针对现有 P300 - BCI 系统在临床应用的问题，研究如何利用深度学习（如 CNN）技术改进传统浅层学习算法，处理 EEG 信号,准确识别 P300 波形。

构建并优化 P300 - BCI 系统模型：基于深度学习算法，构建能捕捉复杂时空特征的模型，提高 P300 事件检测及字符识别性能。

对比与优化模型：将深度学习模型与传统 LDA 模型对比，分析在信息传输效率等方面的差异，依据结果优化模型，提升系统整体性能。

研究方法及技术途径

1.数据处理和分析法：将数据集提取，进行预处理，通常包括去噪声、滤波步骤，再利用叠加平均提取有用的特征信息,建立传统分类模型 LDA,并对模型的性能进行评估。通过计算其准确率、灵敏度、特异性等指标，并通过混淆矩阵直观地展示分类结果。

2.模型构建法：根据研究目的和实验结果，构建优化的 P300-BCI 系统模型。模型构建过程中，利用深度学习算法

来增强模型对复杂时空特征的捕捉能力，从而提高了检测 P300 事件及字符识别任务中的表现。可以从大量的 EEG 数据中自动学习到高维特征表示，从而提升 P300 事件检测及字符识别任务的表现。

3.对比研究法：将优化后的模型与传统的分类模型进行对比，分析其在信息传输效率、识别准确率、校准时间等方面的优势和不足，为模型的进一步优化提供依据。

实施计划

第一阶段：项目准备与调研（1 月 21 日 - 2 月 4 日）：深入调研脑机接口技术尤其是 P300 ERP 识别文献，把握研究现状与瓶颈，完成开题报告与任务书撰写。

第二阶段：数据处理与传统模型构建（2 月 5 日 - 2 月 25 日）：对 EEG 信号去噪、滤波预处理，提取并选择特征；以 LDA 为基准分类器，训练模型并评估性能。

第三阶段：深度学习模型开发（2 月 26 日 - 3 月 18 日）：设计合适深度神经网络架构，如 CNN、RNN 及其变体；通过多种方法调优超参数，利用 GPU 加速训练，探索高级策略提升性能。

第四阶段：对比分析与优化（3 月 19 日 -4 月 5 日）：对比深度学习与传统 LDA 模型，分析信息传输效率等差异，针对问题优化模型，尝试新预处理技术、特征工程方法或调整网络结构。

第五阶段：总结与收尾（4 月 6 日 - 4 月 20 日）：整理实验数据形成结论，按学术标准撰写论文；准备答辩，提交文档代码，收集反馈意见。

指导教师：张宇

审核时间：2025 年 01 月 24 日

东北农业大学毕业论文（设计）中期检查

学生姓名	代阳	学号	A07210177	班级	物联 2103
题目	基于深度学习的事件相关电位识别技术研究				

论文概述

本文共分为六章，具体结构如下：

第一章为绪论，对 P300 脑机接口的研究背景与意义进行阐述，介绍 P300 拼写器的原理和目前对于本文的数据集研究现状，总结现有方式的局限性，并提出本文的创新点。

第二章为数据预处理与 LDA 分类：详细介绍了对 Wadsworth 数据集的处理流程，包括带通滤波处理，叠加平均及 R2 系数分析，再通过 LDA 分类器验证传统方式的分类器的性能。

第三章为通过深度学习的方式改进 LDA 分类。本文设计了 EEGNet 和 ShallowConvNet 模型，结合 SE 与 CBAM 注意力机制，对比分析两类模型在 P300 信号分类中的效果。此外还对 Transformer 架构在 P300 脑机接口中的应用进行讨论，对 Transformer 架构的进一步优化进行了展望。

第四章为消融实验与 t-SNE 可视化分析，通过逐层的消融实验与 t-SNE 降维可视化，验证网络中对特征提取的贡献。

第五章为总结，总结本研究的成果，分析了在 P300 分类任务中深度学习模型的优势，并对未来进行展望。

本阶段研究工作的内容和进展

1.对数据进行预处理，包括对脑电数据进行滤波、降采样、叠加平均增强信号等处理，为后续的分类提供更高质量的数据。

2.使用传统方法（LDA）实现二分类，采用线性判别分析（LDA）进行分类，并基于字符的行列闪烁投票来确定最终输出字符。通过实验结果表明，LDA 方法取得较好的 ERP 识别率，但是还可以通过深度学习的方式改进。

3.在传统方法的基础上，引入深度学习模型以提升分类效果。采用 EEGNet 和 ShallowConvNet 模型，SE（Squeeze-and-Excitation）和 CBAM（Convolutional Block Attention Module）注意力机制，以增强模型的特征提取能力。实验表明，EEGNet 的效果显著优于 ShallowConvNet，并且 SE 机制相比 CBAM 在本任务中更有效。此外也对 Transformer 架构进行了尝试，TransformerBlock 结合空间-时间注意力机制，即使在其他数据集中表现优异，但在本研究中效果不如 LDA，表明 P300 任务可能不适合该架构。

4.采用 t-SNE（t-Distributed Stochastic Neighbor Embedding）对不同模型的特征进行可视化，选取深度学习模型的不同层进行 t-SNE 降维分析，以观察卷积层的特征分布情况。通过 t-SNE 可视化分析，探索不同深度学习模型在不同层级的特征表达方式，进一步理解模型对 P300 信号的学习能力。

遇到的问题 1.数据集信号不够明显,噪声过多。本研究中所采用的数据集来源于 BCI Competition III（2004）提供的 Wadsworth BCI 数据集，信号干扰较大，分类效果不太好。 2.深度学习模型训练速度较慢。虽然 EEG 数据量较小，但是使用 CPU 训练效率低，影响实验进度。 3.Transformer 架构在 P300 任务上的表现不如 LDA，可能是由于其更适用于运动想象任务，而 P300 信号的时间特性较短，注意力机制的优势难以发挥。
下一步工作 1.采用 EEGNet 和 ShallowConvNet 模型的参数进一步优化，使其更好地适配 EEG 信号，进一步提升分类准确率。 2.进一步分析 Transformer 的局限性，分析 Transformer 在 P300 任务中的不足，尝试通过继续调整参数，看是否会出现更好的效果。 3.对研究结果进行可视化，采用可视化方法展示分类准确率随刺激轮次的变化趋势，以及不同模型在字符预测任务中的表现，让显示结果的方式更加直观。
指导教师：张宇 **审核时间：**2025 年 04 月 07 日

指导教师评语

学生姓名	代阳	学号	A07210177	班级	物联 2103
题目	基于深度学习的事件相关电位识别技术研究				

指导教师评语：

该论文针对脑机接口中 P300 信号分类的挑战，提出了一种融合深度学习与注意力机制的改进方法，通过引入 SE 和 CBAM 注意力机制增强 EEGNet 与 ShallowConvNet 模型的特征提取能力，并在 Wadsworth 数据集上实现了显著优于传统 LDA 分类器的识别效果。论文研究目标明确，方法创新性强，实验设计严谨，通过 t-SNE 可视化和消融实验深入验证了模型结构的有效性，尤其在通道注意力优化与时空特征提取方面具有技术亮点。研究成果对提升脑电信号解码效率及推动低成本脑机接口应用具有重要实用价值。论文结构完整，逻辑清晰，写作规范，查重率与 AIGC 检测结果均符合学校要求，同意参加答辩。

指导教师：张宇

评阅时间：2025 年 05 月 01 日

评阅人意见

学生姓名	代阳	学号	A07210177	班级	物联 2103
题目	基于深度学习的事件相关电位识别技术研究				

评阅人意见：

该论文构建了基于深度学习的 P300 识别方法，对比分析了不同深度学习模型的性能，并进行了实验分析。论文研究目的较为明确，结构较为清晰，工作量基本达标，但是部分章节结构需要进一步优化，论文规范性有待进一步提升，具体问题如下：

1.建议 1.4 节标题修改为“论文结构安排”

2. 第三章标题与内容不符，建议修改第三章标题

3.建议修改第四章标题

4.论文页码不足，不符合毕设要求。

5.最好将研究背景与意义中的参考文献放在国内外研究现状部分，意义介绍过多，国内外现状偏少。

6.建议将 1.3 和 1.4 节合并。

7.论文中很多多余的空格和空行。

8.第二章 LDA 分类结果最好用表格给出。

9.第二章和第三章没有给出模型评价指标。

10.第三章和第四章模型分类结果最好用表格给出。

11.第五章标题建议修改为“总结与展望”，5.1 总结，5.2 展望。

建议修改论文后参加答辩。

评阅人：尹艳玲

评阅时间：2025 年 05 月 19 日

答辩委员会意见

<table>
<tr><td>学生姓名</td><td>代阳</td><td>学号</td><td>A07210177</td><td>班级</td><td>物联 2103</td></tr>
<tr><td>题目</td><td colspan="5">基于深度学习的事件相关电位识别技术研究</td></tr>
<tr><td colspan="6">答辩委员会意见：
代阳同学能出色的完成毕业设计任务书规定的内容、要求；运用所学理论知识解决设计中问题能力非常好；具有独立工作能力，设计合理，计算结果无明显错误，图表、论文很好的达到要求；答辩时回答问题非常流畅。经答辩委员会讨论，一致同意该生通过论文答辩，并建议授予工学学士学位。

答辩委员会主席：谢秋菊</td></tr>
<tr><td>等级</td><td>优秀</td><td colspan="4">院长：李晓明

2025 年 06 月 01 日</td></tr>
</table>

电气与信息学院本科毕业论文（设计）评价指标

指标	评价要素		评价指标内涵
选题质量	1	目的明确，符合要求	符合培养目标，体现学科、专业特点和教学计划中对能力、知识结构的基本要求，达到毕业综合训练的目的。
	2	理论意义或实际价值	符合本学科的理论发展，解决学科建设、科学发展的理论或方法问题，有一定的科学意义，符合我国经济建设和社会发展的需要，解决应用性研究中的某个理论或方法问题，具有一定的实际价值。
	3	选题适当	题目贴切，有较强的科学性，难易度适中，题目规模适当。
能力水平	4	查阅文献资料能力	能独立查阅相关文献资料，归纳总结本领域有关科学成果。
	5	综合运用知识能力	能运用所学专业知识分析论述有关问题，能对占有资料进行分析整理并适当运用，概念清楚，能以恰当的论据对科学论点进行有说服力的论证。
	6	研究方案的设计能力	设计（论文）的整体思路清晰，结构完整，研究方案完整有序。
	7	研究方法和手段的运用能力	能较熟练的运用本学科的常规科学研究方法，能适当运用相关研究手段（如计算机、实验仪器设备等）进行资料搜集、加工、处理，并辅助论文写作。
	8	外文应用能力	能按照学校规定结合论文阅读、翻译一定量的本专业外文资料，有外文摘要和外文书目。
成果质量管理	9	文题相符	论文较完整地回答了题目所设定的有关问题。
	10	写作水平	论点鲜明，观点正确，论据充分，论证有力，条理分明，语言流畅。
	11	写作规范	符合科学论文的基本要求，论文（设计）中的用语格式、图表、数据、各种资料的运用及引用都要规范化。
	12	篇幅	工程设计类篇幅不少于 8000 字，研究论文篇幅不少于 10000 字。
	13	成果的理论或实际价值	在理论上具有新意，应用性研究对于实际工作具有一定意义。