東北農業大學

本科毕业论文

基于深度学习的垃圾识别与分类方法研究与应用

Research and Application of Garbage Recognition and Classification Methods Based on Deep Learning

所在学院：电气与信息学院

所在班级：物联 2102 班

学生姓名：许晨冉

学生学号：A07210244

指导教师：张宇 吴凯

研究方向：物联网应用技术

2025 年 06 月

東北農業大學

本科毕业论文

基于深度学习的垃圾识别与分类方法研究与应用

Research and Application of Garbage Recognition and Classification Methods Based on Deep Learning

所在学院：电气与信息学院

所在班级：物联 2102 班

学生姓名：许晨冉

学生学号：A07210244

指导教师：张宇 吴凯

研究方向：物联网应用技术

2025 年 06 月

摘 要

城市化进程的加快，使得垃圾数量飞速上涨。正确分类垃圾并提高垃圾的回收循环利用率不仅能够保护环境还可以节约资源。但是当前以深度学习技术为基础的垃圾分类算法存在网络参数量过大、不便于移植到移动设备中、实际场景下适应性较差等缺点。

为了应对上述挑战，本文以 YOLO11 模型为基准模型，引入坐标注意力机制，将优化后的 CA-YOLO11 目标检测模型应用于本研究。本文还自建了数据集，其中包括生活常见的四大类垃圾。本文除了使用自建数据集，还使用了来自于 kaggle 竞赛的一个公开数据集，将其修改为适配本文之后用于检验模型精度。本文以提高基准模型检测精度和鲁棒性等问题为出发点，将坐标注意力机制嵌入 Neck 和 Head 网络中，提升模型对复杂背景和小目标垃圾图片的检测能力；增强模型对于垃圾图像的特征和空间位置提取能力；并且也优化了检测多尺寸垃圾的能力。利用自建数据集对 CA-YOLO11 模型进行训练。实验表明 CA-YOLO11 模型的准确率相比于基准模型的 map@0.5 和 map@0.5:0.95 提高了 4.4%和 3.0%，map@0.5 达到了 0.621。在公共数据集上进行实验，结果表明 CA-YOLO11 模型的准确率相比于基准模型的 map@0.5 和 map@0.5:0.95 提高了 5.1%和 6.4%，map@0.5 达到了 0.523。证明 CA-YOLO11 模型在垃圾图像识别与分类上有更好的检测精度和泛化性。

本文还利用 CA-YOLO11 模型开发了一套完整的垃圾识别与分类系统。系统包括网页端和桌面端界面，可以更好的服务于实际生活中的垃圾识别与分类任务，为实现环保城市增添力量。

关键词：深度学习；目标检测；YOLO11；坐标注意力；垃圾识别与分类系统

Research and Application of Garbage Recognition and Classification Methods Based on Deep Learning

Abstract

The acceleration of urbanization has led to a rapid increase in the amount of garbage. Properly classifying garbage and improving its recycling rate can not only protect the environment but also save resources. However, the current garbage classification algorithms based on deep learning technology have disadvantages such as excessive network parameters, difficulty in porting to mobile devices, and poor adaptability in practical scenarios.

In order to address the above challenges, this paper takes the YOLO11 model as the benchmark model, introduces coordinate attention mechanism, and applies the optimized CA-YOLO11 object detection model to this study. This article also created its own dataset, which includes the four common types of garbage in daily life. In addition to using a self built dataset, this article also utilized a publicly available dataset from the Kaggle competition, which was modified to fit this article and used to test the accuracy of the model.Starting from improving the detection accuracy and robustness of the benchmark model, the coordinate attention mechanism is embedded into the Neck and Head networks to enhance the model's ability to detect complex backgrounds and small target garbage images; Enhance the model's ability to extract features and spatial positions from garbage images; And multiple parts of the benchmark model have also been optimized to reduce computational costs and detect multi-scale garbage. Train the CA-YOLO11 network using a self built dataset. The experiment shows that the accuracy of the CA-YOLO11 model is higher than that of the benchmark model map@0.5 and map@0.5:0.95 increased by 4.4% and 3.0%, map@0.5 Reached 0.621. Experiments were conducted on public datasets, and the results showed that the accuracy of the CA-YOLO11 model was higher than that of the benchmark model map@0.5 and map@0.5:0.95 increased by 5.1% and 6.4%, map@0.5 Reached 0.523. Prove that the CA-YOLO11 model has better detection accuracy and generalization in garbage image recognition and classification.

This article also developed a complete garbage recognition and classification system using the CA-YOLO11 model. The system includes web and desktop interfaces, which can better serve the tasks of garbage identification and classification in real life, adding strength to the realization of environmentally friendly cities.

Key words: Deep learning;Object detection;YOLO11;Coordinate Attention;Garbage recognition and classification system

目录

摘　要 I
Abstract II
目录 I
1 绪论 1
1.1 研究目的意义 1
1.2 国内外研究现状 2
1.2.1 国外研究现状 2
1.2.2 国内研究现状 3
1.3 论文主要内容 4
2 相关技术背景 6
2.1 深度学习 6
2.1.1 神经网络 6
2.1.2 卷积神经网络 7
2.2 目标检测技术 10
2.2.1 目标检测技术综述 10
2.2.2 YOLO11 模型 10
2.3 注意力机制 11
2.3.1 注意力机制原理 11
2.3.2 坐标注意力基本原理 12
2.4 本章小结 12
3 基于 CA-YOLO11 的垃圾识别与分类模型设计 13
3.1 垃圾图片数据集 13
3.1.1 数据分类 13
3.1.2 数据标注 14
3.2 模型架构 15
3.2.1 数据预处理 15
3.2.2 Backbone 网络 16
3.2.3 坐标注意力(Coordinate Attention) 17
3.2.4 Neck 网络 19
3.2.5 Head 网络 22
3.2.6 损失函数 24
3.3 模型训练 24
3.3.1 实验环境配置 24

3.3.2 超参数选择 24
3.4 本章小结 25
4 垃圾识别与分类模型评估与分析 26
4.1 实验评价指标 26
4.2 YOLO11 模型基准实验结果 27
4.2.1 自建数据集实验结果 27
4.2.2 公共数据集实验结果 28
4.3 CA-YOLO11 模型实验结果 28
4.3.1 自建数据集实验结果 28
4.3.2 公开数据集实验结果 29
4.4 CA-YOLO11 模型与 YOLO11 模型对比 30
4.5 本章小结 31
5 基于 CA-YOLO11 的垃圾识别与分类系统 32
5.1 系统架构 32
5.2 网页界面 32
5.2.1 电脑端网页界面 32
5.2.2 手机端网页界面 33
5.3 图形用户界面 34
5.4 本章小结 35
6 结论 36
参考文献 37
致谢 40
学位论文原创性声明 41
学位论文版权授权书 41

1 绪论

1.1 研究目的意义

随着我国国民经济的持续增长和城镇化战略的推进，近十年间，全国常住人口逐渐增长，人均可支配收入较 2010 年翻番。但是快速的城镇化进程和消费升级也带来严峻环境压力。城市垃圾的产生量以年均约 6.8%的速度递增，部分特大城市的日均垃圾处理量已经突破三万吨。自 2022 年起，我国城市垃圾的年清运总量稳定在两亿吨以上且逐步上升。这一趋势不但加剧城市环境污染问题，而且影响居民生活质量，给公共卫生安全和区域生态平衡带来了严峻挑战。为了应对这些难题，政府各级部门开始加大对环境卫生事业的投入，积极推动垃圾分类制度的实施和垃圾处理设施的现代化建设[1]。

但是目前绝大多数城市的环卫作业还是以传统的人工清扫和垃圾收集为主，如图 1-1 所示。随着城市规模的扩大和垃圾种类的增加，这种高度依赖人力的作业模式暴露出其不足之处，主要表现在：清扫效率较低；环卫工人的劳动强度过大；以及人力资源成本上升。尤其是在公园、居民区、校园和商业街等人流密集、环境复杂的公共区域，垃圾经常散落在草坪、灌木丛、沟渠等难以用机械清理的地方，导致全面实现自动化清扫和高精度垃圾分类都面临巨大的挑战[2]。因此，有效利用现代科技手段提高环卫作业的自动化和智能化水平，特别是实现精准高效的垃圾分类，已成为当前环卫行业一大难题。

图 1-1 人工捡拾垃圾

为了应对垃圾分类面临的挑战，推动垃圾分类的自动化和智能化是必然趋势，同时受到了国家层面的高度关注和政策支持。近日，国家发展改革委和住房城乡建设部联合发布《生活垃圾分类制度实施方案》。方案指出推动垃圾分类是建设资源节约型社会的必须步骤。实行全民垃圾分类对于增强城市的可持续发展能力和推动城市生态文明建设具有重要意义[3]。

不仅仅是国家政策开始呼吁全民进行垃圾分类，深度学习领域的计算机视觉技术也取得了较大进展，为垃圾分类提供技术基础。计算机视觉技术中的经典模型，卷积神经网络通过多层次的特征学习来提高图像识别和目标检测的精度[4]。将深度学习技术应用

于垃圾识别与分类任务，不失为提高垃圾识别与分类任务的准确度的一种方法。利用现代化技术进行垃圾识别与分类不仅能够减轻环卫工人的劳动强度，更能提高整体环卫作业的效率和质量[5]。

我国当前将“可持续化发展”视为重要战略，如果要实现这一战略，确保垃圾正确分类并且有效回收是必不可少的一环。所以我国当前需要完善的垃圾识别与分类算法[6]。未来的趋势也必然是将完善的垃圾识别与分类算法部署在环卫车、智能清扫机器人等设备上实现环卫智能化以及环卫自动化。

1.2 国内外研究现状

1.2.1 国外研究现状

国外的垃圾分类相比国内起步更早。早在 1976 年美国的 Hertz 就曾提出实施垃圾分类是推动环境保护的重要一步。Hertz 也强调了实施垃圾分类不仅需要依靠道德层面的推动，更需要国家和政府从法律和政策角度进行干预，并且鼓励企业和个人积极参与垃圾分类[7]。自那之后，许多研究人员开始探索如何通过政策手段推动垃圾分类的全面普及。2005 年，Loudmouth 提出如果垃圾分类想要成功实施，那么得首先从源头上培养居民的分类习惯，Loudmouth 认为激励措施虽然重要，但对于未将垃圾分类养成习惯的居民更需要通过政策约束和政府的知识教育。这一观点为后续有关于垃圾分类政策的研究提供了理论依据[8]。

2006 年，Goddard 开始研究垃圾收费与垃圾产生量之间的关联。研究结果表明：对垃圾进行收费能显著减少垃圾的产生量。并建议通过对进行垃圾分类的人给予补贴从而激励他们[9]。2009 年，Beuchera 提出，培养适当数量具备垃圾分类技能的专业人员，可以有效推动垃圾分类的全民普及。一场处于英国的实践也证明了这一点。英国通过培训拾荒者，使他们掌握垃圾分类技能，这一政策不仅降低了垃圾处理成本，还为拾荒者创造了经济收入，让当地社会更加稳定[10]。

在一部分研究人员探索政策的同时，对垃圾分类的技术性研究也在逐渐进步。Ebrahimi 就曾利用深度学习技术改进蘑菇采摘机器人，实现蘑菇采摘的自动化，为垃圾分类提供了新的可能性。既然机器人可以识别并采摘蘑菇，那么机器人也可以识别并回收垃圾[11]；2011 年，Ren Y 在利用深度学习技术提高垃圾分类图像的识别准确度之后设计了相关设备用于支持实际应用，从此深度学习技术在垃圾分类中的重要性可见一斑[12]。

在深度学习技术被确定为垃圾分类的核心技术之后，Xen 集团的研究人员对深度学习的图像识别方法进行了改进；他们设计的机器人可以利用深度学习技术识别并回收特定的建筑材料；这一革新技术不仅提高了建筑材料回收的效率，更推动了建筑行业的垃圾分类技术[13]；2016 年之后，GThung 等人开始将深度学习中的计算机视觉技术引入垃圾分类领域，GThung 等人比较 SVM 与 CNN 模型在垃圾图像分类中的表现之后发现 SVM 在垃圾分类的速度和准确度上更为优越，而 CNN 则在处理复杂数据时展现了其独特的优势；为垃圾识别与分类后续的技术进步指明了方向[14]。

在深度学习技术的革新以及深度学习所需硬件的飞速发展下，2020 年 Yang 等人开发出 WasNTE 模型，WasNTE 是一种适配于移动端的垃圾分类识别神经网络模型。WasNTE 通过大数据对比来提高垃圾分类的准确性，使识别率达到了 96.1%，远超传统方法。这一模型的提出为垃圾分类的移动化应用提供了新的思路，将“大数据”引入智能垃圾识别与分类中[15]。同年，Berardina De Carolis 等人通过对 YOLOv3 算法的改进开发出基于视频流的实时垃圾检测系统，这一系统具有了 68%的精确度，为垃圾分类的实时检测提供了有效的技术支持[16]。YOLO 系列算法体现出来的高效性能向人们指明了新的研究方向，尤其是 YOLO 系列算法在实时分类和应对背景干扰方面，其强悍的性能充分的向研究人员展示了深度学习技术在垃圾识别与分类任务中的广阔应用前景[17]。

1.2.2 国内研究现状

虽然国内对以深度学习技术为基础的垃圾分类的研究稍晚于国外，但伴随着国家对垃圾分类的逐渐重视，相关研究已经取得了巨大进步。

王朝华的研究表明，随着公众环保意识的提升，越来越多的居民开始主动进行垃圾分类，政策引导在其中起到了关键性作用[18]；潘中柱的研究也指出，有害垃圾的分类处理仍面临较大挑战，许多未正确分类的有害垃圾被混入干垃圾填埋，导致水土污染，我国仍然需要向民众科普垃圾分类知识。

不局限于政策的研究，在垃圾分类技术的研究中，国内学者也在逐步探讨深度学习技术的应用。早在 2014 年，汤晓鸥利用深度学习与图像识别算法开发了高效的人脸识别系统，在 LFW 数据库上的识别准确率达到了 97.45%，为利用深度学习技术识别垃圾图像提供了一条光明的道路[19]；陈先昌也进一步指出，深度学习模型的识别能力依赖于大量的训练数据，所以数据量的增加有助于提高算法的准确性，那么数量充足，质量合格的垃圾数据是利用深度学习技术进行垃圾识别与分类的基础[20]；李武军的研究总结了深度学习对图像识别的促进作用，指出深度学习技术可以广泛应用于身份验证、支付系统等领域，那么将深度学习技术应用于垃圾识别与分类领域也未尝不可[21]。

尽管近年来深度学习技术在图像识别方面进步飞快，但其在垃圾识别与分类中的应用却起步较晚。吴建在 2020 年才在结合深度学习技术与传统图像处理方法之后提出一种垃圾特征提取算法，这种算法可以实现垃圾与背景的分离，为后续垃圾识别与分类的研究奠定了基础[22]；2021 年，陈莎莎通过 ImageNet 数据集和 Inception 模型，优化了算法设计，提升了垃圾识别与分类的识别精度[23]。相对前人来说，吕东的研究更加侧重固体金属垃圾的分类。他通过优化检测算法，提高了模型对金属垃圾的识别准确率[24]；王朔聚焦于可回收垃圾分类问题，设计了一套结合 YOLOv3 与 ResNet50 的垃圾分类系统，提高了模型对于可回收垃圾的识别精度[25]；何婷婷将深度学习应用于智能垃圾分类系统，设计了基于 OpenMV 的图像处理与识别算法，使系统在图像识别上更加高效、准确[26]；战秋成的研究构建了一个智能垃圾分类系统，采用深度学习技术进行垃圾图像识别，取得了较高的识别精度；徐丽则通过将深度学习与硬件系统结合，设计了一种自动分拣系统，实现了对可回收垃圾的高效分拣[27]。

2024 年，武嘉年提出了 YOLOv8 多阶段轻量级可回收垃圾检测算法，针对当前分类算法普遍存在的时间消耗问题，提出了通过改进 MobileNetV3 特征的算法。这一方法提高了运算速度，并增强了对不必要图像数据的处理能力，重点解决了垃圾分类检测中高准确率与高效率的平衡问题，为工业应用提供了技术支持[28]。

1.3 论文主要内容

本文根据对当前国内垃圾识别与分类技术的调查，决定引入坐标注意力机制构建成 CA-YOLO11 目标检测模型。且以此为基础设计了一套完整的垃圾识别与分类系统，研究路线如图 1-2 所示。一方面介绍了研究背景和意义，紧随其后回顾了国内外在目标检测与垃圾分类领域的相关进展；另一方面讲解了深度学习和目标检测技术的基本理论，重点阐述了 YOLO11 模型的结构特点和优点；改进后的 CA-YOLO11 模型结合坐标注意力机制增强了对空间信息的处理能力，提升了垃圾检测的精度和鲁棒性。

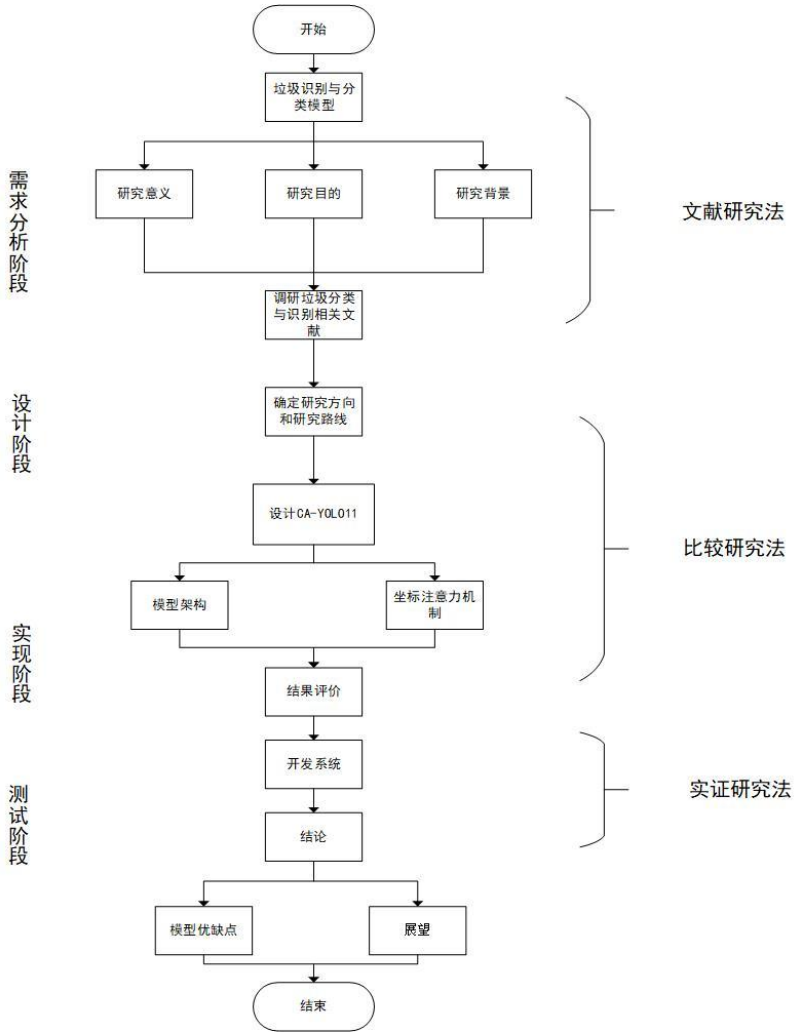

图 1-2 全文研究路线图

各章节的主要研究工作如下：

第一章是绪论，深入探讨了垃圾识别与分类的背景及全民实施垃圾识别与分类的意义，之后回顾了国内外垃圾识别与分类技术的发展历程，明确了本文的研究内容。

第二章讲解相关技术背景。详细阐述本文使用技术的背景。比如深度学习的基础理论等；重点讲解了目标检测技术，尤其是 YOLO11 模型的结构特点和应用优势；引出了了注意力机制的演变以及坐标注意力机制的基本原理。

第三章是基于 CA-YOLO11 的垃圾识别与分类模型设计。详细描述本文是如何构建的自建数据集及自建数据集中垃圾图像分布；同时寻找公开数据集用于检验模型精度；展开分析了 CA-YOLO11 模型的整体架构设计，在介绍时重点分析 Backbone 网络、坐标注意力机制、Neck 网络、Head 网络的设计思路与实现方法；解释了损失函数的设计以及模型训练过程中关键参数的选择与实现过程。

第四章是垃圾识别与分类模型的评估与分析。本章首先介绍了目标检测模型检验精度常用的各种指标，之后将基准模型和 CA-YOLO11 模型分别在自建数据集以及公开数据集上进行检验，结果表明 CA-YOLO11 模型在各个指标都要优于基准模型，证明了 CA-YOLO11 模型可以胜任垃圾识别与分类任务。

第五章是基于 CA-YOLO11 的垃圾识别与分类系统。介绍了系统的用户操作及如何实现的，并且详细叙述了系统的网页界面版本和桌面端版本。

第六章为结论与展望。条理清晰地列举出了对全文的研究结论，再一次证明了 CA-YOLO11 模型的实用性及可推广性。最后对全文的不足之处进行概括，同时对未来的智能垃圾识别与分类工作做出展望。

2 相关技术背景

在进行垃圾识别与分类任务时，深度学习技术可以作为核心手段，因为其能有效地从复杂图像数据中提取重要特征。并且 YOLO11 模型作为目标检测领域的先进算法，已广泛应用于多种实时检测任务中，所以本文在 YOLO11 模型基础上进行垃圾识别与分类任务。并为了进一步提升模型性能，探讨 YOLO11 的相关技术原理和优化方法之后引入了坐标注意力机制，该机制能够增强模型对关键区域的关注，从而提升在复杂环境中的检测效果。本章将依次介绍深度学习基础知识，YOLO11 模型的核心结构以及注意力机制的相关原理。

2.1 深度学习

2.1.1 神经网络

受到人的大脑中各个神经元互相传递信息的生物机制启发，上个世纪的人工智能领域研究者发明了神经网络，神经网络在人工智能领域是一个具有革命性意义的计算模型，标志着人工智能进入了全新的时代。如果想要了解神经网的详细组成，可以从它的基本构成单位——神经元入手，神经元的结构如图 2-1 所示。

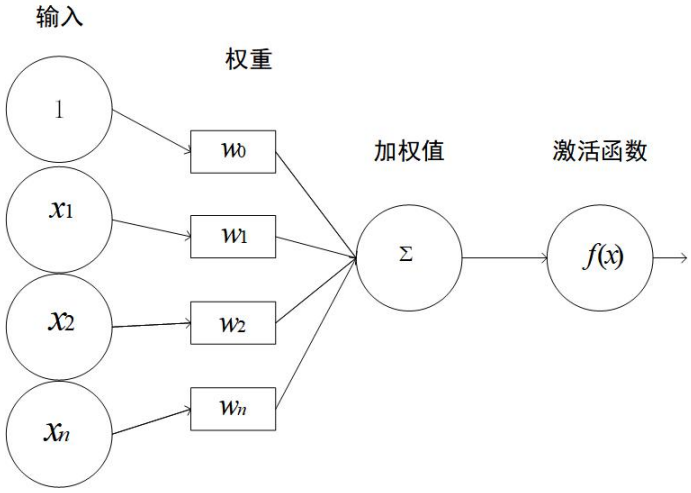

图 2-1 神经元模型

神经元是早期神经网络研究的重要产物，神经元架构包含三个核心要素[29]：

（1）加权输入模块：神经元模块支持多输入通道，并且每个输入通道配备独立权重参数，同时引入偏置项构成仿射变换。

（2）激活函数：神经元模块采用激活函数来引入非线性变化。经典激活函数 RELU 函数如式 2-1 所示，实现了对输入信号的转换。

$$f(z)=\begin{cases}0, & z<0\\ z, & z\geq 0\end{cases} \tag{2-1}$$

（3）输出结果：之前一系列参数通过加权求和运算，如公式 2-2 所示，得到总输入:

$$net = \sum_{i=1}^{n}(x_i * w_i) \tag{2-2}$$

计算后得到输出 y_i，如公式 2-3 所示。

$$y_i = f(\text{net}) \tag{2-3}$$

神经元数学模型可表示为多维参数空间的映射函数，其输入输出关系如公式 2-4 所示。

$$X = \begin{bmatrix} x_1 \\ \vdots \\ x_i \end{bmatrix}, W = \begin{bmatrix} w_1 \\ \vdots \\ w_i \end{bmatrix} \tag{2-4}$$

神经元模块完整计算流程可用公式 2-5 所示。

$$y_i = f(X^T W) \tag{2-5}$$

神经网络可以看作为是多个神经元模块的结合。虽然神经元模块在处理基本的逻辑推理或线性问题时，表现较好，但是当问题变得更复杂，涉及非线性关系时，单个神经元的能力就显得不足，需要引入神经网络来计算[30]。典型的多层前馈神经网络由多个层级组成，如图 2-2 所示。其包括输入层、一个或多个隐藏层以及输出层。数据在各层之间传递，传递方向如图中的箭头所示，各层互相连接。并且通过反向传播算法，网络能够自行调整参数，从而使模型性能达到局部最优。

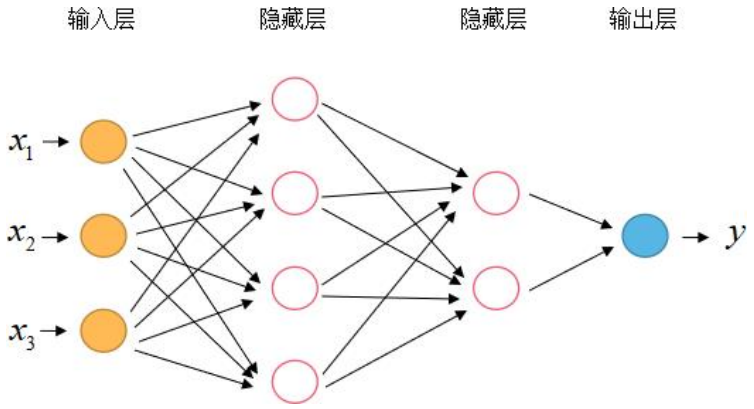

图 2-2 多层前馈神经网络结构

2.1.2 卷积神经网络

卷积神经网络（CNN）已能够广泛应用于目标检测和图像处理等多个研究任务，成为其核心技术。CNN 的优点在于可以通过特征提取进行计算，在多个不同场景中从输入数据中提取关键特征。

卷积核可以看作是由多个权重值组成的集合[31]。例如，一个 3×3 大小的卷积核包含 9 个权重参数，在训练过程中，这 9 个权重参数会不断调整，以优化模型性能，直到误差最小为止。在网络训练完成后，得到的权重参数会用于测试数据的推理，得出最终实验结果。CNN 由多个基本计算单元组成，整体结构相对简单明了。

在 CNN 中，其位置结构靠前的卷积组的组成结构大多数为卷积层与池化层相连接，当输入数据经过这些卷积组之后，就可以输出特征图。但由于不同的卷积层的深度不一样，所以得到的不同层次的特征图所携带的信息也不一样。CNN 除了标志性的网络的多层卷积结构，还有权值共享、局部连接和池化等多个特点，在 CNN 的训练过程中，反向传播算法起到了很大的作用，反向传播算法可以优化 CNN 中的参数，使得网络的训练效果达到最优[32]。

一个标准的卷积神经网络通常包含五个主要部分：输入层、卷积层、池化层、全连接层和输出层。如图 2-3 所示，输入层负责接收原始输入数据；卷积层则负责从输入数据中提取局部特征和共享参数；池化层通过降维减少模型参数，减少模型计算量；全连接层将高维特征图转化为一维向量；输出层采用 softmax 等激活函数输出预测结果。

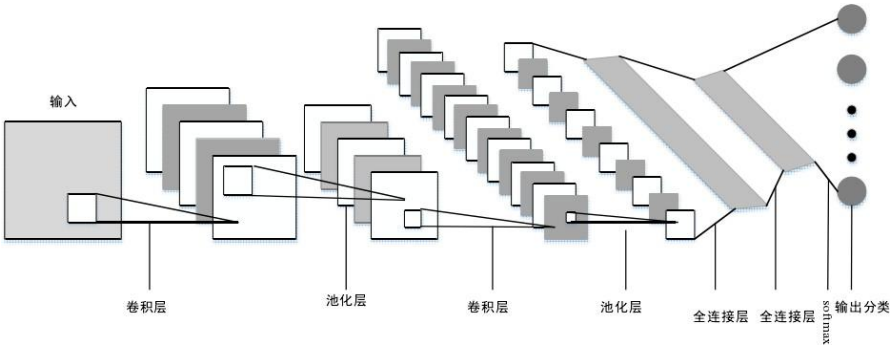

图 2-3 卷积神经网络结构图

在卷积神经网络中，前向传播过程从输入层开始，逐层计算，直到输出层。卷积神经网络在训练时主要分为前向传播和反向传播两个步骤。在前向传播时，网络接收数据之后开始逐层计算，最后输出结果。数据在每一个隐藏层之间传递直到输出层的过程中会被逐渐提取，数据的特征也会更加明显。假设卷积神经网络的第 l 层的第 i 个神经元的输入是 $z_i^{(l)}$ ，那么上述过程可以通过公式 2-6 表示。

$$z_i^{(l)} = \sum_j w_{ij}^{(l)} a_j^{(l-1)} + b_i^{(l)} \tag{2-6}$$

其中： $a_j^{(l-1)}$ 是上一层神经元的激活值， $w_{ij}^{(l)}$ 是当前层的权重， $b_i^{(l)}$ 是当前层的偏置项。然后，经过激活函数 $g(x)$ 处理后，当前层第 i 个神经元的输出如公式 2-7 所示。

$$a_i^{(l)} = g(z_i^{(l)}) \tag{2-7}$$

这种方式会在每一层中递归应用，直到最后一层的输出层，输出最终的预测结果。

紧接着，反向传播阶段开始反向传播首先从输出层开始。对于每一个输出单元，损失函数 L 对该单元的输入 z_i 的梯度是首先计算的。对于二分类问题，假设输出层使用的是 Softmax 函数，损失函数为交叉熵，则输出层的梯度可以通过公式 2-8 得到。

$$\frac{\partial L}{\partial z_i} = p_i - y_i \tag{2-8}$$

其中，p_i 是预测的概率，y_i 是实际的标签。通过计算得到输出层的梯度之后，就可以利用这些信息反向传播到前一层。对于全连接层，梯度被传播到权重和偏置上，如公式 2-9 和 2-10 所示。

$$\frac{\partial L}{\partial W} = a \cdot \frac{\partial L}{\partial z_i} \tag{2-9}$$

$$\frac{\partial L}{\partial b} = \frac{\partial L}{\partial z_i} \tag{2-10}$$

这里，a 是上一层的激活值，W 是当前层的权重，b 是偏置。

反向传播不仅仅是在全连接层之间进行。对于激活函数（如 ReLU、Sigmoid 等），还需要计算它们对损失函数的梯度。假设使用 ReLU 激活函数，它的梯度可以通过公式 2-11 获得。

$$\frac{\partial L}{\partial y_i} = \frac{\partial L}{\partial z_i} \cdot \frac{\partial z_i}{\partial y_i} \tag{2-11}$$

其中，$\frac{\partial z_i}{\partial y_i}$ 为激活函数的导数，对 ReLU 来说，当 $y_i > 0$ 时该值为 1，否则为 0。经过激活函数的梯度之后，梯度会继续反向传播至卷积层或者其他层。如果是卷积神经网络（CNN），则卷积层的梯度计算需要通过卷积核进行。具体地，卷积层的梯度可以表示为公式 2-12。

$$\frac{\partial L}{\partial w_{ij}} = x_j \cdot \frac{\partial L}{\partial y_i} \tag{2-12}$$

x_j 是输入特征，w_{ij} 是卷积核，$\frac{\partial L}{\partial y_i}$ 是从上一层传来的梯度。

一旦得到了每一层的梯度，最终通过梯度下降或其他优化方法（如 SGD）来更新网络中的权重和偏置。权重更新的公式为 2-13 和 2-14。

$$W = W - \eta \frac{\partial L}{\partial W} \tag{2-13}$$

$$b = b - \eta \frac{\partial L}{\partial b} \tag{2-14}$$

其中，η 是学习率，它控制着每次更新步长的大小。通过不断地反向传播和参数更新，网络能够逐渐减少损失函数的值，从而提高模型的精度。

2.2 目标检测技术

2.2.1 目标检测技术综述

当前目标检测技术一般可以分为两类：一阶段检测方法和两阶段检测方法。

一阶段检测方法会直接在输入的特征图上进行目标分类和定位，那么就省略了候选区域生成步骤，推理时间会大幅度降低，适合对实时性要求很高的任务。YOLO 系列模型就是一阶段检测方法的代表作之一，它的特点是会将原本的输入图像划分成多个网格组成的图像，每个网格会单独预测目标的位置和类别，以此达到实现快速检测的目的。

顾名思义，与前者不同，两阶段检测方法就是包括两个步骤：首先生成候选区域，然后在候选区域内进行分类和回归等操作。Faster R-CNN 就是两阶段检测方法的代表作之一。Faster R-CNN 首先通过 RPN 生成候选区域；然后在每个生成的候选区域内进行目标分类和边界框回归。

2.2.2 YOLO11 模型

YOLO 系列模型自从由 Joseph Redmon 等人提出之后，就凭借其高效、轻量的设计席卷了世界。YOLO 系列最新代表作 YOLO11 依靠它的高精度、高稳定性也已经广泛应用于多个实时目标检测任务。例如,YOLO11 在智能驾驶领域就能够高效检测图像中的目标并进行精确定位而备受青睐[33]。

在深入调研国内外优化 YOLO11 的资料之后，发现结合注意力机制可以进一步增强 YOLO11 在复杂背景下的鲁棒性，恰好契合垃圾识别与分类所需要的点。将通道注意力机制（CA）引入 YOLO11，可以提升其对关键特征的提取能力，可以减少背景噪声对目标检测的干扰，从而提升 YOLO11 在多场景下的表现。

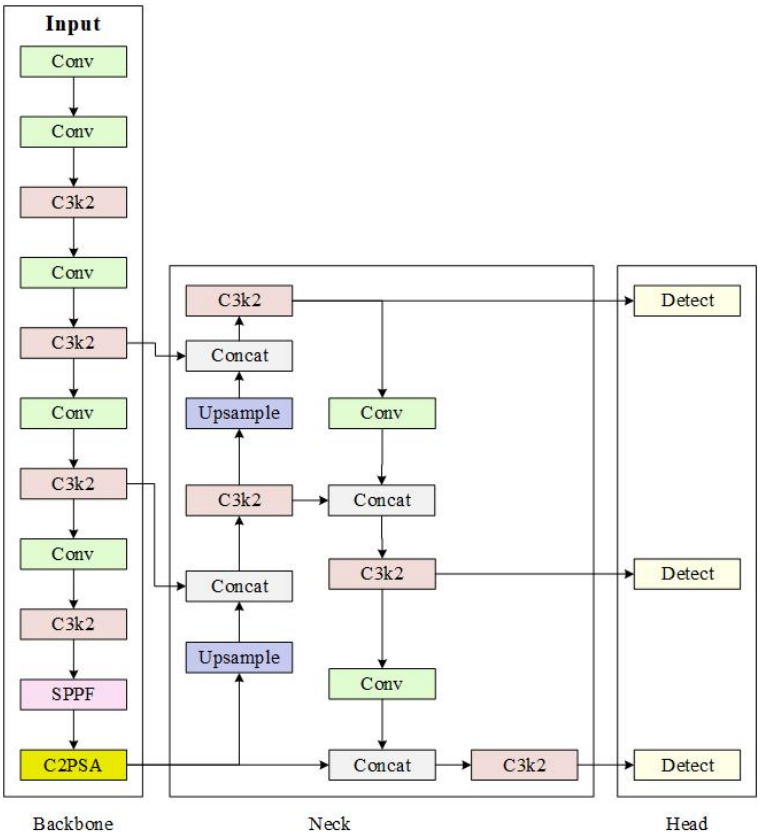

图 2-4 YOLO11 网络结构

2.3 注意力机制

2.3.1 注意力机制原理

人类的大脑之所以能聚焦与最重要的内容是因为人类的视觉可以通过大脑的注意力在复杂环境中高效筛选和处理信息。受这一生物机制的启发，研究人员开始尝试将注意力机制引入于计算机视觉领域，让模型能够自动聚焦图像中的关键部分，最大限度地忽略噪声带来的影响，从而提升模型精度。截止目前，注意力机制已在图像分类、目标检测和语义分割等多个领域得到了广泛应用，展现了巨大的潜力[35]。

尽管各类注意力网络形式不同，但它们的基本原理可以统一为公式 2-15[36]。

$$\text{Attention} = f(g(x), x) \tag{2-15}$$

其中，x 表示输入，$g(x)$ 表示通过网络生成的注意力权重分配，而 $f(x)$ 则根据这些权重对图像的关键区域进行处理。

2.3.2 坐标注意力基本原理

当使用传统深度学习模型进行目标检测任务，经常会受到背景噪声以及无关区域的干扰，尤其是当图像背景复杂或者目标物体较小时。那是因为在传统模型的主干网络中，是依靠局部网络提取特征的。这意味着网络无法考虑整体或者与方向相关的位置消息。为了解决这一问题，坐标注意力（Coordinate Attention）机制应运而生。该机制的创新点在于添加了之前很少有人注意到的空间坐标信息，增强了网络在空间维度上的感知能力，从而能够为目标区域分配更高的权重，提升目标区域的聚焦能力从而提高检测精度[37]。

与传统的通道注意力机制不同，坐标注意力机制是通过将图像中的每一个像素给予数学建模坐标，为整体建立了精确的空间坐标信息，使网络能够灵活自适应地分配注意力，从而精确调整不同空间区域的权重。在引入坐标注意力机制后，网络也能够有效避免传统卷积层在处理局部特征时常见的信息丢失和细节忽视问题[38]。

2.4 本章小结

本章详细介绍本文研究内容的基础理论。在介绍了深度学习和神经网络的基本概念时列举了卷积神经网络在图像处理中的应用；接下来，阐述 YOLO 系列模型的发展，重点讨论 YOLO11 的优化与优势，尤其是在实时目标检测中的表现；最后讲解了坐标注意力（CA）机制及其在目标检测中的应用，特别是在复杂背景和小物体检测中的性能提升。为本文后续 CA-YOLO11 模型的引入打下基础。

3 基于 CA-YOLO11 的垃圾识别与分类模型设计

3.1 垃圾图片数据集

在训练模型之前最重要的就是构建完备的训练数据集。包括寻找垃圾图像及标注每张垃圾图片中的目标物的真值边界框标签，这是进行训练的基础。充足的垃圾数据样本数量和合理的种类划分能够帮助 CA-YOLO11 模型更好地学习数据中的规律，从而提升模型检测性能。

3.1.1 数据分类

目标检测网络的训练需要依赖图片数据集及其对应的目标物真值边界框标签。充足且具有代表性的数据样本可以帮助网络更好地理解数据中的规律，从而提高检测性能。本文的数据集来自于阿里云天池实验室的公开数据集，经过筛选生活中常见的四大类垃圾之后形成了最终的数据集。

本文的研究对象主要是常见的垃圾，日常生活中常见的垃圾大致分为四类：可回收垃圾、厨余垃圾、其他垃圾和有害垃圾[39]。数据集中的各类别典型图片样本如图 3-1 所示。

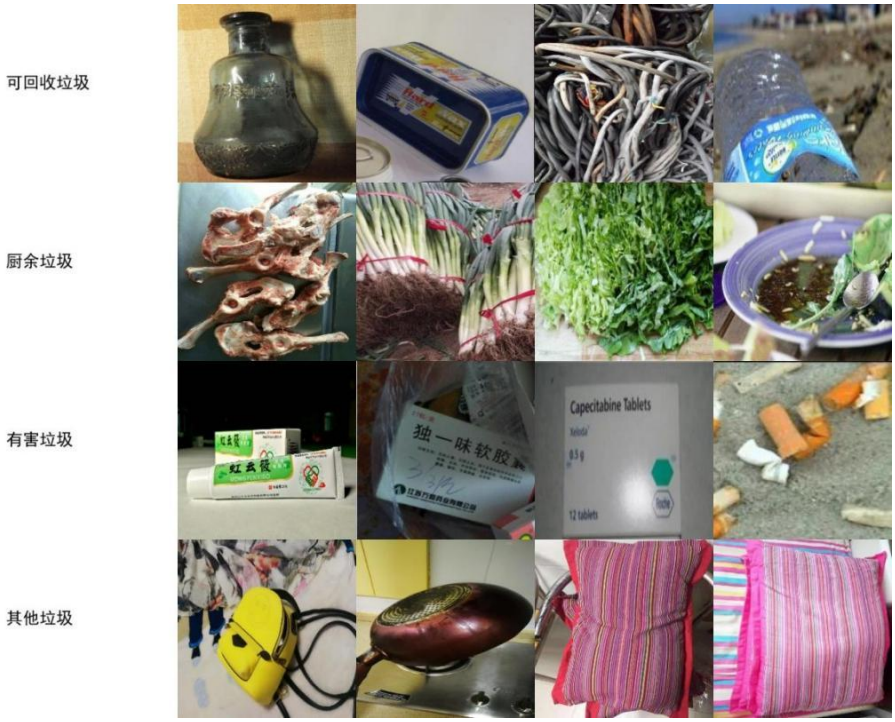

图 3-1 数据集典型样本

可回收垃圾:未经污染，适宜回收再度利用的垃圾。在自建数据集中主要包括纸类、塑料、玻璃、金属等。

厨余垃圾:由垃圾中的食物残渣和其他可降解的有机物组成。在自建数据集中主要包括剩饭剩菜、大骨头、果皮果肉、茶叶渣、菜帮菜叶、蛋壳、鱼骨等。

有害垃圾:对人身安全或者环境有害的垃圾并且需要特殊处理的垃圾。在自建数据集中主要包括干电池、过期药物、软膏等。

其他垃圾：除可回收物、厨余垃圾、有害垃圾外的剩余常见生活垃圾。在自建数据集中主要包括受污染的纸张、卫生纸等。

以 8:2 的比例将垃圾分类检测数据集划分成为训练集和测试集，垃圾分类检测数据集样本中共有 13223 张图片。数据集分布如表 3.1 所示。

表 3.1 自建数据集样本量

数据类别	可回收垃圾	厨余垃圾	有害垃圾	其他垃圾
数量（张）	3396	3240	3256	3331

3.1.2 数据标注

在收集到数量充足的垃圾图片后，需要人工标注图片中的垃圾目标物的真值边界框。本文使用 LabelImg 标注软件对自制垃圾数据集中的垃圾进行真值边界框和类别标注，并将标注信息保存为YOLO格式的标签文件。数据集文件夹中每张图片对应一个标签文件。需要注意的是，垃圾图片和标签文件的文件名必须一致，唯一的区别是文件格式不同。

YOLO 格式的标签文件是 txt 文件，内容由一行或多行数字构成，每行代表一个目标物。每行包括五个数据项：目标类别、真值目标边界框的中心横坐标、纵坐标、目标边界框的高度和宽度，以及这些值相对于图片高度和宽度的比值。LabelImg 标注界面如图 3-2 所示。

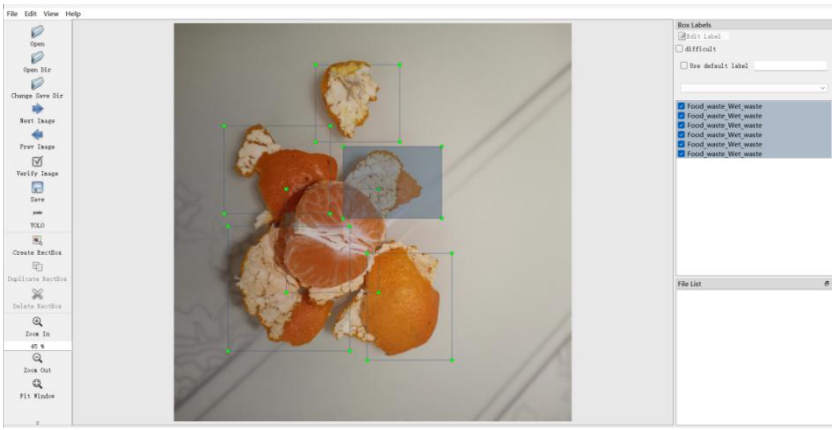

图 3-2 Labelimg 标注界面

3.2 模型架构

本文使用的 CA-YOLO11 模型主要由 Backbone、Neck 和 Head 三个核心部分组成。Backbone 网络主要采用深度可分离卷积来提取数据的有效特征，并结合 C3k2 和 C2PSA 结构，增强 CA-YOLO11 模型识别不同尺寸垃圾的能力。Neck 部分依靠结合 FPN 与 PAN 结构增强模型整合输入垃圾图像不同层次的特征信息，从而提升模型对于各个尺寸垃圾的识别能力。优化的坐标注意力机制部分能够帮助模型在空间和通道维度上合理分配权重，可以增强目标定位能力。Head 作为输出层，具有三个不同尺寸的检测结构，依照垃圾的大小来通过 Detect 层输出结果。

本文的技术架构如图 3-3 所示。

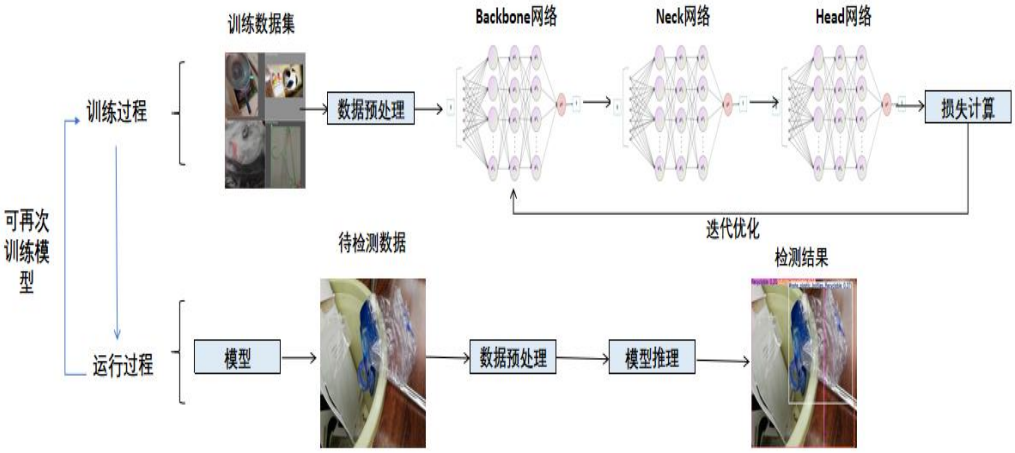

图 3-3 技术框架图

3.2.1 数据预处理

基准模型 YOLO11 的数据预处理方法包括图像尺寸调整、像素值归一化等操作。在训练阶段中，还会额外使用数据增强技术，如随机翻转和 Mosaic 等，来提升模型的检测精度和泛化性。而在推理阶段，模型只会进行必要的预处理操作，如缩放和归一化，以确保输入数据格式与训练时一致，避免影响检测精度和推理耗时过长的现象发生。

在模型训练阶段使用的数据增强技术包括 Mosaic、Mixup 等方法，还可以使用图像翻转、像素统一化等数据增强技巧。Mosaic 方法最早是在 YOLOv4 中被提出，并成为 YOLOv4 的核心部分，大幅提高了 YOLOv4 的检测精度。该方法是在训练集中随机选取四张训练图像，在进行裁剪后将原本的四张图像拼接成一张新图像，经过裁剪的图像按不同尺寸紧密组合，如图 3-4 所示。

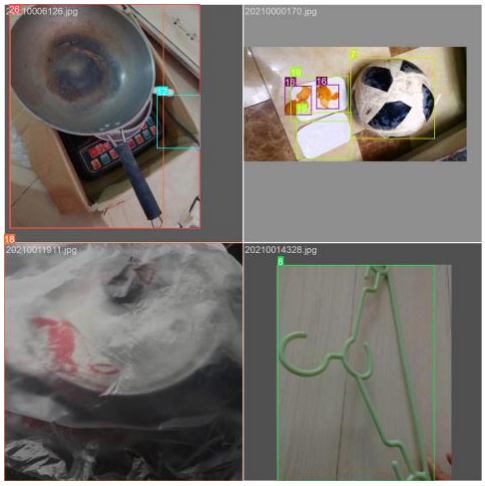

图 3-4 Mosaic 增强方法

如图 3-4 所示，图中的深灰色区域就是模型在将随机选取的训练集图像转换为正方形的填充部分。尽管深灰色区域不包含实际图像信息，但它在模型处理过程中起到了重要作用。它确保了图像具有统一的大小和形状，使模型能够以标准化的方式进行处理和分析。

3.2.2 Backbone 网络

CA-YOLO11 模型对 Backbone 网络进行了轻量级处理，目的是确保计算效率的同时仍然具备目标检测的准确性。该网络的主要作用是逐层提取垃圾图像的多尺寸特征，并通过不同结构优化特征表示。

输入图片会被模型自带程序调整为为 640×640 的 RGB 图像，首先通过 3×3 的标准卷积层（Conv），之后将通道数扩展至 64，步长设为 2，减少计算量并降低输入特征图的分辨率。接着，特征图通过深度可分离卷积（DWConv）进行处理，以较少的参数高效提取特征，减少冗余计算。

紧接着特征张量进入 CBAM（通道&空间注意力机制）模块，CBAM 会计算通道和空间注意力权重帮助网络专注重要区域，减弱背景干扰，增强提取特征能力；经过 CBAM 处理后，特征图进入第一个 C3k2 模块，在 C3k2 模块中提取 P3 级别的局部特征，通道数扩展至 256，空间尺寸保持不变。然后，特征图通过步长为 2 的 DWConv 下采样，分辨率降低至 80×80，进入第二个 C3k2 模块，完成 P4 级别特征提取，通道数增至 512。

接下来，特征图进入 P5 级别，经过深度可分离卷积之后，特征图分辨率降低至 40×40，再经过 C3k2 模块，通道数保持 512，进一步增强多尺寸特征提取能力。自那之后特征图进入高级特征提取阶段，分辨率降至 20×20，通道数增至 1024，经过 C3k2 模块提取特征，主要用于检测大尺度目标。

特征图经过 SPPF（空间金字塔池化）模块处理后，再通过 C2PSA（跨尺度特征聚合模块）优化特征表示。SPPF 的作用是通过多个尺度池化捕捉全局特征，从而增强模型对不同尺寸物体的感知能力，使模型能准确识别各种尺寸目标。C2PSA 模块的功能则是

进一步提升特征融合能力，通过跨尺度信息聚合，确保不同层级特征的顺畅传递与融合，消除层级间信息隔阂，提升模型的精度与鲁棒性。最终，经过 SPPF 和 C2PSA 处理后的特征图具备更强的辨识能力和稳定性，可在复杂场景中提供精准的特征表示。

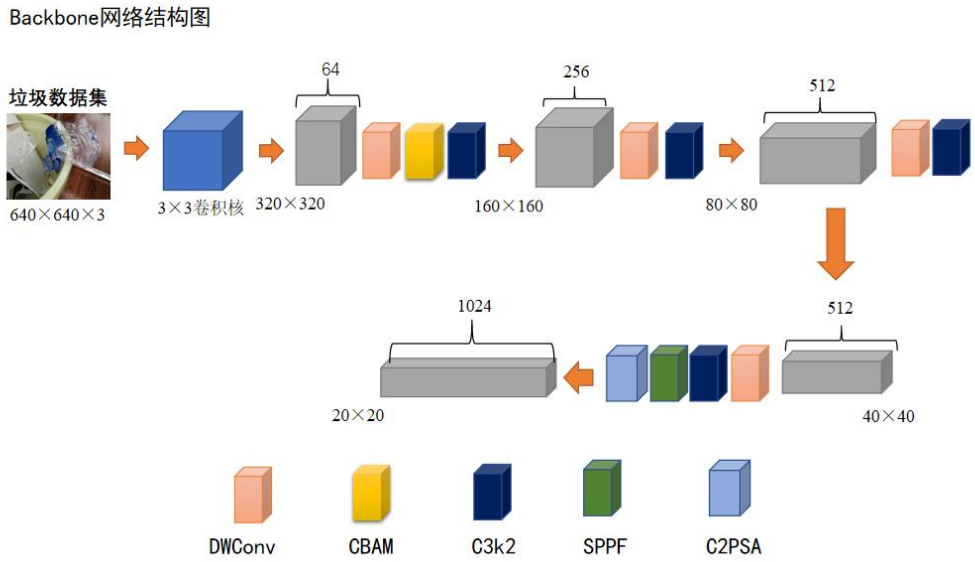

图 3-5　Backbone 网络基本架构

Backbone 网络结构以及参数设置如表 3.2 所示。

表 3.2 Backbone 网络结构及参数

层级	操作层	输入通道	输出通道	空间尺寸	卷积核	步长	填充
输入层	-	3	-	640×640	-	-	-
Conv1	Conv	3	64	320×320	3×3	2	1
Stage1	DWConv	64	128	160×160	3×3	2	1
	CBAM	128	128	160×160	-	-	-
	C3k2	128	256	160×160	-	-	-
Stage2	DWConv	256	256	80×80	3×3	2	1
	C3k2	256	512	80×80	-	-	-
Stage3	DWConv	512	512	40×40	3×3	2	1
	C3k2	512	512	40×40	-	-	-
Stage4	DWConv	512	1024	20×20	3×3	2	1
	C3k2	1024	1024	20×20	-	-	-
	SPPF	1024	1024	20×20	5×5	-	-
	C2PSA	1024	1024	20×20	-	-	-

3.2.3 坐标注意力(Coordinate Attention)

CA 机制通过水平方向（X 轴)和垂直方向（Y 轴）分解特征信息，使模型能够在增强通道特征的同时，精准建模目标的位置信息，复杂场景下也能具备很强的空间感知能力。

CA 机制主要由三个关键步骤组成，分别是全局信息编码、注意力权重计算以及注意力特征融合。

首先，在全局信息编码过程中，输入特征图 $X \in \mathbb{R}^{C\times H\times W}$ 经过 X 轴方向和 Y 轴方向的全局平均池化，分别计算水平方向和垂直方向上的全局特征信息，如公式 3-1 和公式 3-2 所示。

$$z_x^c(i) = \frac{1}{H}\sum_{j=1}^{H} X^c(i,j) \tag{3-1}$$

$$z_y^c(j) = \frac{1}{W}\sum_{i=1}^{W} X^c(i,j) \tag{3-2}$$

其中，$z_x^c(i)$ 代表第 C 个通道在 X 方向上的全局信息，$z_y^c(j)$ 则表示在 Y 方向上的全局信息。

接着，在注意力权重计算阶段，两个方向的全局信息会被送入共享的 MLP（1×1 卷积层）进行特征变换，以计算注意力权重,如公式 3-3 所示。

$$\alpha_x = \sigma(W_x z_x), \quad \alpha_y = \sigma(W_y z_y) \tag{3-3}$$

其中，W_x 和 W_y 分别为水平方向和垂直方向上的卷积权重，σ 代表 $sigmoid$ 激活函数，用于归一化权重，使其取值范围在 $(0,1)$ 之间。

最后，在注意力特征融合阶段，计算得到 α_x 和 α_y 通过广播机制分别扩展至整个特征图，并与原始输入特征进行加权融合，从而形成最终的增强特征，如公式 3-4 所示。

$$Y^c(i,j) = X^c(i,j)\cdot \alpha_x(i)\cdot \alpha_y(j) \tag{3-4}$$

坐标注意力机制的实现方式如图 3-6 所示。

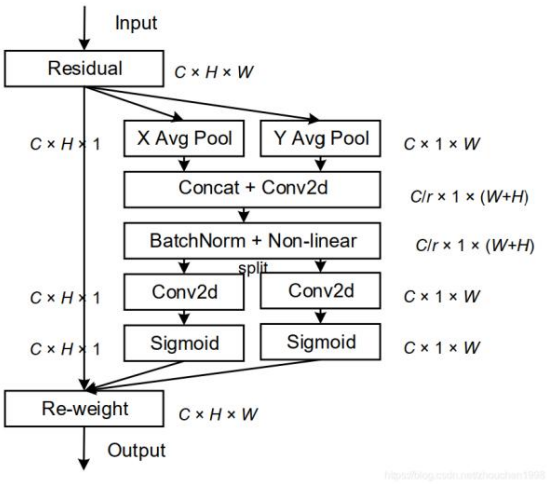

图 3-6 坐标注意力机制原理

3.2.4 Neck 网络

Neck 网络的核心任务是对 Backbone 网络提取的不同尺寸特征进行优化融合。Neck 网络能够有效增强模型对不同大小目标的检测能力，特别是在面对微小尺寸垃圾、巨大尺寸垃圾或多个不同尺寸垃圾时能够保持高效的检测性能。Neck 网络不仅结合 FPN 和 PAN 结构，还引入了坐标注意力机制，所以其在特征融合和位置信息增强方面的优势较一般的网络较为明显。

FPN 会在不同尺寸的特征图之间建立金字塔结构，使得网络可以同时处理来自不同层级的特征信息。这种金字塔结构能够帮助模型在处理不同尺寸的垃圾时，保持了良好的尺寸适应性，同时避免了在多尺度物体的检测过程中信息丢失的现象。FPN 还在 Neck 网络的上采样和下采样之间建立了有效的路径，确保低层次信息和高层次的信息能够融合，能够增强数据融合。

Neck 网络接收来自 Backbone 网络的 P3、P4、P5 三个尺寸的特征图。不同尺寸的特征图拥有不同的空间分辨率，它们的通道数自然也不一样，分别具有 256、512 和 1024 个通道。在 Neck 网络中会首先对 P5 级别特征图进行一次双线性上采样，使其分辨率与 P4 级别特征图相匹配，随后将其与 P4 特征图进行级联，形成新的 P4 级别特征。级联之后的特征图再经过 C3k2 模块处理，使其通道数维持在 512，适用于中等尺寸目标检测。

然后，该 P4 特征图会再次进行上采样，使其分辨率与 P3 级别匹配，再与 P3 特征图进行级联。随后，融合后的特征图经过 C3k2 模块进一步处理，使得底层信息和高级信息相结合，最终形成 256 通道的 P3 级别特征图，适用于小尺寸目标检测。

除了自底向上的特征融合，Neck 网络也同时包含了自顶向下的特征传递，用于增强高层语义信息。P3 级别的融合特征图首先经过 3×3 卷积进行降采样，使其尺寸达到 P4 级别，随后进行级联。融合后的 P4 特征图又会进入 C3k2 模块进行特征优化，使得该层的信息更加稳定。随后，该 P4 特征图再一次降采样，与 P5 级别特征进行融合，并通

过 C3k2 模块提取更深层的高语义特征，最终得到适用于大尺寸目标检测的 P5 级别特征图。

在 CA-YOLO11 模型的 Neck 网络的特征融合过程中，坐标注意力机制也起到了关键作用。在 P5 级别特征图融合时，坐标注意力模块会对输入特征图进行 X 轴和 Y 轴的全局池化，计算出水平方向和垂直方向上的全局特征表示。再经过 1×1 卷积和 sigmoid 函数计算出方向注意力权重，最终将原始特征通过点乘的方式输出，使得特征在传递过程中不仅包含通道信息，还能增强空间位置信息。在 P3 和 P4 级别的融合阶段时，坐标注意力机制能够有效优化小目标的空间感知能力，防止小目标信息在特征传递过程中被弱化，大大提高了小尺寸目标的检测精度。

Neck 部分不仅优化了特征的传递和融合，还增强了信息的表达能力，为后续的目标检测任务提供了更加稳定和丰富的特征。在这个过程中，Neck 会处理来自 Backbone 网络的不同特征图，特别是 P3、P4 和 P5 这些关键层级的特征图，这些特征图具有不同的空间分辨率和感知范围，分别对应不同层级的语义信息。经过 Neck 模块的处理后，这些特征图会被有效地融合和加强，形成一个综合的特征表示。

最终，经过 Neck 网络处理后的 P3、P4 和 P5 特征图被送入 Head 结构，在 Head 中进行进一步的目标检测预测。

Neck 网络的基本架构图如图 3-7 所示，展示了特征图 P3、P4 和 P5 是如何通过 Neck 网络进行处理与优化的。

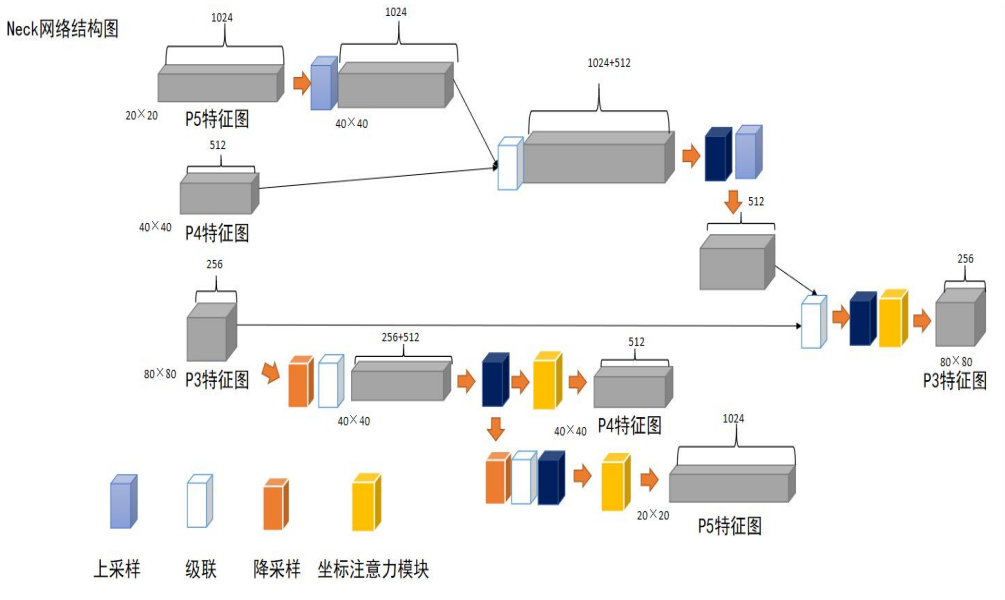

图 3-7　Neck 网络基本架构

网络结构以及参数设置如表 3.3 所示。

表 3.3 Neck 网络结构及参数

层级	操作层	输入通道	输出通道	空间尺寸	卷积核	步长	填充
P5 上采样	Upsample	1024	1024	40×40	-	-	-
P4 级联	Concat	1024 + 512	1536	40×40	-	-	-
P4 C3k2	C3k2	1536	512	40×40	3×3	1	1
P4 上采样	Upsample	512	512	80×80	-	-	-
P3 级联	Concat	512 + 256	768	80×80	-	-	-
P3 C3k2	C3k2	768	256	80×80	3×3	1	1
P4 降采样	Conv	256	256	40×40	3×3	2	1
P4 级联（PAN）	Conc·1at	256 + 512	768	40×40	-	-	-
P4 C3k2	C3k2	768	512	40×40	3×3	1	1
P3 降采样	Conv	512	512	20×20	3×3	2	1
P5 级联（PAN）	Concat	512 + 1024	1536	20×20	-	-	-
P5 C3k2	C3k2	1536	1024	20×20	3×3	1	1
P5 CA 模块	CoordAtt	1024	1024	20×20	-	-	-
P4 CA 模块	CoordAtt	512	512	40×40	-	-	-
P3 CA 模块	CoordAtt	256	256	80×80	-	-	-

3.2.5 Head 网络

CA-YOLO11 模型中 Head 网络的主要作用是接收 Neck 网络传递过来的多尺寸特征图，进一步处理以预测目标类别、边界框坐标和目标置信度，直至最终完成目标检测任务。

Head 网络首先需要对 Neck 输入的不同尺寸特征图进行处理，保证了信息的充分表达。在经过初步特征提取后，Head 网络会进入三个不同的分支，分别是用于类别预测、边界框回归和目标置信度预测的分支。其中，类别预测分支会通过多个 3×3 卷积层来提取目标的分类信息，并最终输出形状为 $C \times H \times W$ 的张量。C 为类别数。边界框回归分支与分类分支类似，最终输出的形状为 $4 \times H \times W$，表示目标框的四个坐标信息；目标置信度分支则用于判断该位置是否存在目标，并给出置信度得分。

在最终的各个特征图进入 Detect 层之前，CA-YOLO11 模型在该层额外引入了坐标注意力机制，以增强高层特征的空间感知能力，并优化通道间的依赖关系。在坐标注意力机制中，首先沿 x 轴和 y 轴分别进行特征聚合，从而提取全局信息，定义如公式 3-5，公式 3-6 所示。

$$F_x^c(i) = \frac{1}{H}\sum_{j=1}^{H} X(i,j) \tag{3-5}$$

$$F_y^c(j) = \frac{1}{W}\sum_{i=1}^{W} X(i,j) \tag{3-6}$$

其中，$X(i,j)$ 代表输入特征图在位置 (i,j) 处的通道特征 H 和 W 分别表示特征图的高度和宽度。

接着，利用两个不同的权重矩阵对聚合后的特征进行变换，以计算通道注意力，如公式 3-7，3-8 所示。

$$A_x^c = \sigma(W_1(F_x^c)) \tag{3-7}$$

$$A_y^c = \sigma(W_2(F_y^c)) \tag{3-8}$$

其中，W_1 和 W_2 为可学习参数，$\sigma()$ 代表 $sigmoid$ 激活函数。

随后，通过加权运算，将这些注意力信息重新融合到原始特征图中，以增强模型对目标区域的关注能力，具体计算如公式 3-9 所示。

$$X' = X \cdot A_x^c + X \cdot A_y^c \tag{3-9}$$

经过坐标注意力机制增强后的不同尺寸的特征图被输入 Detect 层，结合多尺度信息，进一步提高了目标检测的准确性。

Head 网络的基本架构图如图 3-8 所示。

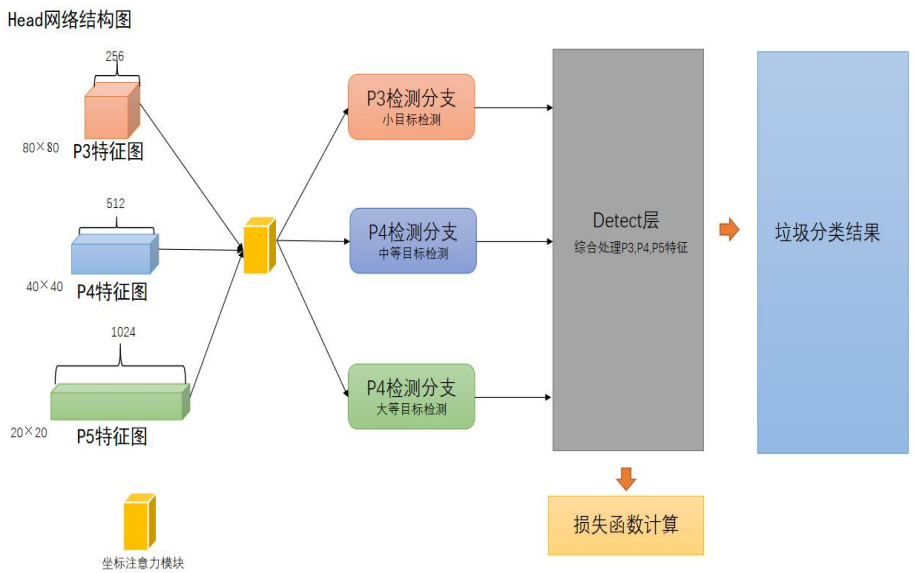

图 3-8　Head 网络基本架构

网络结构以及参数设置如表 3.4 所示。

表 3.4 Head 网络结构及参数

层级	操作层	输入通道	输出通道	空间尺寸	卷积核	步长	填充
P5 处理	P5 上采样	1024	1024	40×40	-	-	-
	P4 级联	1024 + 512	1536	40×40	-	-	-
	C3k2	1536	512	40×40	-	-	-
P4 处理	P3 上采样	512	512	80×80	-	-	-
	P3 级联	512 + 256	768	80×80	-	-	-
	C3k2	768	256	80×80	-	-	-
	P4 降采样	256	256	40×40	3×3	2	1
	P4 级联	256 + 512	768	40×40	-	-	-
	C3k2	768	512	40×40	-	-	-
P3 处理	P5 降采样	512	512	20×20	3×3	2	1
	P5 级联	512 + 1024	1536	20×20	-	-	-
	C3k2	1536	1024	20×20	-	-	-
	CoordAtt	1024	1024	20×20	-	-	-
输出	Detect	[256,512,1024]	nc×3	多尺度	-	-	-

3.2.6 损失函数

目标检测模型中损失函数的主要作用就是量化模型预测结果与真实标注值之间的偏差，可以使模型在训练过程中不断优化结构以提高模型精度。CA-YOLO11 模型的损失计算就包括三个核心部分:类别损失、边界框回归损失以及置信度损失。

在前向传播过程中，Detect 头部输出会 P3、P4 和 P5 级别的预测结果，包括目标类别得分、边界框坐标和置信度分数。这些预测结果与真实标签对比，得到对应的目标分配情况。接着，在类别损失计算部分，预测类别得分 *nn.BCEWithLogitsLoss* 进行计算，该损失函数用于衡量每个预测框的类别分布与真实类别的匹配程度，并通过 *FocalLoss* 进一步优化，增强对难分类目标的学习能力。

随后，预测框坐标经过 *BboxLoss* 计算边界框回归损失，其中 *GIoU* 损失被用于优化边界框回归精度，计算方法如公式 3-10 所示。

$$\mathcal{L}_{giou} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \tag{3-10}$$

其中，IoU 表示交并比，ρ 为目标框与真实框的欧式距离，c 为包围盒的最小外接框对角线长度，v 则表示长宽比的一致性参数。

此外，目标置信度损失采用二元交叉熵，衡量预测目标置信度与真实目标是否存在之间的误差，其计算方式如公式 3-11 所示。

$$\mathcal{L}_{obj} = BCE(p_{obj}, p_{obj}^{gt}) \tag{3-11}$$

其中，p_{obj} 为预测的目标置信度，p_{obj}^{gt} 则为真实标注值。

在反向传播过程中，计算出的总损失用于梯度更新，模型得以不断优化权重参数，使得模型在垃圾识别与分类分类任务上逐步收敛，迭代优化，提高检测精度。

3.3 模型训练

本次模型初始训练共历经 100 个周期，总耗时从初始的 521.573 秒累积至 45178.1 秒。训练期间，边界框损失由 3.16328 降至 0.54999，分类损失从 5.24268 减至 1.17559，特定任务损失也从 4.17685 降至 1.17971，各项损失均显著下降。验证集损失趋势类似但略高。评估指标上，精度由 0.00163 提升至 0.66236，召回率从 0.13407 增至 0.49901，mAP@50 和 mAP@50:95 分别从 0.00098、0.00028 升至 0.56469、0.47140，模型性能大幅提升。整体来看，模型效果良好。

3.3.1 实验环境配置

本文使用的实验环境如表 3.5 所示。

表 3.5 实验环境配置

软硬件环境	版本
操作系统	Ubuntu 20.04
GPU	NVIDIA GeForce RTX 3090
CUDA	11.8
运行平台	PyCharm 2024.2.5 (Professional Edition)
深度学习框架	PyTorch 2.0.0
Python 版本	Python 3.8

3.3.2 超参数选择

本文训练和测试 CA-YOLO11 模型时主要使用的超参数如表 3.6 所示。本文采用的梯度下降优化算法为 Adam 优化器，设置其参数 β_1 为 0，β_2 为 0.9，表示本模型用于计算一阶矩估计的指数衰减率为 0，计算二阶矩估计的指数衰减率为 0.9。

表 3.6 模型主要超参数

超参数名称	符号/参数	值
训练轮数	epochs	100
每批次图像数量	batch_size	4
输入图像尺寸	Imgsize	640
优化器	optimizer	Adam
学习率	lr0	0.01
学习率下降比例	lrf	0.01
动量	momentum	0.937
权重衰减	weight_decay	0.0005

3.4 本章小结

本章首先介绍了本文自建数据集的样本量及样本组成，然后说明了基准模型进行数据预处理的方法；详细阐述了 CA-YOLO11 的模型架构以及坐标注意力机制在这个模型中的应用以及优化部分；说明了 CA-YOLO11 的设计思路和关键技术。最后介绍了模型训练的实验环境以及主要超参数配置。

4 垃圾识别与分类模型评估与分析

4.1 实验评价指标

在详细介绍完 CA-YOLO11 模型架构之后，需要评估基于 CA-YOLO11 的垃圾识别与分类模型的性能。评估精度就需要使用目标检测任务中的常见的指标，包括了精确率（Precision）、召回率（Recall)、平均精度（Average Precision, AP）、平均精度均值（mean Average Precision, mAP）以及参数量（Parameters）。其中，mAP 的计算相比其他指标更加复杂，需要展开叙述。

在目标检测任务中，通常会根据目标的真值边界框与预测的边界框之间的关系来评估模型的表现。预测的边界框与真值目标会存在交并比（IoU），当交并比大于阈值时表明模型成功地检测到了一个目标，这就是 TP（True Positive）。那么显而易见，False Positive（FP）指的就是那些预测的边界框与真值边界框的 IoU 小于阈值的预测框，或者是对于同一个真值目标的重复预测框，这些都被视为错误的预测。至于 False Negative（FN），就是图像中有目标存在，但模型未能成功预测出来。对于这些概念，精确率 Precision 和召回率 Recall 定义分别如公式 4-1，公式 4-2 所示。

$$\text{Precision} = \frac{TP}{TP + FP} \tag{4-1}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{4-2}$$

由以上公式可以看出，Precision 代表了被模型检测出的目标框中，实际正确的比例，那么 Recall 就代表着模型能识别出所有真实目标框的能力。

模型在预测目标框的位置、大小和类别的同时，还会计算置信度。根据置信度的不同，可以筛选不同的目标框，进而影响 Precision 和 Recall；置信度较高，检测出的目标框更少，且通常更准确；置信度较低：检测出的目标框更多，但错误预测的可能性增加。

将不同置信度阈值下的召回率 Recall 和精确率 Precision 的值组成数值对，并以召回率 Recall 为横坐标，精确率 Precision 为纵坐标，将这些数值对绘制成对应的坐标点，根据上述规则，随着召回率 Recall 的增大，精确率 Precision 则会逐渐减小。如果对每个点都向横坐标轴和纵坐标轴画垂直线，则最终形成的最外侧轮廓线与横纵坐标围成的多边形的面积被称作平均精度 AP，AP 的计算可大致表示为公式 4-3。

$$AP = \int_0^1 P(R)dR \tag{4-3}$$

对于包含多类别目标的检测任务，每个类别都可以计算一个 AP，然后取所有类别的 AP 平均值，得到平均精度均值（mAP），如公式 4-4 所示。

$$mAP = \frac{1}{n_{\text{cls}}} \sum_{i=1}^{n_{\text{cls}}} AP_i \tag{4-4}$$

其中，n_{cls} 表示类别总数。

在平均精度均值 mAP 的计算过程中，判断 TP 和 FP 时比较通用的 IoU 阈值为 0.5，此 IoU 阈值下计算出的 mAP 被称为 mAP@0.5。另一个常用的 mAP 指标为 mAP@0.5:0.95，其是通过计算 0.5-0.95 之间每间隔 0.05 的十个数值作为 IoU 阈值计算的 mAP 的平均值得出的。

4.2 YOLO11 模型基准实验结果

4.2.1 自建数据集实验结果

基于已搭建好的实验环境和配置，本文采用未作修改的 YOLO11n 模型在自建垃圾数据集上进行训练与验证。通过在本文自建数据集上的训练，YOLO11n 能够高效地提取各类垃圾的特征信息，并对其进行准确的分类与定位。然而，从训练和验证结果来看，基准模型在“其他垃圾”类别的检测上表现并不好。分析其原因，可以归结为“其他垃圾”类别中包含了形状多样且复杂的物体，“其他垃圾”类别的垃圾在形态、材质、颜色等方面存在较大差异，增加了模型学习“其他垃圾”类别垃圾特征的难度。

表 4.1 YOLO11n 模型自建数据集基准实验结果

指标	可回收垃圾	厨余垃圾	有害垃圾	其他垃圾	全部
Precision	0.571	0.577	0.585	0.523	0.564
Recall	0.095	0.451	0.509	0.207	0.315
AP (IoU=0.5)	0.636	0.541	0.636	0.496	mAP@0.5 0.577
AP (IoU=0.5:0.95)	0.498	0.682	0.415	0.411	mAP@0.5:0.95 0.501

训练过程中的各项数据的变化趋势如图 4-1 所示。从图中可以看出，各项数据变化趋势均合理，并且随着训练轮数的增加都成功收敛。最终，经过 100 轮的训练，未作修改的 YOLO11n 网络在本文的垃圾数据集上训练得性能最好的模型，垃圾检测的 mAP@0.5 和 mAP@0.5:0.95 分别达到了 0.577 和 0.501。

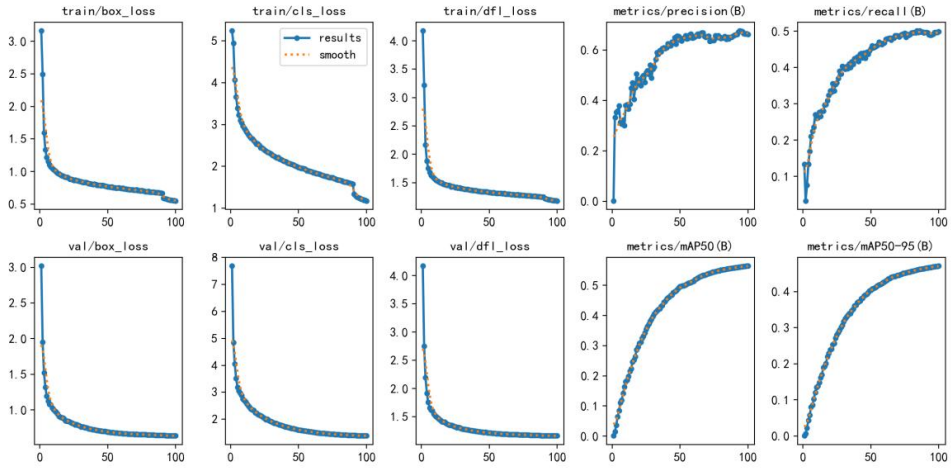

图 4-1 基准实验各项数据变化趋势

4.2.2 公共数据集实验结果

本文选择的公共数据集来自于国际知名数据科学竞赛平台 Kaggle，该平台举办过一场关于垃圾识别的竞赛，在竞赛结束之后对大量的垃圾分类数据集开源。公共数据集图片总共 4800 张，为后续模型的训练和测试提供了坚实的基础。未作修改的 YOLO11n 模型在公开的垃圾数据集上的训练验证结果如表 4.2 所示。

表 4.2 YOLO11n 模型公开数据集基准实验结果

指标	可回收垃圾	厨余垃圾	有害垃圾	其他垃圾	全部
Precision	0.462	0.376	0.485	0.467	0.448
Recall	0.115	0.326	0.319	0.157	0.231
AP (IoU=0.5)	0.567	0.587	0.511	0.461	mAP@0.5 0.472
AP (IoU=0.5:0.95)	0.487	0.496	0.503	0.411	mAP@0.5:0.95 0.423

4.3 CA-YOLO11 模型实验结果

4.3.1 自建数据集实验结果

本文优化的 CA-YOLO11 模型在垃圾分类任务上进行了的验证实验。基于包含 3200 张验证图片的数据集进行测试。此外，模型在检测速度上表现良好，推理时间仅为 6.3ms，

展现出较高的实时性。CA-YOLO11 模型在本文自建的垃圾数据集上的训练验证结果如表 4.3 所示。

表 4.3 CA-YOLO11 模型自建数据集实验结果

指标	可回收垃圾	厨余垃圾	有害垃圾	其他垃圾	全部
Precision	0.613	0.742	0.714	0.660	0.657
Recall	0.449	0.606	0.647	0.565	0.523
AP (IoU=0.5)	0.566	0.697	0.688	0.601	mAP@0.5 0.621
AP (IoU=0.5:0.95)	0.490	0.600	0.612	0.519	mAP@0.5:0.95 0.531

训练过程中的各项数据的变化趋势如图 4-2 所示。从图中可以看出，各项数据变化趋势都很平稳，并且随着训练轮数的增加都成功收敛。最终，经过 100 轮的训练，CA-YOLO11 模型在自建垃圾数据集上训练取得性能较好的模型，从训练和验证的损失曲线来看，模型在整个训练过程中收敛良好，损失值稳步下降，并且训练损失与验证损失趋势一致，说明模型的泛化能力较好，没有明显的过拟合现象。

在目标检测的精度核心指标 mAP 方面，mAP@0.5 是 0.621，并且 mAP@0.5:0.95 也达到 0.531，说明模型能够较准确地检测不同类别的垃圾目标。证明了 CA-YOLO11 模型在垃圾分类检测任务上能够取得较好的效果。

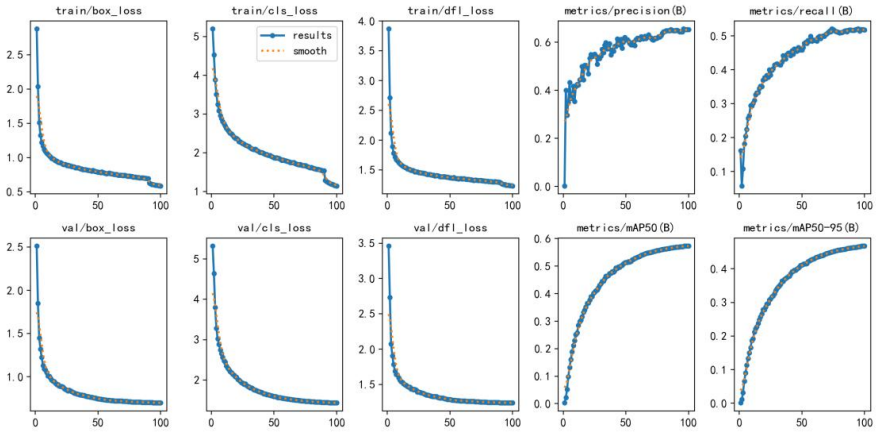

图 4-2 模型实验各项数据变化趋势

4.3.2 公开数据集实验结果

使用 CA-YOLO11 模型在公开数据集上进行测试，进一步检验模型在不同场景的泛

化能力。实验结果也表明了 CA-YOLO11 模型在 Precision 指标上表现较为稳定。CA-YOLO11 模型在本文公开的垃圾数据集上的训练验证结果如表 4.4 所示。

表 4.4 CA-YOLO11 模型公开数据集实验结果

指标	可回收垃圾	厨余垃圾	有害垃圾	其他垃圾	全部
Precision	0.482	0.76	0.56	0.640	0.543
Recall	0.421	0.459	0.751	0.352	0.496
AP (IoU=0.5)	0.477	0.622	0.716	0.494	mAP@0.5 0.523
AP (IoU=0.5:0.95)	0.439	0.451	0.667	0.392	mAP@0.5:0.95 0.487

4.4 CA-YOLO11 模型与 YOLO11 模型对比

本小节主要对比分析基准 YOLO11n 模型和引入坐标注意力机制的 CA-YOLO11 模型在自建数据集与公开数据集上的检测精度。

归功于引入的坐标注意力机制，CA-YOLO11 模型在垃圾识别与分类任务中性能明显优于基准模型 CA-YOLO11 模型的召回率提高了 15.5%，体现了坐标注意力机制增强了模型对垃圾图像细粒度特征的捕捉能力，从而减少了漏检。在衡量模型整体检测精度需要依靠 mAP@50 和 mAP@50:0.95 指标。CA-YOLO11 在模型整体精度也强于基准模型。mAP@50 提高了 4.4%，mAP@50:0.95 提高 3.0%。相较于基准的 YOLO11n 模型，CA-YOLO11 模型在自建数据集上的 mAP@0.5 和 mAP@0.5:0.95 分别提高了 4.4%和 3.0%，在公开数据集上则分别提高了 5.1%和 6.4%。这些数据充分证明了 CA-YOLO11 模型在垃圾分类任务中的优越性。两个模型精度对比如图 4-3 所示。

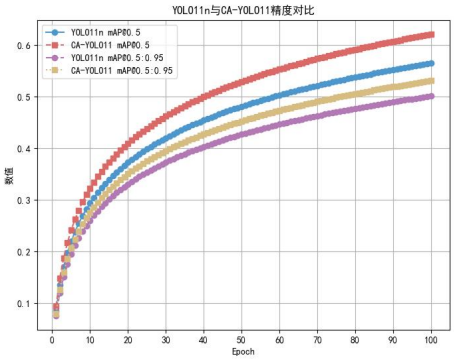

图 4-3 YOLO11n 与 CA-YOLO11 精度对比

但是 CA-YOLO11 模型轻量化相比 YOLO11n 做的并不好，是一个需要优化的点。具体数值如表 4.5 所示。

表 4.5 YOLO11n 与 CA-YOLO11 轻量化对比

指标 (Metric)	YOLO11n	CA-YOLO11	变化量 (对比基础版)
参数量 (Parameters)	≈ 2.59 M	≈ 3.25 M	增加约 0.66 M (+25%)
计算量 (GFLOPs)	6.4 G	9.4 G	增加 3.0 G (+47%)
层数 (Layers)	238 层	249 层	增加 11 层

4.5 本章小结

本章首先介绍了目标检测模型检验精度常用的各种指标，之后将基准模型和 CA-YOLO11 模型分别在自建数据集以及公开数据集上进行检验，结果表明 CA-YOLO11 模型在各个指标都要优于基准模型，证明了 CA-YOLO11 模型可以胜任垃圾识别与分类任务。

5 基于 CA-YOLO11 的垃圾识别与分类系统

基于第四章对 CA-YOLO11 模型在垃圾识别与分类任务中展现出的卓越性能评估，本章将聚焦于将这一先进模型转化为实际应用。CA-YOLO11 模型凭借其引入的坐标注意力机制，显著提升了模型对垃圾图像细粒度特征的捕捉能力，从而在精确率、召回率、平均精度以及平均精度均值等关键指标上均展现出优于基准 YOLO11n 模型的显著优势。构建一个集成 CA-YOLO11 的高效、易用垃圾识别与分类系统，旨在实现垃圾图像的快速准确识别与分类，为垃圾分类的智能化与自动化提供坚实支撑，并兼顾用户体验与系统实用性，推出网页版与 GUI 版两种使用方式以满足不同需求。

5.1 系统架构

本系统的组成主要包括前端界面、目标检测模型、后端处理模块和管理配置功能模块。

系统的有两种前端界面：网页版本和图形用户界面版本。网页版本基于 Gradio 框架开发。用户只需点击网页，上传垃圾图像便可以快捷的进行垃圾识别与分类。网页版本的最大优点就是可以快速部署和跨平台支持，用户只需通过浏览器即可使用系统，操作简便。图形用户界面版本基于 PySide6 框架开发。既可以检测上传的垃圾图像，还能够实时检测视频内容。并且可以对模型进行配置调整。

系统的后端处理模块负责接收从前端传递的图像或视频流数据，将其送入模型进行目标检测。后端处理模块基于 Python 编程语言开发。当用户上传一张图片或视频流时，系统会通过后端快速进行数据处理，识别其中的垃圾类型，并将结果返回给前端，展示在用户界面上。

系统还提供了配置管理功能。用户可以调整模型的置信度阈值和 IoU 阈值。除此之外，用户还可以选择是否保存检测结果，适应不同的应用场景和需求。

5.2 网页界面

网页界面的垃圾识别与分类系统基于 Gradio 接口实现，为用户提供了一个简洁直观的在线平台。考虑到手机屏幕和电脑屏幕尺寸的差别，网页界面还分为了电脑端和手机端。用户只需上传一张图片或者一段视频，系统就可以调用 CA-YOLO11 模型来进行推理，推理结束之后在图片上标注出检测到的垃圾类别及其置信度。

5.2.1 电脑端网页界面

电脑端网页界面为用户提供了一个简洁直观的在线垃圾识别与分类平台。在此版本中，用户可以通过上传图片之后，系统会自动调用 CA-YOLO11 模型进行分析，并在图片上标注出检测到的垃圾类别及其置信度。整个界面设计简洁清晰，用户仅需上传图片、

调整置信度阈值和 IoU 阈值，点击“submit”按钮即可获得结果。电脑端网页界面如图 5-1 所示。

图 5-1 系统电脑端网页版本界面

在系统电脑端网页版本中，用户可以随便调整置信度阈值和 IoU 阈值以达到用户需求。置信度阈值决定了模型对目标的可信度要求，如果置信度得分大于或等于阈值，那么模型就会将目标给划分到特定类别。置信度阈值越高，筛选出的目标越可靠，但可能会漏检部分垃圾。而 IoU 阈值则影响区分相邻物体时系统的严格程度，如果 IoU 大于或等于阈值，模型就可以区分不同的物体，减少误检。检测完成后，系统会在网页上直观地展示处理后的图片，用户不仅能清晰看到标注出的垃圾类别，还可以查看对应的置信度分数。如果对结果不满意，用户可以调整参数重新检测，也可以下载带有检测框的图片以作进一步分析。

用户无需安装任何软件或进行复杂的配置，只需要点击特定的网页，就可以在线使用 CA-YOLO11 模型。

5.2.2 手机端网页界面

由于手机屏幕尺寸较小，手机端网页界面便对较小的屏幕尺寸进行了优化。在保持了与电脑端相似的功能和操作方式的同时也在布局上进行了调整，使得手机端用户在移动设备上也能流畅地使用。手机端网页界面保证了触屏操作的便利性，布局变为竖直排列，确保每个功能模块都易于操作和查看。用户可以实现电脑端网页界面的每一个操作，十分便捷。

尽管手机屏幕较小，但系统依然保持了简洁明了的界面设计。用户可以通过滑动来调整置信度和 IoU 阈值，并立即看到实时更新的检测结果。检测后的图片会在屏幕上以适应尺寸显示，用户可以查看垃圾的类别、置信度以及目标框的位置。如果用户对检测结果不满意，仍然可以轻松调整参数进行重新检测。通过手机端网页，用户可以随时随地进行垃圾识别，无需安装任何应用程序，极大地提高了系统的便捷性。手机端网页界面如图 5-2 所示。

图 5-2 系统手机端网页版本界面

5.3 图形用户界面

系统的图形用户界面版本基于 PySide6 开发，适用于电脑端桌面环境。相比于网页版本，图形用户界面版本不仅在界面上更具层次感，还增强了用户对检测过程的掌控力，使操作更加灵活高效。

用户可以识别垃圾图像或者垃圾视频。在图片处理流程中，用户能够上传检验本地存储的图片，系统接着会启动 CA-YOLO11 模型对其进行检测分析，最终的分析成果将展示在界面上。检测结果以图片的形式展现，检测结果上面有标注好的目标区域以及不同类别垃圾的数量统计，帮助用户直观了解垃圾分类情况。在视频检测模式下，用户既可以上传视频文件，也可以启用摄像头进行实时检测。系统会自动解析视频流，并对每一帧画面进行分析，将检测到的垃圾对象以边界框的形式标注出来，实现流畅的实时追踪。

系统图形用户界面如图 5-3 所示。

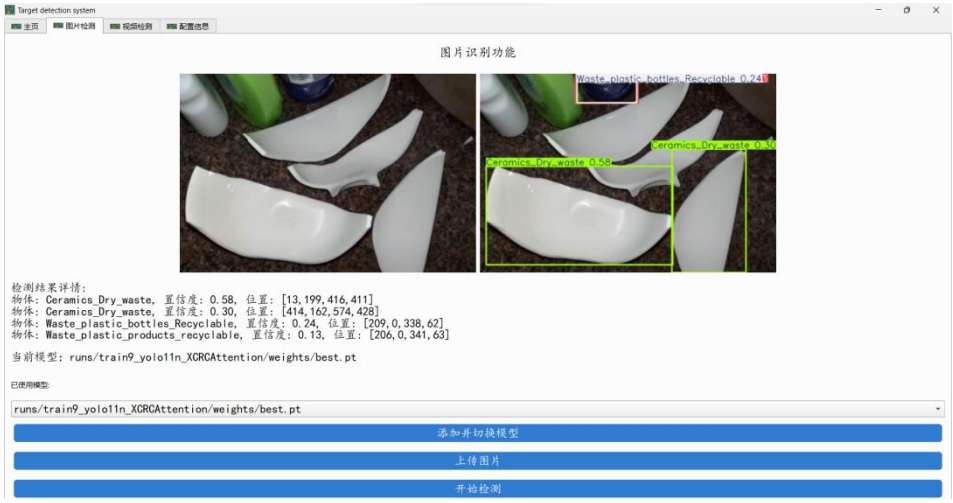

图 5-3 基于 CA-YOLO11 的垃圾识别与分类系统图形用户界面

整个系统界面设计清晰直观，包含文件选择区域、检测结果展示窗口以及切换模型等多个功能板块。无论是单张图片识别，还是长时间的视频流检测，都可以流畅操作，并在本地桌面环境下进行高效的垃圾识别与分类任务。用户还可以自由切换目标检测模型，如图 5-4 所示。这个版本不仅适用于个人使用，也可作为智能垃圾分类、环境监测等领域的辅助工具，为实际应用提供更便捷的技术支持。

图 5-4 用户自由切换目标检测模型界面

5.4 本章小结

本章首先介绍了系统的用户操作及如何实现的，详细叙述了系统的网页界面版本和桌面端版本是如何依靠 Gradio 框架和 python 语言进行开发的，并介绍了如何上传垃圾图像、检测垃圾种类、根据需求自行调整参数等操作，最后完整的展示了基于 CA-YOLO11 的垃圾识别与分类系统。

6 结论

本文针对垃圾产生量日益增加、大量垃圾仍然需要人力处理且耗时耗力、智能清扫设备还未全面普及等一系列问题，引入坐标注意力机制优化 CA-YOLO11 模型，并且通过在自建数据集和公开数据集上进行模型评估证明该模型的精度，之后基于该模型设计了一套完整的垃圾识别与分类系统。本文所得出的结论如下：

（1）将坐标注意力引入基准模型之后优化得到 CA-YOLO11 模型。CA-YOLO11 模型结构对比基准模型来说，Backbone 网络要更为轻量，在复杂背景图片中也能更好地检测到目标；Neck 网络也嵌入了坐标注意力机制，对不同尺寸的垃圾特征提取更为具体；Head 输出结果也更贴切垃圾的尺寸。

（2）分别将基准模型和 CA-YOLO11 模型在本文自建数据集和公开数据集上做对比试验。在自建数据集上，CA-YOLO11 模型的 mAP@0.5 和 mAP@0.5:0.95 是 0.621，相比基准模型提高了 4.4%和 3.0%；在公开数据集上，CA-YOLO11 模型的 mAP@0.5 和 mAP@0.5:0.95 是 0.523 和 0.427，相比基准模型提高了 5.1%和 6.4%。体现了 CA-YOLO11 模型的检测精度与泛化性，证明该模型可以应用于符合我国现状的垃圾识别与分类任务。

（3）基于 CA-YOLO11 模型设计了一套完整的垃圾识别与分类系统。该系统分为网页版和桌面用户界面版，支持图片和实时视频流检测，提供可调参数，如置信度和 IoU 阈值。这验证了该模型从理论到实际应用的转化潜力，能够服务于多种垃圾分类场景。

从应用角度来看，垃圾识别与分类智能化具有巨大的应用价值，也可以拓展至其他智能任务中，比如智能采摘农作物，智能检测天然气管道等。本文将坐标注意力引入计算机视觉领域，虽然取得了一定进展，但是有几处不足：

（1）本文主要对生活中常见的四大类垃圾进行识别与分类，未来还可以尝试对数据集和模型做出改变，检测更多其他种类的垃圾，拓宽检测范围，提高模型检测精度。

（2）本文对其他类别垃圾检测效果较另外三个种类的垃圾效果较差，究其原因是因为这个类别的垃圾形状、颜色差异较大，模型很难学习到垃圾的特征信息。未来可以将这个种类的垃圾进行细分，以增强模型精度。

（3）当前模型对于图片检测速度较快，但是检测视频数据的时候速度和精度都会下降。未来可以调整模型，实现对于视频数据的高精度、高速度检测。

参考文献

[1] 王鸽, 丁勇, 潘云峰, 等. 城市环卫设施规划与建设研究[J]. 工程技术研究, 2022, 7(22):227-229.

[2] 肖献法. 针对“背街小巷”，北京环卫集团推出一系列新款小型化、智能化清洁设备[J]. 商用汽车, 2017(12):86-90.

[3] 张莉萍, 张中华. 城市生活垃圾源头分类中居民集体行动的困境及克服[J]. 武汉大学学报(哲学社会科学版), 2016, 69(6):50-56.

[4] 罗安能. 基于改进 YOLOv5s 的可回收垃圾检测与应用研究[D]:[硕士学位论文]. 南宁: 广西大学, 2022.

[5] 城北. 把垃圾分类做好办实. 山西日报, 2020, 21(1): 1–9.

[6] 李伟, 刘桂雄, 曾成刚. 基于实例分割的垃圾检测方法研究[J]. 电子测量技术, 2022, 45(03): 153-157.

[7] Hertz D. E. Boston Teamsters Strike Against Hertz Over Benefits [J]. Job Classification (Originated from The Boston Globe), 1976: 99 - 193.

[8] Karami E, Shehata M, Smith A. Image identification using SIFT algorithm: performance analysis against different image deformations [J]. 2017.

[9] Lowe D G. Distinctive image features from scale-invariant keypoints [J]. International Journal of Computer Vision, 2006, 60(2): 91 - 110.

[10] Beucher A, Sutskever I, Hinton G. ImageNet classification with deep convolutional neural Advances in Neural Information Processing Systems, 2009, 25(2).

[11] Ebrahimi M, Liu W, Jia Y, et al. Going deeper with convolutions [C] // 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2010.

[12] Chen L C, Zhu Y, Papandreou G, et al. Rethinking atrous convolution for semantic image segmentation [J]. arXiv preprint arXiv:1706.05587, 2018.

[13] 周倩倩, 刘汉林, 陈维锋, 司徒祖祥, 腾帅, 陈贡发. 基于 Deeplabv3+的垃圾检测与语义分割[J]. 中国技术, 2022, 38(13): 22-27.

[14] Thung G, Sande KEAVD, GeversT,al. Selective search for object recognition [J]. International Journal of Computer Vision, 2016, 104(2): 154 - 171.

[15] Yang A, Wang C Y, Liao H. Yolov4: optimal speed and accuracy of object detection [J]. arXiv Preprint arXiv: 2020(10): 134 - 141.

[16] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: Common objects incontext. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics). 2020: 740–755.

[17] Simonyan K, Zisserman A. (2024). Application of YOLO and convolutional neural networks (CNN) in plastic waste classification.https://arxiv.org/abs/1409.1556, 2024-04-10.

[18] 王朝华. 对我国进一步推进垃圾分类形成全民参与态势的建议 [J]. 北方经济, 2022(1): 57 - 59.

[19] Lu C , Tang X .Surpassing human-level face verification performance on LFW with gaussian face[C]//National Conference on Artificial Intelligence.AAAI Press, 2015.

[20] 罗平, 田永龙, 王晓刚, 等. 可切换深度学习网络结构的方法与终端: CN 105224963B [P]. 2019.

[21] 范蕾, 王晓颖, 李武军, et al. KNSBN 晶体全息再现像质量的研究 [J]. 西安工业大学学报, 2014, 34(12): 5.

[22] 吴奎华, 吴健, 卢兆军, 等. 一种基于深度学习与多源信息融合的饱和负荷空间分布精准预测方法: CN 108960488A[P]. 2018.

[23] 陈莎莎. 基于深度学习的可回收垃圾分类算法研究.

[24] 吕东, 王萍, 王宇航, 等. 固体金属垃圾分类中基于深度学习方法的研究[J]. 广西工学院学报, 2021(004): 032.

[25] 王朔, 郭凤娜. 基于 YOLOV3 与 ResNet50 算法的智能垃圾分类系统[J]. 传感器世界, 2021, 27(9): 6.

[26] 何婷婷, 朱亚红, 杨雪. 基于深度学习的 AI 智能垃圾分类系统[J]. 新一代信息技术, 2022(007): 005.

[27] 王烨. 基于深度学习的垃圾评论识别研究[P]. 吉林大学, 2018.

[28] 武嘉年, 陆康, 李红. 基于改进的 YOLOV8 多阶段轻量级可回收垃圾检测算法[J]. 武汉大学学报：综合版, 2024, 39(5): 7.

[29] Paisitkriangkrai, S., Sherrah, J., Janney, P., et al. Effective semantic pixel labelling with convolutional networks and Conditional Random Fields. In IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (2015), pp. 36–43.

[30] Koller, D., & Friedman, N. Probabilistic graphical models: Principles and Techniques (Adaptive Computation and Machine Learning series). Foundations, 2009.

[31] Lafferty, J., McCallum, A., & Pereira, F. C. N. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In ICML ’01 Proceedings of the Eighteenth International Conference on Machine Learning (2001), 1(1), pp. 406–417.

[32] WU Y, YANG T, ZHAO J, 等. Fully combined convolutional network with soft cost function for traffic scene parsing. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics). 2017: 725–731.

[33] Khanam, R., & Hussain, M. (2024, October 23). YOLO11: An Overview of the Key ArchitecturalEnhancements.arXivpreprintarXiv:2410.17725. https://doi.org/10.48550/arXiv.2410.17725

[34] Li X , Deng J , Fang Y . Few-Shot Object Detection on Remote Sensing Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024(99).

[35] Mnih V, Heess N, Graves A. Recurrent models of visual attention[J]. Advances in neural

information processing systems, 2014, 27
[36] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE
[37] conference on computer vision and pattern recognition. 2018: 7132-7141.
[38] Hou, Q., Zhou, D., & Feng, J. (2021). Coordinate Attention for Efficient Mobile Network Design. arXiv. https://doi.org/10.48550/arXiv.2103.02907
[39] 田军. 让节能低碳成为我们的生活方式[J]. 企业导报, 2019(07): 250-251. DOI: 10.19354/j.cnki.42-1616/f.2013.07.189.

致　谢

时光荏苒，岁月如梭，大学四年的时光转瞬即逝，我也即将为自己画上大学生涯的句号。在这四年里我收获了太多太多的快乐、知识以及自身的成长，我也想对所有帮助过我的人表达由衷的谢意。

我想感谢我的指导老师，张宇老师和吴凯老师。你们对于我的这篇论文的建议以及指导让我受益匪浅，不仅加深了我对专业知识的理解，也锻炼了我论文叙述与写作的能力。这篇论文的完成与您二位的帮助是紧密相连的。在这里再真挚的对张宇老师和吴凯老师说声感谢！

我想感谢我的父母和姐姐，他们永远会在我处于低谷的时候给我无尽的鼓励和帮助；永远会在我取得哪怕再小的成绩时不吝他们的赞美；永远会在我提出我想做某件事情时说让我放心大胆的去做；永远给予我独属于家的温暖；但他们却从不会将他们脆弱的一面让我看到。在哈尔滨读大学的四年我离安徽有 2133 公里，但有他们的关怀让我每天都觉得我离家并不远。对他们的感激之情，我无以言表，但是我想告诉他们，我会继续努力，不会辜负他们给我的爱！祝福他们万事顺意！

我想感谢所有对我予以帮助的同学和朋友。和余宏骏学长是在大一认识的，在这四年里无论是在生活还是学习上他都给了我最大的帮助，希望他在以后的生活中一帆风顺！感谢本硕校友刘凡博学长对我的诸多帮助！庆幸可以在大学中遇到这么多志同道合的朋友，张欣瑞、刘松玮、方书研、钤相涛，很感谢他们对我生活以及学习中的帮助，愿友谊长存，我也会永远记住我们在一起度过的快乐时光！感谢我的初高中同学，他们让我大学生活更加丰富多彩！感谢感谢北八 637 的室友，寝室只有我一个外地人，从小到大也没有住过校，他们用他们的善意让我很快熟悉了环境，也让我拥有了幸福且宝贵的大学寝室回忆，感谢你们！

我想感谢东北农业大学，给了我那么多的机会，让我不管在知识还是社交上都有所进步！

还记得高中看到过一句话：“你高考错的每一分都是为了让你遇见对的人。”在最后我想感谢我遇到的每一个“对的人”！

学位论文原创性声明

本人郑重声明：所提交的毕业论文是本人在导师指导下独立进行研究工作所取得的成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明，其它未注明部分不包含他人已发表或撰写过的研究成果，不存在购买、由他人代写、剽窃和伪造数据等学术不端行为。

本人愿为此声明承担法律责任。

作者签名：许晨冉　　日期：2025 年 6 月 1 日

学位论文版权授权书

本学位论文作者同意授予东北农业大学对本论文全部内容的信息网络传播权、汇编权、发行权、转授权与复制权，具体包括但不限于将学位论文上传到有关数据库，影印、缩印或扫描等手段保存、查阅、借阅、汇编等。

（保密的学位论文在解密后适用本授权书）

作者签名：许晨冉　　日期：2025 年 6 月 1 日

任务书

学生姓名	许晨冉	学号	A07210244	班级	物联 2102
题目	基于深度学习的垃圾识别与分类方法研究与应用				

毕业论文（设计）要求

1.调研当前国内外基于深度学习的垃圾图像识别、垃圾的分类方法、及公开数据集；

2.搭建基于深度学习的垃圾识别、目标检测模型，并在公开数据集上训练、测试效果。根据我国垃圾分类方法，对数据集中的垃圾进行自动分类，并评估识别与分类的性能。

3.自行收集垃圾图像数据集，包含可回收垃圾、干湿垃圾等大类，其中常见垃圾具体种类应不少于 15 种，同时完成图像预处理、数据扩增、标注标签等工作。

4. 查阅国内外相关文献，按照东北农业大学《本科生毕业设计论文基本规范》撰写论文。

毕业论文（设计）内容与技术参数

1. 设计内容

(1) 利用深度学习基础知识，讨论基于深度学习进行垃圾分类与检测的国内外研究现状；

(2) 首先选择包含垃圾常见种类、垃圾种类数目恰当的公开图像数据集。

(3) 搭建基本模型之后添加注意力机制等方面来优化垃圾的识别与分类。

(4) 利用自行收集的数据集上进行验证，评估优化后的模型效果。

2. 部分技术参数

(1) 网络参数数量：1181150；

(2) 数据集大小：12000 张垃圾图像；

毕业论文（设计）工作计划

2024.12.1-2024.12.15：查阅相关文献资料，确定论文选题；

2024.12.15-2025.1.15：选择技术手段，进行需求分析，撰写开题报告；

2025.1.15-2025.2.15：制作数据集，进行网络设计和实现；

2025.2.15-2025.2.29：完成系统测试与分析，撰写中期检查报告；

2025.3.1-2025.4.1：整理代码，完成毕业论文撰写；

2025.4.1-2025.4.30：修改完善论文并提交，制作 PPT，准备答辩。

接受任务日期：2024 年 12 月 01 日　**要求完成日期：**2025 年 05 月 08 日

学　　生：许晨冉

指 导 教 师：张宇　吴凯

东北农业大学毕业论文（设计）开题报告

学生姓名	许晨冉	学号	A07210244	班级	物联 2102
题目	基于深度学习的垃圾识别与分类方法研究与应用				

题目研究的目的和意义

1. 研究目的

随着我国经济的蓬勃发展和城镇化、工业化步伐的加速，居民生活消费水平持续提升，这一趋势直接导致了生活垃圾产生量的急剧增加。据统计，自 2022 年起，我国城市生活垃圾的年清运量已稳定超过两亿吨，且这一数字仍在持续攀升，城市环境污染问题因此变得日益严峻，对居民的日常生活质量和身体健康构成了严重威胁。鉴于此，众多城市已逐步加大对环卫工程规划与建设的重视，并为此投入了大量的人力物力资源。环卫问题已成为影响城乡发展的重要因素，其重要性不言而喻。

传统上，我国的环卫作业主要依赖人工完成。然而，随着清扫保洁区域的不断扩大，人工环卫作业在效率、安全性和环保性方面的局限性日益凸显，已难以满足当前社会的发展需求。因此，环卫作业的自动化和智能化管理成为了大势所趋。随着国内环卫市场的逐步开放以及装备制造技术的不断革新，环卫作业模式正逐步向机械化和现代化转型。

尽管如此，当前大多数环卫车辆仍主要适用于清扫平坦的道路，而对于人行道、辅道、公园景区、校园、商业区以及生活社区等“城市毛细血管”区域的清扫保洁工作，其效果并不理想。这些区域的垃圾往往隐藏在缝隙、草坪、树丛、沟槽和花坛等难以触及的地方，仍需大量依靠人工进行清扫和拾捡，全面自动化和智能化管理的目标尚未实现。

近年来，深度学习技术在计算机视觉、自然语言处理等多个领域取得了显著进展，其中卷积神经网络（CNN）作为深度学习的核心研究方向之一，通过模拟人脑的学习机制，采用多层神经网络结构，能够高效提取数据中的本质特征，并在多个公开数据集上展现了高精确度。因此，深度学习在计算机视觉领域的优异表现引起了学术界的广泛关注，同时也为垃圾识别领域提供了新的研究思路和技术手段。

针对当前垃圾分类中存在的问题，本文致力于探索基于深度学习的垃圾识别与分类方法。通过构建深度神经网络模型，实现垃圾的自动识别和精准分类，以提升垃圾分类的效率和准确性，推动垃圾分类技术向智能化、自动化方向发展。这一研究不仅有望提高垃圾处理的效率，降低人工操作成本，还将对环境保护和资源回收产生积极影响。

2. 研究意义

近年来，国家对垃圾分类问题给予了高度重视，并出台了一系列政策和实施方案。国家发展改革委、住房城乡建设部发布的《生活垃圾分类制度实施方案》明确指出，垃圾分类不仅能够有效改善环境，促进资源回收利用，还能加速建设资源节约型、环境友好型社会，提高新型城镇化和生态文明建设水平。源头垃圾分类能够实现垃圾的减量化和资源化，减轻后续垃圾处理的压力，节约处理成本，对于推动可持续发展具有重要意

义。

随着计算机视觉和计算机硬件技术的迅速发展，许多基于深度学习的目标检测算法在各个领域取得了显著成效。将这些技术应用于垃圾分类任务中，能够实现更高效的垃圾识别与定位，提高分类的准确性和资源回收效率。尤其是对于清扫设备，具备精准的垃圾识别与定位能力，能够有效提升垃圾分类的精度和自动化水平。然而，提升目标检测模型的准确性和可靠性，尤其是在部署于清扫设备上的应用，仍是当前技术面临的核心挑战和难点。因此，针对这一问题，本研究致力于通过改进现有目标检测算法，提升垃圾识别和分类技术，为清扫设备的智能化应用提供有力支持，从而推动垃圾分类技术在实际环卫工作中的有效应用。

题目研究方案和主要内容

题目研究方案和主要内容

1. 研究方案

(1) 结合国内外垃圾智能识别与分类研究现状及文献资料，寻找合适的公开数据集；

(2) 确定生成网络的设计思路和主要框架，对数据集进行预处理，扩增等操作；

(3) 训练网络，在公开数据集上评估模型的识别与分类精度，以及自行收集数据集，探索改进优化方法；

(4) 总结研究内容，撰写论文。

2. 主要内容

本文的主要研究内容和如下：

(1) 分析垃圾智能识别与分类的国内外研究现状，明确设计合适的神经网络模型的研究背景和意义；

(2)选择垃圾种类全面、拍摄角度和光照（白天、傍晚、夜间）各异的垃圾图片数据集，构建基于深度学习的垃圾识别与分类模型；

(3) 选择 YOLO 模型作为主要框架，对原本模型中的超参数和损失函数等进行适当调整，在模型训练过程中不断评估效果；

(4) 使用自行收集的数据集对优化后的模型进行评估，并为在清扫设备的应用打下基础。

研究方法及技术途径

(1) 文献研究法。文献研究法是本文研究采用的主要方法，通过查阅期刊、互联网、书籍等资料整理的有关垃圾智能分类与识别的文献，掌握 YOLO 模型的架构和基本原理，确定自己的研究思路。

(2) 比较研究法。在确定优化器，损失函数和超参数时，通过对比不同的超参数优缺点，最终选择最适合本文网络架构的超参数。在成功实现网络后，通过与其他已知网络进行对比体现本文设计的网络的性能。

(3) 实证研究法。在进行模型验证时采用实证研究法，确保模型的精准度符合预期。

实施计划 2024.12.1-2024.12.15：查阅相关文献资料，确定论文选题； 2024.12.15-2025.1.15：选择技术手段，进行需求分析，撰写开题报告； 2024.1.15-2025.2.15：制作数据集，进行网络设计和实现； 2025.2.15-2025.2.29：完成系统测试与分析，撰写中期检查报告； 2025.3.1-2025.4.1：整理代码，完成毕业论文撰写； 2025.4.1-2025.4.30：修改完善论文并提交，制作 PPT，准备答辩
指导教师：张宇 吴凯 **审核时间：**2025 年 02 月 11 日

东北农业大学毕业论文（设计）中期检查

学生姓名	许晨冉	学号	A07210244	班级	物联 2102
题目	基于深度学习的垃圾识别与分类方法研究与应用				

论文概述

在本文中，我使用了一个包含四个主要类别的自建垃圾数据集：可回收物、干垃圾、湿垃圾以及有害垃圾，每个大类下面有若干种类的垃圾。结合国内外研究现状，我选择了 YOLOv11 作为基础模型。针对现有模型在小体积、多种类数据检测中效果较差的问题，我决定对 YOLOv11 模型进行改进，加入了 Coordinate Attention 机制，这样可以帮助模型更好地识别各种类型的垃圾。最后，为了验证该模型的有效性，在 Kaggle 上找到了一个与自建数据集垃圾种类相似的公开数据集，进行了测试，结果证明了该模型的可行性。

本阶段研究工作的内容和进展

1. 已完成的工作：

（1）根据国内外利用深度学习技术对垃圾进行分类和识别的研究现状，查阅相关文献。目前已查阅中文文献 25 篇，英文文献 12 篇，了解了垃圾分类和识别的发展进程，以及现有的几种主流方法之后，选择了 YOLO 作为基础模型，且选择目前较前沿的 YOLO11 模型；

（2）针对现有模型存在的对小体积，多种类数据检测效果较差的问题，对模型进行修改和优化，引入坐标注意力机制（coordinate attention），并且将其命名为 CA-YOLO11 模型；

（3）自建一个初始数据集，该数据集包含丰富的常见垃圾种类，对数据集进行预处理，统一垃圾图片大小或格式化标注文件；

（4）对自建数据集的训练已经完成，得到训练好的模型权重以及评估结果，具体训练结果如表 1 所示。

表 1　CA-YOLO11 模型自建数据集实验结果

指标	可回收垃圾	厨余垃圾	有害垃圾	其他垃圾	全部
Precision	0.613	0.742	0.714	0.660	0.657
Recall	0.449	0.606	0.647	0.565	0.523
AP (IoU=0.5)	0.566	0.697	0.688	0.601	mAP@0.5 0.621
AP (IoU=0.5:0.95)	0.490	0.600	0.612	0.519	mAP@0.5:0.95 0.531

训练趋势如图 1 所示。

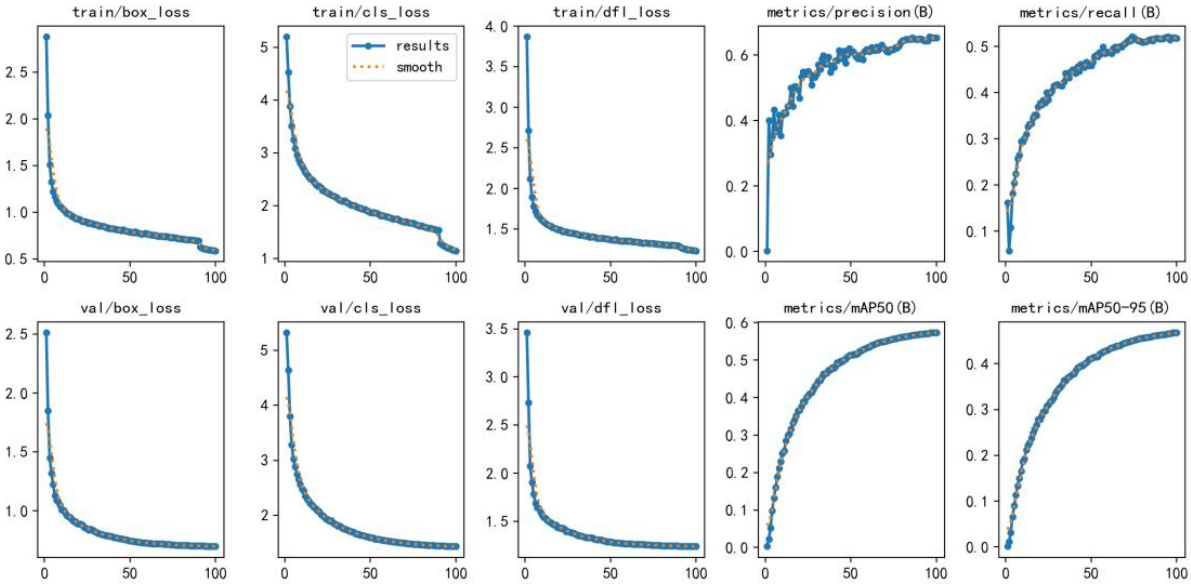

图 1 模型实验各项数据变化趋势

从图中可以看出，各项数据变化趋势均合理，并且随着训练轮数的增加都成功收敛。最终，经过 100 轮的训练，CA-YOLO11 模型在本研究的垃圾数据集上训练得性能最好的模型，从训练和验证的损失曲线来看，模型在整个训练过程中收敛良好，损失值稳步下降，并且训练损失与验证损失趋势一致，说明模型的泛化能力较好，没有明显的过拟合现象。同时，Precision 和 Recall 在训练初期快速上升，并最终趋于稳定，分别达到 0.6 和 0.55 左右，表明模型在目标检测任务上的表现较为均衡。

在核心指标 mAP 方面，mAP@0.5 达到了 62%，而更严格的 mAP@0.5:0.95 也达到 53%，说明模型能够较准确地检测不同类别的垃圾目标，但仍然有一定的优化空间，比如可以进一步提升召回率或优化特征提取能力。整体而言，模型在垃圾分类检测任务上取得了较好的效果，并具备进一步提升的潜力。

（5）在公开数据集上完成对模型的检验，得到评估结果；

（6）完成了论文引言部分的撰写。

2. 待完成的任务：

（1）对模型超参数进行适当调整以观察能否提高精度；

（2）论文剩余部分的撰写；

（3）制作答辩 PPT 等其他材料。

遇到的问题 1. 实验初期基础模型的准确率十分不理想，mAP@0.5 仅有 0.3 左右。解决方法：检查模型保存和模型加载两部分的代码，排查出模型加载时没有携带训练出的模型参数，并且对模型数据文件内容由最初的中文改变为同等意思的英文，对数据集进行扩增，成功解决该问题。 2. 在对基础模型进行改进时，更换多种方法后模型精度却几乎不变。解决方法：由于初期设立训练批次过多，且个人电脑性能有限，导致模型训练中途强行关闭。后来更改最大内存设置以及使用云服务器，成功解决该问题。
下一步工作 1. 2025.4.12-2025.4.15，理解透彻添加了 Coordinate Attention 机制的 YOLO11 模型的结构，以便更好地撰写论文； 2. 2025.4.15-2025.4.20，撰写论文，制作流程图、表格等说明性材料； 3. 2025.4.25-2025.4.30，制作答辩 PPT 等其他材料。
指导教师：张宇 吴凯 **审核时间：**2025 年 04 月 03 日

指导教师评语

学生姓名	许晨冉	学号	A07210244	班级	物联 2102
题目	基于深度学习的垃圾识别与分类方法研究与应用				

指导教师评语：

本篇论文围绕提高垃圾识别与分类的效率与准确性，通过引入坐标注意力机制对 YOLO11 模型进行优化，设计出 CA-YOLO11 模型，并构建了垃圾识别与分类系统，对推动垃圾分类的智能化发展具有积极意义。论文研究内容完整，结构清晰，方法得当，实验充分验证了模型的优越性，结论明确且具创新性，同时自建数据集为研究提供了有力支撑。论文查重率与 AIGC 检测结果均符合学校规定标准，同意该生参加毕业论文答辩。

指导教师：张宇

评阅时间：2025 年 05 月 03 日

评阅人意见

学生姓名	许晨冉	学号	A07210244	班级	物联 2102
题目	基于深度学习的垃圾识别与分类方法研究与应用				

评阅人意见：

许晨冉同学的毕业设计题目是《基于深度学习的垃圾识别与分类方法研究与应用》，基于 CA-YOLO11 模型设计了一套垃圾识别与分类系统，自制了一定量的数据集引入坐标注意力机制，将优化后的 CA-YOLO11 目标检测模型应用于垃圾分类，并对比了基准模型，通过仿真实验证明其性能都有所提升。论文体现出作者具有较深的理论基础和一定的实践动手能力，结构合理、文字表达流畅，达到本科毕业设计要求。

评阅人：冯江

评阅时间：2025 年 05 月 19 日

答辩委员会意见

<table>
<tr><td>学生姓名</td><td>许晨冉</td><td>学号</td><td>A07210244</td><td>班级</td><td>物联 2102</td></tr>
<tr><td>题目</td><td colspan="5">基于深度学习的垃圾识别与分类方法研究与应用</td></tr>
<tr><td colspan="6">答辩委员会意见：
毕业论文全面完成了毕业设计任务书规定的内容、要求；能灵活运用所学的理论知识解决设计中的问题，有独到见解；
论文设计合理，计算结果正确，图表清晰，表达准确，论文的系统性、逻辑性较强，行文流畅，文字简练；答辩时回答问题思路清晰、正确。经答辩委员会讨论，一致同意该生通过论文答辩，并建议授予工学学士学位。

答辩委员会主席：冯江</td></tr>
<tr><td>等级</td><td>优秀</td><td colspan="4">院长：李晓明

2025 年 05 月 30 日</td></tr>
</table>

电气与信息学院本科毕业论文（设计）评价指标

指标	评价要素		评价指标内涵
选题质量	1	目的明确，符合要求	符合培养目标，体现学科、专业特点和教学计划中对能力、知识结构的基本要求，达到毕业综合训练的目的。
	2	理论意义或实际价值	符合本学科的理论发展，解决学科建设、科学发展的理论或方法问题，有一定的科学意义，符合我国经济建设和社会发展的需要，解决应用性研究中的某个理论或方法问题，具有一定的实际价值。
	3	选题适当	题目贴切，有较强的科学性，难易度适中，题目规模适当。
能力水平	4	查阅文献资料能力	能独立查阅相关文献资料，归纳总结本领域有关科学成果。
	5	综合运用知识能力	能运用所学专业知识分析论述有关问题，能对占有资料进行分析整理并适当运用，概念清楚，能以恰当的论据对科学论点进行有说服力的论证。
	6	研究方案的设计能力	设计（论文）的整体思路清晰，结构完整，研究方案完整有序。
	7	研究方法和手段的运用能力	能较熟练的运用本学科的常规科学研究方法，能适当运用相关研究手段（如计算机、实验仪器设备等）进行资料搜集、加工、处理，并辅助论文写作。
	8	外文应用能力	能按照学校规定结合论文阅读、翻译一定量的本专业外文资料，有外文摘要和外文书目。
成果质量管理	9	文题相符	论文较完整地回答了题目所设定的有关问题。
	10	写作水平	论点鲜明，观点正确，论据充分，论证有力，条理分明，语言流畅。
	11	写作规范	符合科学论文的基本要求，论文（设计）中的用语格式、图表、数据、各种资料的运用及引用都要规范化。
	12	篇幅	工程设计类篇幅不少于 8000 字，研究论文篇幅不少于 10000 字。
	13	成果的理论或实际价值	在理论上具有新意，应用性研究对于实际工作具有一定意义。