東北農業大學

本科毕业论文

基于改进 YOLOv11 的吸烟行为检测算法设计与实现

Design and Implementation of Smoking Behavior Detection Algorithm Based on Improved YOLOv11

所在学院：电气与信息学院

所在班级：物联 2101

学生姓名：郭梦雪

学生学号：A10210035

指导教师：张宇　马瑞新

研究方向：物联网智能算法

2025 年 06 月

東北農業大學

本科毕业论文

基于改进 YOLOv11 的吸烟行为检测算法设计与实现

Design and Implementation of Smoking Behavior Detection Algorithm Based on Improved YOLOv11

所在学院：电气与信息学院

所在班级：物联 2101

学生姓名：郭梦雪

学生学号：A10210035

指导教师：张宇　马瑞新

研究方向：物联网智能算法

2025 年 06 月

摘要

吸烟行为的自动检测在智能监控系统与公共卫生管理中具有重要的实际应用意义。香烟目标尺寸较小且特征微弱，致使检测精度较低，针对这一情况，本文在 YOLOv11 框架基础上提出改进模型 YOLOv11s-SE。通过引入 SE（Squeeze-and-Excitation）通道注意力机制，该模型可对烟支区域的特征响应进行自适应提高，抑制背景干扰，并且保持轻量化设计以契合实际部署的需要。

本文采用公开吸烟行为数据集来对模型进行训练与评估，该数据集包含 783 张图像以及 816 个标注框，并按照 8:1:1 的比例被划分成训练集、验证集以及测试集。改进之后的 YOLOv11s-SE 在 mAP@50 以及 Precision 指标方面分别达到了 0.910 以及 0.958，相较于原始的 YOLOv11s 提升了 3.3%以及 3.9%。实验显示，SE 模块借助动态调整通道权重分配，使得模型对小目标烟支的敏感度得到了提升，误检率降低到了 15%以内。同时模型参数量从 9.3M 增加到了 9.41M，仅仅增长了 1.2%，推理速度稳定在每帧 7.5 毫秒，兼顾了轻量化以及实时性的需求。

本研究借助改进模型开发出以 PyQt5 框架为基础的图形化吸烟行为检测系统，此系统融合了单帧图片检测功能以及视频分析功能，并且支持 CSV 格式数据导出。本研究希望能够提出一种可应用于公共场所吸烟监管的轻量化目标检测办法，并在一定程度上提高检测的精准度。实验结果显示，引入通道注意力机制有利于改进小目标的检测成效，对于其他弱特征识别任务也有一定的参考价值。

关键词：YOLOv11；SE 注意力机制；吸烟行为检测；小目标检测；PyQt5

Design and Implementation of Smoking Behavior Detection Algorithm Based on Improved YOLOv11

Abstract

Automatic detection of smoking behavior has important practical significance in intelligent monitoring system and public health management.Cigarette target size is small and feature is weak,which leads to low detection accuracy.In this paper, an improved YOLOv11s-SE model based on YOLOv11 framework is proposed.By introducing SE (Squeeze-and-Excitation) channel attention mechanism,the model can adaptively improve the feature response of cigarette region,suppress background interference,and keep lightweight design to meet the needs of practical deployment.

The model is trained and evaluated on a public smoking dataset,which consists of 783 images and 816 labeled boxes and is divided into training set,validation set and test set according to the ratio of 8:1:1.The improved YOLOv11s-SE achieves mAP@50 and Precision index of 0.910 and 0.958 respectively,which is 3.3% and 3.9% higher than the original YOLOv11s.Experiments show that SE module improves the sensitivity of the model to small target smoke by dynamically adjusting channel weight assignment,and reduces the false detection rate to less than 15%,while the model parameters increase from 9.3M to 9.41M,only increasing by 1.2%,and the inference speed is stable at 7.5 ms per frame,which takes into account the requirements of lightweight and real-time.

In this study,we developed a graphical smoking behavior detection system based on PyQt5 framework,which integrates single-frame image detection function and video analysis function,and supports CSV format data export.Experimental results show that the introduction of the channel attention mechanism is conducive to improving the detection performance of small targets,and also has certain reference value for other weak feature recognition tasks.

Key words:YOLOv11;SE Attention Mechanism;Smoking Behavior Detection;small target detection;PyQt5

目录

摘要 I
Abstract II
1 绪论 1
1.1 研究的背景及意义 1
1.2 国内外研究现状 2
1.2.1 目标检测算法研究现状 2
1.2.2 小目标检测算法研究现状 3
1.2.3 吸烟行为检测研究现状 4
1.3 研究的主要内容 5
1.4 研究的技术路线 6
1.5 论文章节安排 7
2 相关理论基础 9
2.1 传统目标检测方法 9
2.2 基于深度学习的目标检测方法 9
2.2.1 卷积神经网络 9
2.2.2 YOLO 单阶段目标检测 13
2.2.3 注意力机制 16
2.3 本章小结 17
3 数据集和吸烟检测模型的实现 18
3.1 吸烟行为数据集制作 18
3.1.1 数据集采集 18
3.1.2 数据集标注 19
3.1.3 数据的最终分布 20
3.2 基于 YOLOv11 的吸烟目标检测模型 22
3.3 本章小结 23
4 实验结果与分析 24
4.1 实验环境 24
4.1.1 软硬件配置 24
4.1.2 模型训练策略 24
4.2 评价指标 25
4.3 YOLOv11s 模型性能分析 27
4.3.1 模型训练结果分析 27
4.3.2 模型评估结果分析 30
4.4 模型对比 30
4.4.1 YOLOv11s 对比 YOLO8s 性能提升情况 31

4.4.2 YOLOv11s 与 YOLO11s-attention-SE 性能对比 34
4.5 本章小结 38
5 吸烟行为检测系统界面设计 39
5.1 界面功能模块设计 39
5.2 控件设计与样式 40
5.3 信号与槽机制 40
5.4 本章小结 41
6 结论 42
6.1 结论 42
6.2 展望 42
参考文献 44
致　谢 47
学位论文原创性声明 49
学位论文版权授权书 49

1 绪论

1.1 研究的背景及意义

中国作为全球最大的烟草生产国与消费国，卷烟消费量在全球总消费中所占比例超过 43%，成年男性吸烟率常年维持在 50%以上[1]。按照世卫组织的报告，2022 年中国烟民数量超过 3 亿，其中成年男性吸烟率达 45.3%，14 岁以上人群吸烟率为 24.1%，高于全球平均水平。并且吸烟相关疾病和死亡人数不断攀升，我国每年有 100 多万人因烟草失去生命，若不采取有效举措，预计到 2030 年会增至 200 万人，到 2050 年会增至 300 万人[2]，而且烟草含有的尼古丁、苯并芘等有害物质，燃烧时会释放大量烟雾，严重危害人体健康，致使癌症、心血管疾病以及呼吸系统疾病等多种非传染性慢性疾病频繁发生。烟蒂处理不当还可能引发火灾或者爆炸事故，造成重大经济损失以及人员伤亡。

为解决吸烟带来的危害，中国政府多年来一直开展禁烟工作。在 2005 年，中国加入《世界卫生组织烟草控制框架公约》；2006 年，全国人大借助禁烟法规，把烟草危害纳入公共卫生议题；2012 年，北京市颁布了《北京市公共场所禁烟规定》，此规定扩大了禁烟的范围，把公共场所划分成完全禁烟区域、部分禁烟区域以及特殊禁烟区域[3]；2016 年，《健康中国 2030 规划纲要》提出相关目标，即到 2030 年要把 15 岁及以上人群的吸烟率降低至 20%。虽然已经出台了不少法规和政策，并且在公共场所设置了数量不少的禁烟标识与警示牌（如图 1-1 所示），然而吸烟人口数量以及烟草产量却仍然在逐年上升，禁烟工作依然面临着相当大的挑战。

图 1-1 禁烟标识和警示牌

早期在公共场所开展控烟工作时主要依靠人工监管、烟雾传感检测以及传统目标识别技术。人工监管模式要投入大量的人力资源与运营成本，且因为受到生理机能负荷以及注意力分配机制的限制，很难实现广域空间的全时段、无死角监控覆盖，使得监管效能有较大的局限性。烟雾传感检测体系是基于气体浓度监测原理的，当空间单元内烟雾颗粒浓度超过预设阈值时就会触发报警机制。但是它的作用范围有限，在开放场域或者空气流动的条件下，烟雾扩散造成的浓度衰减效应比较明显，大多时候难以达到报警触

发条件，环境适应性不足的问题较为突出。传统目标检测方法依靠手工设计特征提取规则，在处理烟支类小目标时，特征表达能力受到很大限制，目标像素占比不足致使类间区分度下降，同时该技术方案对目标姿态变化、部分遮挡以及光照条件波动等干扰因素有很强的敏感性，在复杂环境背景下难以保持稳定的检测性能，技术缺陷极大地限制了其适用性和推广价值。

近些年来，深度学习算法于计算机视觉领域收获了突破性的成果，智能监控系统在公共安全以及交通管理等应用场景里的深度布局变得日益广泛，这些技术进展为禁烟工作开拓了全新的技术达成途径，还提升了禁烟效能的智能化水准[4]。深度学习是一种基于多层神经网络架构的特征自学习框架，在目标检测任务中呈现出优异的性能优势。其中最关键的是可自动达成层次化特征提取与抽象表达学习，和传统方法相比，该技术对复杂环境变量有着更强的鲁棒性，在降低小目标烟支的误检率与漏检率方面表现突出，为达成高精度检测提供了算法层面的关键支撑。

由智能监控设备所构成的分布式感知网络，可对公共场所及办公区域开展不间断的行为监测工作，实时获取吸烟行为在空间与时间方面的分布数据。此种模式突破了人工监管在时间与空间上的限制，构建起了涉及“数据采集、行为分析以及证据留存”的全自动化流程，降低了人力成本，而且提升了执法响应效率。针对禁烟场景里存在的如样本分布失衡、目标尺度微小以及像素特征稀疏等技术难题，把烟支当作典型小目标来展开专项研究，并且构建基于深度神经网络的检测模型，已成为当前技术发展的关键方向。这种技术路径可有效克服传统方法在检测精度方面的瓶颈，同时推动禁烟工作朝着智能化与精准化方向转变，有关键的学术研究价值以及实际应用前景。

1.2 国内外研究现状

1.2.1 目标检测算法研究现状

目标检测属于计算机视觉领域里的一项关键任务，该任务的主要目的在于识别出图像或者视频里的特定对象，同时确定这些对象的位置以及边界框，此任务在自动驾驶、视频监控以及医学图像分析等多个领域当中都发挥着关键作用[5]。目标检测的演化过程大体上可分成三类，分别是基于传统特征的方法、基于手工特征与机器学习分类器的方法以及基于深度学习的端到端检测方法。

（1）传统方法与机器学习阶段

早期目标检测大多依靠人工设计的特征提取方式，比如 Pailus 等人提出借助级联简单特征以及 Adaboost 算法来快速达成物体检测，有着速度较快、可实时检测的优势[6]。随后 Jin 等人依据方向梯度直方图（HOG）特征并且结合支持向量机（SVM）进行分类，切实提高了复杂场景下的检测能力[7]。

Dollar 等人对特征提取方式做了改进，提出一种基于邻近尺度外推的多尺度特征近似方法，该方法达成了更快且更准的行人检测效果，为后续多尺度特征分析给予了理论支撑[8]。

（2）深度学习方法逐渐兴起

深度学习的兴起意味着目标检测进入了一个新的阶段，Girshick 等人最先把卷积神经网络引入到检测任务当中，提出了 R-CNN 算法，使得特征判别能力以及检测精度得到了一定程度的提升[9]。随后 Redmon 等人提出了 YOLO 系列算法，把目标检测转变为回归问题，达成了端到端的实时检测[10]。Liu 等人发布的 SSD 算法引入了多尺度检测机制，兼顾了检测速度和精度两方面[11]。

随着检测需求不断提高，Redmon 等人所提出的 YOLOv3 借助多尺度输出以及与类别无关的边界框回归，优化了检测性能[12]。Zhang 等人提出了 RefineDet 模型，此模型在 SSD 基础上引入锚点细化机制，提高了对目标位置的准确回归能力[13]。

（3）结构优化以及特征提升阶段

为了可提高检测的效果，研究者在网络结构和特征融合方式这两个方面持续不断地进行优化。Tan 等人提出了 EfficientDet 模型，该模型引入了 BiFPN 模块用来实现高效的特征融合，采用复合缩放策略来平衡网络宽度、深度以及分辨率，在保持轻量化的状况下提升整体性能[14]。

在关键点检测这一研究方向上，Duan 等人提出了 CenterNet，把目标检测建模成为关键点预测问题，使得边界框定位精度得到了提升[15]。另外 Carion 等人基于 Transformer 结构提出了 DETR 算法，该算法首次达成了目标检测任务的端到端建模，为目标检测引入了全局上下文建模机制[16]。

Xie 等人提出的 Oriented R-CNN 模型结合方向感兴趣区域处理方式，在旋转目标检测任务里提升了精度以及鲁棒性[17]。而 Chen 等人提出 DiffusionDet，把检测建模成从噪声框到目标框的扩散过程，创新性地引入扩散建模思路，有效提高了检测精度[18]。

（4）小目标检测与注意力机制相融合

小目标检测存在险阻，近年来研究开始重视引入特征提高机制，如把 SE 注意力模块整合到主干网络里，凭借自适应调整通道权重，提高模型对局部关键区域的关注能力，在烟雾检测等小目标识别任务中呈现出不错的效果。

1.2.2 小目标检测算法研究现状

对于小目标对象的检测是目标检测算法中的关键挑战和技术发展瓶颈。虽然小目标研究存在一些难题，但研究价值也吸引了很多学者关注。现在，基于深度学习小目标检测算法研究主要集中以下几个方向：

（1）数据增加

Kisantal 等使用复制增加算法将数据集小目标复制，然后随机贴到图像其他位置，通过增加数据集小目标框数量，改善目标框图像中占比面积小，预测框和真实框之间 IoU（交并比）小造成漏检问题，从而小目标检测精度提升[19]。

YOLOv4 使用 Mosaic 数据增加算法，该算法用四张图像，并对它们随机缩放后重新拼成一张新图像，此时新图像中含更多小目标框，使小目标检测精度提升[20]。

Kim 等使用生成对抗网络 GAN（对抗生成网络）分别生成红外小目标和背景图像两部分，然后用强度调制网络将两部分图像合成为红外小目标图像数据，并将生成红外小目标数据集和真实红外小目标数据集合并，对合成数据进行训练，因此获得比只用真实

图像数据更好的性能指标[21]。

（2）尺度变化

基于尺度变化将小目标转为大目标，可以提升小目标检测精度。Li 等通过使用 GAN 网络对小目标框做超分辨率操作，使小目标重建成相对大尺寸目标，从而提升更多小目标特征信息。但是超分辨率算法需结合其他算法使用，对设备需求高，小目标检测速度降低[22]。Zhou 等通过使用尺度转移模块，对 DenseNet-169 网络提取特征层进一步处理，获得不同嵌入式超分辨率层，在不增加参数和计算量情况下，使网络能获得大尺度特征层，从而提高小目标检测精度[23]。

（3）上下文信息

基于上下文信息方法将小目标检测转为相关环境或事物特征信息，进行特征提取，从而提高检测精度。Y 等提出 CoupleNet 小目标检测模型，通过融合全局信息与局部信息，引入上下文特征信息，使用此方法提升小目标检测精度[24]。Chen 等利用小目标上下文信息，在 R-CNN 算法基础上提出新区域建议网络，在检测小目标时，改进算法获得平均精度比 R-CNN 算法提升了 29.8%[25]。但基于上下文信息小目标检测可能引入无关特征信息，对检测精度产生负面影响，因此上下文信息需针对具体情况合理选择。

（4）特征融合

在卷积神经网络中，不同特征层包含不同特征信息。通常浅层特征更关注目标边缘和其他局部细节信息，而深层特征更多包含目标语义信息。FPN（特征金字塔网络）算法综合利用浅层与深层信息，提升小目标检测精度[26]。Zeng 提出新增强多尺度特征融合方法 ABFPN，使用不同膨胀率空洞卷积，有助于充分利用上下文特征信息，并通过跳跃连接实现不同特征层信息融合，在三个公共数据集上评估，证明此新多尺度特征融合方法能显著提升小尺寸目标检测精度[27]。

（5）合适 Anchor

目标检测算法中，Anchor 通常固定不变，但对不同数据集，使用不同尺寸 Anchor 可实现更好检测效果。直接应用通用 Anchor 到小目标检测任务，可能引入额外噪声，因此需针对小目标设计特殊 Anchor[28]。Zhang 等改进 GA-RPN 算法，实现自适应 Anchor 生成，并在 DOTA 与 NWPU VHR-10 数据集上验证算法，证明自适应 Anchor 生成算法可提升遥感图像检测精度[29]。

1.2.3 吸烟行为检测研究现状

在公共场所吸烟，这一行为会对吸烟者自身的健康造成危害，其所产生的二手烟还会给周围的人群带来健康方面的损害，而且随意丢弃的烟头有可能引发火灾隐患。目前关于吸烟行为识别的研究主要集中在三个技术维度，即烟雾特征分析、吸烟动作模式识别以及烟支目标检测[30]。接下来，将分别从这三个方向对现有的研究进展进行综述：

（1）烟雾特征检测

该领域的相关研究主要围绕烟雾的物理特性展开检测工作，借助传感器来对环境中烟雾浓度的变化情况给予监测，一旦检测所得数值突破预先设定的阈限，便会触发相应的报警机制。Panpaeng 团队所研发的香烟烟雾传感器系统，达成了对室内环境烟雾浓度

的监测目的。其具体工作原理是把烟雾浓度信号转化为电信号，当电信号的幅值超过所设定的阈值时，该系统就会自动向管理人员发送警示信息[31]。

Irawan 等人把物联网技术融入到烟雾检测领域之中，开发出了一种有网络接入能力的智能烟雾传感器，这种设备可以自动搜索可使用的网络，当检测到烟雾超过标准数值的时候，就会借助网络通道把警报数据实时传送到监管平台[32]。

（2）吸烟动作模式识别

该方向研究聚焦于吸烟行为特有的动作模式，主要依托可穿戴设备与计算机视觉技术。Cole 等利用智能手表内置的加速度传感器采集吸烟动作数据，通过构建人工神经网络模型对 Apple Watch 和 Pebble Steel 设备采集的多受试者数据进行训练，实现了超过 90%的吸烟行为识别准确率[33]。

Senyurek 团队在手腕部位固定单轴加速度传感器，创新性地提出无偏自相关算法对手势时序信号进行处理，该算法对手-嘴交互动作及打火机使用等吸烟相关手势展现出优异的识别性能[34]。邢予权等基于计算机视觉技术开发吸烟手势识别系统，采用超分辨率重建技术优化图像预处理流程，结合人脸检测技术定位手势识别区域，有效降低了计算复杂度[35]。

（3）烟支目标检测

在该领域的研究工作中，主要将烟支本体作为检测对象。马研凯等人运用 YOLOv5 算法框架来构建烟支检测模型，选用 MobileNetv3-small 轻量化网络当作主干结构，并且针对特征金字塔池化模块做了优化改进，使得多尺度烟支目标的检测精度得到了提升[36]。王超平团队构建了专门用于烟支检测的数据集，基于 YOLOv5 架构重新设计了主干网络，还引入 CBAM 注意力机制来提高特征表达能力，检测准确率有了明显提高[37]。

Liao 等人运用 EfficientDet 模型开展烟支检测工作，借助复合缩放策略同时对网络深度、宽度以及分辨率参数进行同步调整，以此构建起多尺度特征提取网络。之后把提取出的多层次特征输入到带有跨尺度连接的双向特征金字塔网络即 BiFPN 中，达成了高性能的烟支目标预测[38]。

目前在烟支检测领域已有的研究取得了一定成果，然而鉴于烟支目标自身存在体积较小、特征稀疏等内在特性，检测的精准程度仍然受到限制。现有的算法在实际场景应用过程中面临诸多难题，例如在复杂背景下目标识别的难度加大，小目标检测容易出现漏检或者误检的状况，这些因素共同对烟支检测技术的推广和应用形成了制约。

1.3 研究的主要内容

本研究将 YOLOv11 目标检测算法当作核心框架，借助对其骨干网络结构给予优化，以此提升特征表达能力，提高整体检测模型的性能表现，为吸烟行为识别给予技术支撑。具体研究内容包含以下四个维度：

（1）数据集构建与预处理

高质量标注数据集是吸烟行为检测模型训练的基础要素，它会直接影响模型的特征学习能力以及泛化性能。本研究借助公开数据集构建训练样本库，并针对原始图像数据开展标准化预处理流程，这个流程包含尺寸归一化等处理环节，之后运用专业标注工具

对吸烟行为进行精细化标注，生成适用于深度学习框架的标注文件。

（2）模型训练与性能评估

构建吸烟行为检测模型时运用了 YOLOv11 算法架构，还采用自适应参数调整策略对该模型开展精细化训练。在模型训练的全过程里，采用了包含精确率、召回率以及 $F1$ 分数等关键指标的多维度评估指标体系，借助这些指标评估模型在多种不同场景下的检测效能。

（3）小目标检测能力增强

在对吸烟行为进行检测时会出现烟支等小目标识别精度不足的状况，本研究将会在模型 Neck 结构中嵌入 SE 注意力机制，这样的改进凭借自适应校准通道特征响应，提升网络对小目标特征的敏感程度。实验将会对比引入 SE 模块前后模型在吸烟行为检测任务中的性能指标变化，验证改进策略的有效性。

（4）智能检测系统集成

本研究还设计部署了基于 PyQt5 框架的交互式检测界面，将优化过后的 YOLOv11s 模型集成在该系统中，以此达成视频流以及静态图像的吸烟行为检测。该系统拥有检测结果显示、行为标记等功能模块，可为公共场所吸烟监控提供可视化且智能化发展提供基础技术参考。

1.4 研究的技术路线

本研究技术路线围绕数据采集与处理、模型构建优化、性能验证以及系统部署这四个核心环节展开（如图 1-2 所示）。

（1）在数据采集环节，本研究以在 Kaggle 平台获取公开数据集作为数据的来源，随后采用人工清洗的办法，把那些模糊不明、反复出现或者标注存在错误的低质量数据给予剔除。同时还要开展图像归一化、尺寸调整等预处理工作，以此保证输入格式维持一致。

接着借助 LabelImg 工具对香烟、手部持烟动作等关键目标进行精确标注。最终按照 8:1:1 的比例，把数据集划分成训练集、验证集以及测试集，形成适合模型训练的标准化数据。

（2）在构建模型阶段，依靠对相关文献展开调研并进行对比分析，本研究选择 YOLOv11 作为基础框架，充分考虑到它在检测速度和精度方面有的平衡特性，其 CSPDarknet53 骨干网络以及多尺度预测机制可为捕捉烟雾这样的小目标提供理论支撑。

之后利用 PyTorch 框架来复现模型架构，搭建本地训练环境。在完成初步训练后，发现模型对小目标的漏检率比较高。针对这种情况，在 YOLOv11s 模型的骨干网络中嵌入 SE 注意力模块，依靠动态调整特征通道权重来提高关键区域的响应。

（3）模型性能比较阶段，首先把 YOLOv11s 模型同 Ultralytics 团队应用极为广泛的 YOLOv8s 模型开展对比，将性能提升的比重给予可视化呈现。紧接着，把基准模型 YOLOv11s 和引入 SE 注意力机制的改进模型进行性能方面的比较，依靠精确率-召回率曲线分析以及 mAP 值计算，对模型在复杂背景下的检测能力进行量化评估。

（4）在系统部署阶段，借助 PyQt5 开发可视化交互平台，将优化后的检测模型进

行集成，达成三大核心功能。

其一可支持本地图像或者视频上传。其二，检测结果会进行动态标注，即显示边界框与置信度。其三，检测记录可一键导出成为结构化文件，格式为 CSV。保证系统响应时间稳定处于 1 秒以内，误检率控制在 15%以下。

整个技术路线注重理论和实践的结合，利用模块化设计保证每个环节有可追溯性以及可复现性，呈现了深度学习技术在吸烟检测领域的创新应用，也为计算机视觉工程的系统化实施提供了基础技术支持。

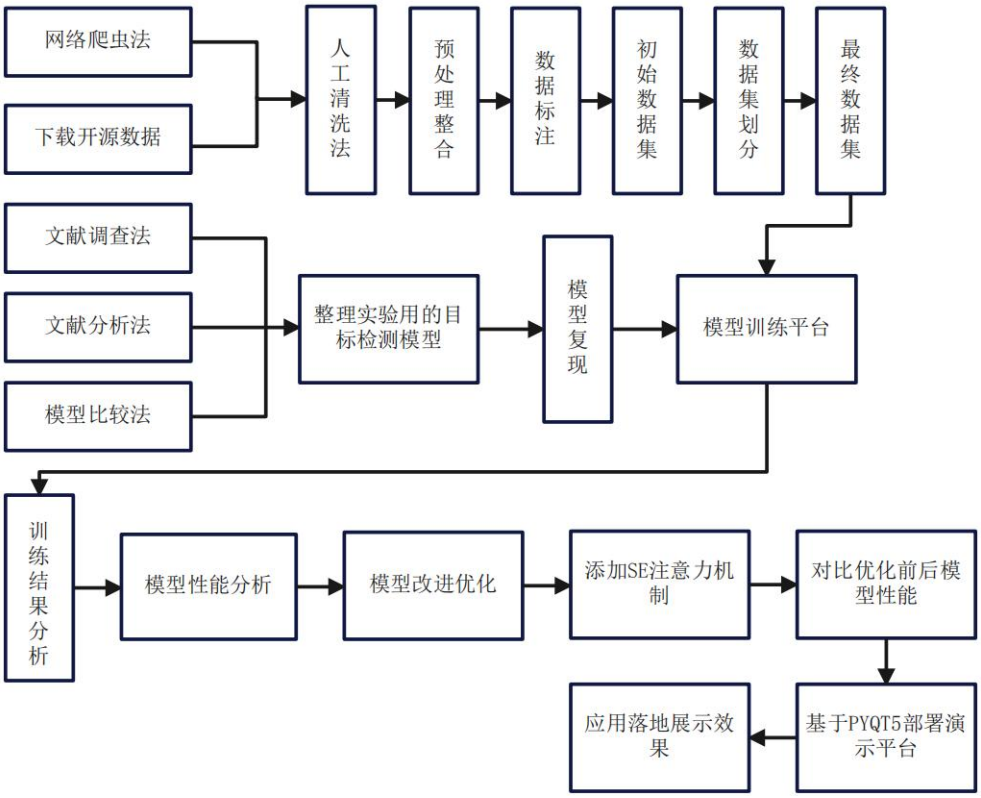

图 1-2 研究的技术路线图

1.5 论文章节安排

本论文设计并完成了一个基于 YOLOv11 的吸烟行为检测系统，以此提升对公共场所违规吸烟行为的自动化识别水平。

第一章是绪论，阐述了论文的研究背景以及意义、国内外研究的现状，还简单讲述了本文的研究内容与结构。

第二章为相关理论基础，着重介绍了基于深度学习的目标检测办法、卷积神经网络 CNN 以及 YOLO 单阶段目标检测技术，同时也简要介绍了三种注意力机制的原理和特性。

第三章主要对数据集以及吸烟检测模型的实现过程展开阐述，具体说明了本研究运

用的技术路线，介绍了吸烟行为数据集的采集方式以及标注情况，展示了数据的最终分布状况，同时也提到了基于 YOLOv11 算法构建的吸烟目标检测模型。

第四章聚焦于实验结果以及相关分析展开论述，其内容涉及多个方面，其中包含对实验环境以及训练参数的详细阐释。还说明了本研究采用的主要评价指标，对模型训练结果以及性能评估给予了说明，呈现出在本实验吸烟数据集上 YOLOv8s 和 YOLOv11s 的性能对比情形，并且开展了引入 SE 注意力机制前后的模型性能对比分析。

第五章针对吸烟行为检测系统的界面设计进行了较为全面的阐述，覆盖了界面功能模块的划分情况、操作流程、控件选型以及信号与槽机制的具体应用，以此全面呈现了该系统在可用性与交互性方面的设计思路以及实现效果。

第六章着重关注研究的结论与展望部分，一开始就对本研究得到的结论进行了较为全面的梳理概括，接着详细分析了当下所运用方法存在的不足之处，最后对未来的改进方向作出展望，希望依靠这些改进措施提高检测的精准度以及系统的实际应用价值。

2 相关理论基础

2.1 传统目标检测方法

传统目标检测算法流程示意图如图 2-1 所示，其核心技术环节可分解为：图像预调整、候选区域筛选、特征提取、特征匹配与分类。

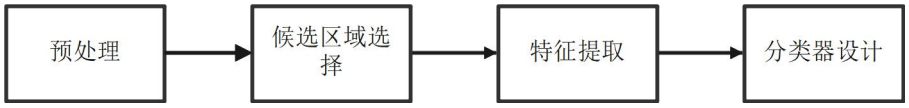

图 2-1 传统目标检测流程图

（1）图像预调整阶段主要是为了消除图像采集时引入的干扰噪声，借助灰度转换、尺度标准化以及降噪滤波等操作，提升目标区域较大的特征，为后续处理提供高质量输入数据，这种预处理机制可提高检测精度，还可以提高模型对不同成像条件的适应能力。

（2）在候选区域筛选阶段，采用多尺度滑动窗口方法，依靠对整幅图像进行遍历，生成潜在目标区域。由于目标尺度有不确定性，算法会动态调整窗口尺寸比例，保证目标候选区域可被完整覆盖，为后续特征分析提供有效的承载对象。

（3）在特征提取阶段，会综合运用一系列方法，如边缘检测算子、角点定位算法以及颜色空间分布统计等，以此来构建一个多维特征向量。该向量包括了纹理细节、几何形态、色彩分布以及空间关系等多个方面，借助这种多模态特征融合的方式，可相对全面地描述目标的特性。

（4）在针对特征进行比对以及开展决策的阶段之中，支持向量机 SVM 可充当核心的分类器角色，它是依靠计算特征向量之间的相似度这种方式来实现目标匹配的。分类器会给出置信度评分，根据这个评分就可判断候选区域的目标存在状况以及具体的类别归属。

传统的检测方式存在着两个关键的瓶颈之处，一方面是采用串行处理架构，这导致计算效能比较低，因为全局穷举搜索策略会产生数量众多的冗余候选区域，增加了计算的负载，很难契合实时检测以及大规模场景的应用需求。另一方面是手工设计的特征表达与决策模型在表征能力上存在一定的局限，当面对复杂场景变化、目标姿态多样以及光照条件波动的情况时，这种固定模式的特征提取与分类机制难以保证检测的鲁棒性，就会出现模型迁移到新数据域时性能衰减的问题[39]。

2.2 基于深度学习的目标检测方法

2.2.1 卷积神经网络

卷积神经网络作为深度学习领域颇具代表性的架构，其结构化设计呈现于图 2-2。各个功能层协同合作，以此达成特征提取以及模式识别任务。网络前端存在输入层，该层承担接收原始图像数据并开展标准化预处理的职责，依靠归一化操作消除量纲差异，

为后续处理给予规范输入。卷积层是核心的特征提取单元，它运用局部感受野机制开展卷积运算，可有效地捕捉图像的空间结构特征，借助层级化的特征抽象过程，它会逐步生成带有高阶语义信息的特征表示。池化层借助下采样操作达成特征降维的目的，在下采样过程中保留了关键信息，并且压缩了参数规模，提升了模型的计算效率。处于末端位置的全连接层会把多维特征向量映射至预测空间，与 Softmax 函数协同工作来输出类别概率分布，以此达成从特征到决策的转变。

该架构在设计上有许多优势，输入层凭借标准化处理方式，以此提升数据的一致性。卷积层采用稀疏连接以及参数共享机制，提高特征提取效率。池化层依靠空间汇聚操作，提高了模型的鲁棒性。全连接层实现了从特征到预测的非线性映射。这种层级化处理模式，使网络可逐步构建从低级边缘特征到高级语义特征的抽象表示，为复杂视觉任务提供有效解决办法。

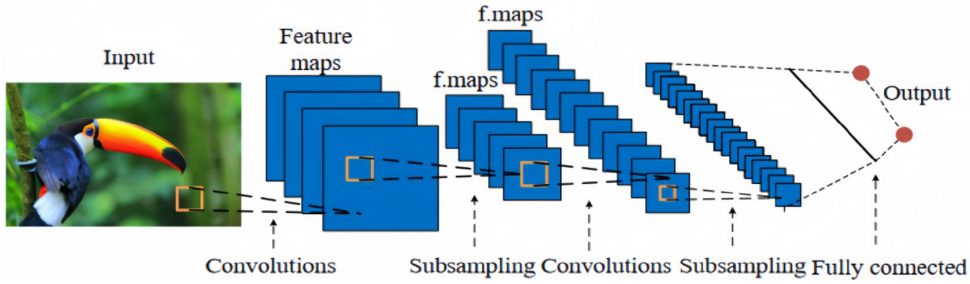

图 2-2 卷积神经网络的基本结构

（1）输入输出层

卷积神经网络当中的输入输出层是核心架构单元，承担着数据交互以及预测输出的关键职能。输入层作为网络开始的处理环节，要采集原始数据并传递到卷积层来进行特征提取，每一个输入节点都对应着特定维度的数据特征。输出层作为网络的终端决策部分，根据网络学习到的深层特征生成预测结果，其节点配置和具体任务的需求维度严格匹配。

在模型开展训练的阶段之中，输出层所产生的预测结果会和真实标签利用损失函数来进行差异方面的量化，形成误差信号。这个信号借助反向传播机制逐层次地进行传递，以此来驱动网络参数作出优化调整，达成模型性能的迭代优化。在数据接入阶段的输入层，一般需要施行标准化预处理操作来提高模型训练的效率，具体覆盖以下这些核心步骤：

归一化处理会运用最小-最大缩放或者 Z-score 标准化之类的方法，把原始数据映射到统一量纲的空间之中，以此消除特征尺度差异给模型训练带来的影响。中心化处理是要计算各维度特征的均值，然后执行逐样本的均值消减操作，让特征分布中心与零点对齐，提高数值的稳定性。白化处理借助协方差矩阵分解以及特征值映射，消除特征之间的线性相关性，提升特征的独立性。这个过程借助奇异值分解算法达成矩阵特征空间的解耦重构，这样一种集成化的预处理机制，给卷积神经网络提供了规范化的输入特征，切实提升了模型的特征学习能力以及收敛速度。

（2）卷积层

卷积层作为图像特征提取的关键部分，是核心模块之一。它借助配置多个卷积核来达成图像特征的分层学习，每一个卷积核就如同小型矩阵滤波器，会在输入图像上开展系统性扫描，按照从上到下、从左到右的空间遍历规律来进行。在扫描时，卷积核会和图像局部区域感受野做加权求和的点积运算，算出该位置的输出特征值。这种局部感知的机制让卷积层可以有效地捕捉图像的空间结构信息，卷积运算之后所生成的特征图尺寸，可依靠专门的计算公式（见式 2-1）准确推导出来，此公式全面考虑了卷积核尺寸、步长以及填充参数所带来的影响。

$$Q=\frac{N+2*P-F}{S}+1 \tag{2-1}$$

在卷积神经网络的结构里，特征图的空间维度 Q 受到输入图像尺寸 N、边缘填充像素数 P、卷积核维度 F 以及滑动步长 S 等多个因素的共同作用而得到调控，对于各参数的具体作用原理如下：

卷积核的二维扩展范围 F 可决定其局部感知区域的大小情况，若采用较大尺寸的卷积核，则可较为有效地捕捉输入数据里更为广泛一些的空间上下文信息。然而较小尺寸的卷积核主要侧重于提取局部的细微特征，依靠这样来提高对细节信息的捕捉能力。

步长参数 S 所代表的含义是卷积核于输入矩阵上的位移间隔情况，其取值会对输出特征图的分辨率产生直接的作用。要是将步长设置得比较大，那么特征图的空间维度会受到压缩，使得计算复杂度降低。而当步长较小时，会借助密集采样的方式来维持特征图的分辨率，保留更多的空间细节内容。

填充操作会在输入图像的边缘增添 P 层虚拟像素边界，以此解决卷积运算期间空间维度衰减的问题，此边界扩展机制维持了特征图尺寸的稳定性，而且为边缘区域的特征提取给予了完整的感受野支持。

在卷积操作里，输入通道数以及输出通道数属于核心参数。输入通道数决定了特征提取器的数量规模，而输出通道数则决定了特征映射的维度大小。这样一种层级化的通道配置方式，构建起了从初级图像特征朝着高级抽象表征的映射途径，并且其连接方式对于神经网络的信息传递效率会产生较为深刻的影响。

（3）池化层

下采样层（池化层）是卷积神经网络里关键的结构组成部分，在维持图像本质特征的情形下，借助空间降维操作可有效地抑制模型过拟合风险，还可以让网络有对目标微小位移以及形态畸变的鲁棒性。这一层一般是紧跟在卷积层后面的，其核心运算机制是针对输入特征图的局部区块开展特征汇聚操作，把空间邻域内的信息压缩成单一统计量。

典型汇聚策略主要有两种主流方法，分别是最大汇聚也就是 Max Pooling，以及平均汇聚即 Average Pooling。

最大汇聚会把输入特征划分成彼此不重叠的矩形网格，于每个局部窗口里挑选最大值当作输出特征，如图 2-3(a)所示，当输入是 4×4 特征矩阵时，运用 2×2 窗口以及步长 2 的采样方式，遍历之后输出 2×2 降维特征图。此操作借助保留最突出响应特征，提高了网络对判别性信息的提取能力。

平均汇聚采用同样的分区策略，不过是计算局部窗口内所有元素的均值来作为输出，

如图 2-3(b)所示，在相同输入条件下，2×2 窗口以步长 2 滑动，最终生成 2×2 特征图。这种汇聚方式借助对空间邻域的信息进行平均，让输出对输入信号的微小偏移以及局部形变有更强的鲁棒性，提升了模型对目标位置变化的适应能力。

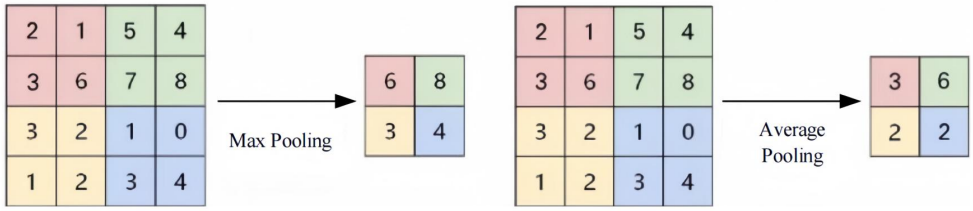

a) 最大池化　　b) 平均池化

图 2-3 最大池化与平均池化

（4）全连接层

图 2-4 呈现出全连接层的网络架构状况，此层内所有神经元呈现出全互联的状态，依靠可学习的权重参数达成信息交互以及特征融合。深层网络所提取的高维特征在经过全连接层展平之后，转变为单一维度的向量输入到非线性决策模块之中，最终借助 Softmax 函数或者支持向量机来完成多类别概率预测，选取最大概率值所对应的类别当作预测结果。

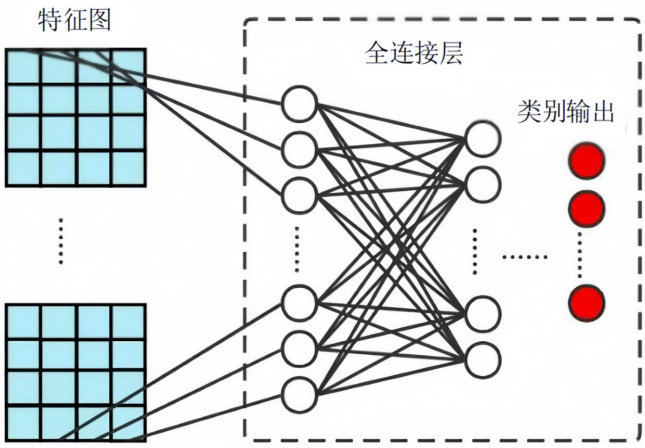

图 2-4 全连接层示意图

在全连接层中，为了提高模型对于复杂特征的表征能力，一般会引入非线性激活函数来对深层特征做映射变换。这个非线性转换过程可以式的形式来表达，随着激活函数的引入，网络拥有了对非线性决策边界的建模能力，提高了模型的表达能力。

$$y_{w,b}(x) = f(w^T x) = f\left(\sum_{i=1}^{n} w_i x_i + b\right) \tag{2-2}$$

在神经网络的全连接层架构里，输入向量 x_i 体现着该层的输入数据，输出值借助函

数 $y_{w,b}(x)$ 来呈现，w_i 权重系数以向量形式呈现，偏置项 b 是此层的关键参数之一。依据公式(2-2)，全连接层首先会针对输入数据执行线性变换操作，随后运用激活函数来引入非线性特性，最终得出输出结果，该公式完整地描绘了输入数据在经历权重矩阵运算以及偏置调整后，借助非线性激活函数处理获得最终输出的整个过程。

卷积神经网络的训练流程主要是由正向传递和反向优化这两个阶段所组成。在正向传递阶段，首先会把输入数据一层一层地传递到输出端，在这个过程中会依次进行卷积运算、下采样处理以及激活函数映射，最终达成原始数据的特征转换，形成带有语义信息的抽象表征。当预测输出和期望标签出现偏差的时候，反向优化阶段就会启动误差回传机制，借助链式法则把残差信息从深层反馈到浅层，推动网络参数迭代更新以接近最优解。这个过程依据损失函数的梯度信号，运用反向传播算法来调整各层权重矩阵，依靠迭代优化让模型输出接近真实分布，同步提高数据拟合精度与泛化性能。完整的卷积神经网络训练流程示意图如图 2-5。

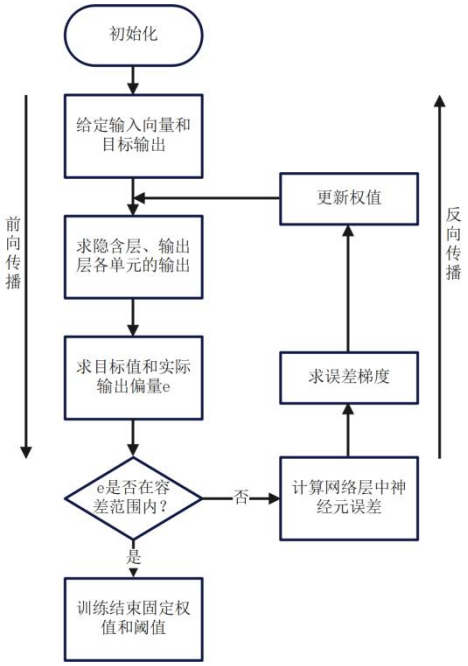

图 2-5 卷积神经网络训练过程

2.2.2 YOLO 单阶段目标检测

Joseph Redmon 团队在 2016 年提出了 YOLO 框架，其初始版本被命名为 YOLOv1，此框架的核心创新点是把目标检测任务统一构建成神经网络回归问题。该模型借助单次前馈计算就能同时完成目标定位以及分类预测，完全舍弃了传统多阶段检测流程里的繁杂处理步骤。实验显示，这个架构在维持检测精度的情况下，达成了每秒 45 帧的处理速度，这样有突破性的效率表现当时在学术界引起了广泛的关注。

YOLO 模型运用回归策略来达成目标检测[40]，在复杂的视觉任务里呈现出高效的处

理能力，它和传统检测范式不一样，传统检测范式依靠多尺度滑动窗口去遍历图像区域，还使用分类器逐个验证候选区域，而 YOLO 模型是依靠单阶段回归策略直接预测目标的位置以及类别属性。其核心机制包括三个同步的过程：先是依据全局特征映射来预测目标的中心坐标以及尺寸参数，生成包含完整目标的边界框，接着借助多分类概率输出确定目标所属的语义类别，最后经由端到端的优化框架达成检测精度与推理效率的平衡。

与主流的两阶段检测模型例如 Fast R-CNN 系列，以及单阶段检测器像 RetinaNet 和 SSD 相比，YOLO 算法在检测精度、推理速度以及单次前馈检测效能等方面都呈现出优势，这种突破主要是因为三个创新性改进：一是借助单次全局预测达成实时检测能力，完全摒弃了区域提议阶段的计算冗余。二是输出包含完整目标的紧致边界框，有效抑制了背景噪声对检测结果的影响。三是强大的特征表征学习能力让模型可自适应优化目标语义表达，在复杂场景中也能保持稳定的检测性能。这些技术特性使 YOLO 算法成为目标检测领域有里程碑意义的技术方案，推动了实时检测系统在智能监控、自动驾驶等领域的实际应用，图 2-6 系统说明了 YOLO 算法的网络结构图，图 2-7 是 YOLO 算法的检测过程流程图。

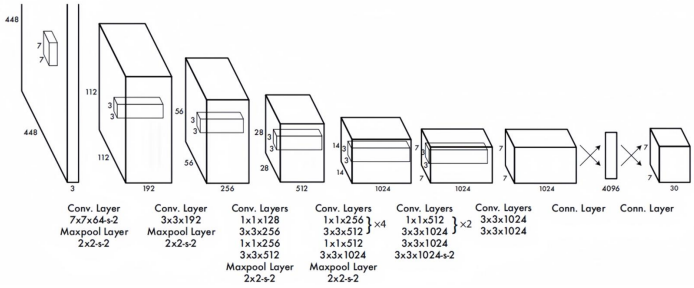

图 2-6 YOLO 算法的网络结构图

借助观察图 2-7 可发现，YOLO 检测框架在设计理念方面借鉴了 GoogLeNet 的核心架构，其检测过程依照多阶段处理模式来进行，该模型依靠级联卷积运算以及空间下采样操作以实现特征提取，最终借助全局特征映射来达成检测预测。网络前端利用多层卷积核对图像的多尺度特征给予提取，再联合最大池化操作逐步压缩空间维度，最终在全局特征层完成目标位置的回归以及类别的判断。这种端到端的检测架构和传统检测模型的多阶段处理机制有着较大差异。

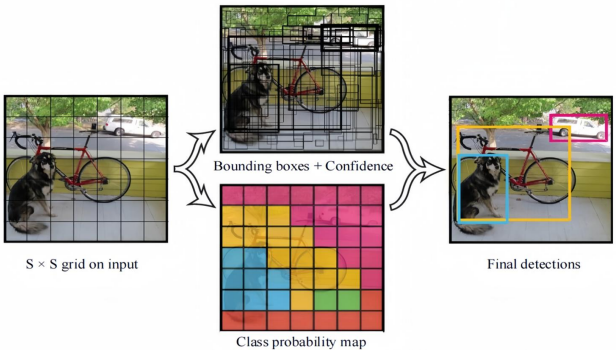

图 2-7 YOLO 算法检测过程流程图

YOLO 检测模型会把输入图像离散化成 S×S 的均匀网格阵列，在这个过程中每个网格单元独自负责预测其空间区域里目标的任务，依靠同步输出目标边界框坐标以及类别概率分布，实现单次网络前馈就能完成全图检测任务。具体实现时，每个网格单元要生成 B 个候选预测框，每个预测框由一个 5 维参数向量和一个 C 维类别概率向量共同来描述。模型最终输出的是维度为 S×S×(5B+C)的三维张量结构，该架构依靠网格化空间采样与候选框预测机制共同发挥作用，有效地建立起目标类别与空间定位的映射关系，预测框的类别置信度评估采用特定的计算模型，其数学表达形式见式(2-3)所示。

$$Conf = P_{object} * IoU_{pred}^{truth} \tag{2-3}$$

其中，P_{object} 描述的是预测框里是否有目标，其中当 P_{object}=1 时表征预测框中存在目标，当 P_{object}=0 时代表预测框中检测到没有目标。

在检测效率这个方面，YOLOv1 模型相比 Faster R-CNN 有着超过 6 倍的性能提升，它的最高处理帧率可达到 150FPS，最低推理延迟被压缩到了 25ms。不过这个初代模型有一定缺陷：每个网格单元只支持输出 2 个预测框并且类别是共享的，这使得小尺寸目标检测的精度出现了下降，对于非常规视角目标的泛化能力也存在一定的局限。小目标检测问题是 YOLO 算法的技术瓶颈，是本文重点研究的方向。

自 2015 年 YOLO 算法开创了单阶段检测范式之后，它的技术体系不断地从 YOLOv1 发展到 YOLOv12。YOLOv1 创新性地提出了单阶段检测架构用以替代传统的两阶段范式，凭借运用全连接层直接回归边界框坐标，不过缺少候选区域生成机制，这使得模型在训练初期收敛比较险阻。面对如此状况，YOLOv2 引入了锚框机制，其目的在于促使网络收敛速度加快，同时对多尺度特征融合策略给予优化，以此提升模型针对小目标的检测能力。YOLOv3 搭建了残差网络，同时结合了特征金字塔结构，实现了浅层细节和深层语义之间的跨层交互。YOLOv4 运用空间金字塔池化模块来对感受野给予扩展，在保持推理效率的同时提高了对上下文信息的捕获能力。YOLOv5 将高效通道注意力机制引入，借助自适应特征校准的方式来提升检测的精度。

YOLOv6 特别注重模型轻量化方面的需求，凭借运用神经架构搜索技术实现了计算量的压缩。YOLOv7 推出了跨尺度信息交互模块，在提升小目标以及复杂场景下的检测鲁棒性方面起到了切实有效的作用。最新的 YOLOv8 借助深度可分离卷积构建起高效骨干网络，并且引入了任务对齐学习机制，在维持检测速度优势的情况下提升了模型泛化性能。

YOLOv9 在 YOLOv5 的基础上进行了优化，延续了实时检测优势，创新地引入了可编程梯度信息(PGI)机制，依靠优化输入特征表征提升了梯度有效性，提高了网络参数更新效率。同时设计广义高效层聚合网络(GELAN)，采用轻量化架构在维持检测精度前提下降低计算复杂度，实现模型效能与资源消耗的平衡优化[41]。

YOLOv10 采用了与 YOLOv8 相同的四段式结构框架，并在细节组件方面进行了创新和优化，它引入了 SCDown 空间通道解耦模块、PSA 局部注意力机制以及大核卷积结

构，凭借这些改进，YOLOv10 在保持计算效率的有效提高了特征表达能力，另外检测头采用双模态轻量化分类架构进行训练，并配合双标签匹配机制，省去了 NMS 后处理步骤，实现了检测效率与性能的最佳平衡[42]。

YOLOv11 继承了前代版本的技术优势，并且进行了深度优化，实现了检测速度与精度的双重提升。该模型引入了自适应特征融合机制，在保持模型复杂度的提高了多尺度目标检测能力，其创新性的架构设计和训练策略优化，让检测性能相比前期版本有了较大提升[43]。

YOLOv12 模型的核心改进是引入区域注意力机制，该机制采用十字形窗口自注意力计算框架，分别在水平维度和垂直维度构建注意力分布，凭借对特征图进行空间分块处理，在保持有效感受野的同时降低计算复杂度。鉴于该模型尚未经过充分实践验证，本研究选择以 YOLOv11 算法为基础框。

2.2.3 注意力机制

卷积神经网络里的注意力机制设计的灵感来源于生物视觉注意力系统，这一系统是人类在漫长进化进程中所形成的独特的视觉信息处理机制。当人类去观察某个场景的时候，视觉皮层会先凭借快速的全局扫描来定位较大性区域，之后再集中认知资源针对这个区域展开精细化的分析，同时抑制其他非关键信息带来的干扰。这样的选择性聚焦机制被抽象成了两种注意力范式，分别是硬注意力和软注意力，

硬注意力遵循二元选择机制，可清晰地划分出关注区域与非关注区域，它的决策过程有离散性以及随机性，并且不可导，需要借助强化学习框架来进行优化。

与之不同的是，软注意力采用连续型概率分布，使用[0,1]区间内的权重系数来表示各个区域的关注强度，其关注点可以分布在空间或者通道维度，借助前向传播就能生成注意力分布，有确定性且可导，可顺利地融入神经网络架构，借助梯度下降算法进行端到端优化[44]。

在深度卷积网络里，注意力机制主要呈现为两种模式：通道注意力和空间注意力，2015 年 DeepMind 团队推出的 STN（Spatial Transformer Networks）模型，堪称空间注意力机制的典型代表。它借助自主学习输入数据的几何形变，达成自适应的空间变换以及特征对齐，提高模型对于空间不变性的鲁棒性，提高分类等任务的性能表现。该模块的创新性架构如图 2-8 所示：

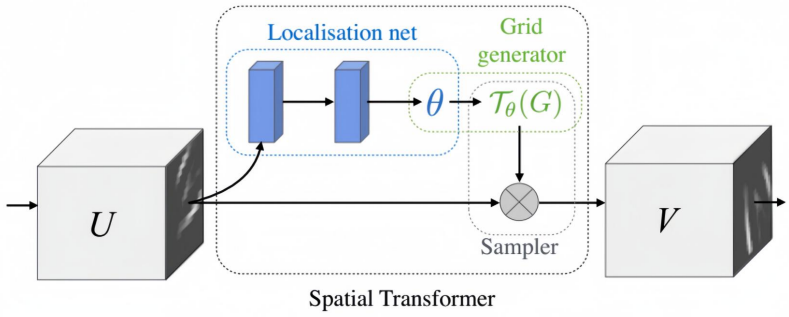

图 2-8 STN 模块示意图

2017 年举办的 ImageNet 大规模视觉识别挑战赛里，有一个成功引入通道注意力机制并夺冠的模型，此模型名为 SENet。它的核心架构是由 Squeeze-and-Excitation 单元组成，其创新之处在于 SE 注意力模块的设计，该模块凭借显式建模通道间的相互依赖关系，能自适应地对各通道的激活强度加以调整，以此实现对关键特征通道的强化以及对冗余通道的抑制。SE 模块的结构示意图如图 2-9 所示，本研究将引入 SE 注意力机制来提升系统对烟支的识别准确度等方面。

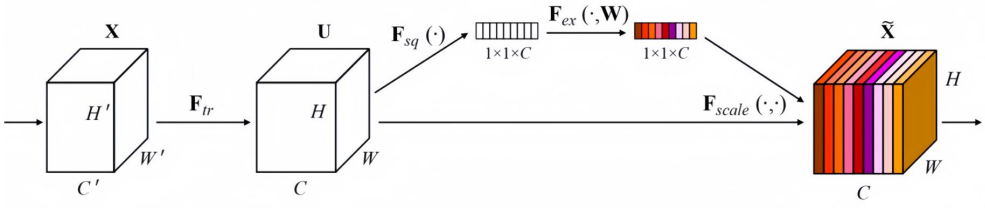

图 2-9 SE 模块示意图

近年来也有研究人员开始探索将空间注意力与通道注意力相结合的混合注意力机制，其中具有代表性的工作是 2018 年提出的 CBAM 模型（Convolutional Block Attention Module），该模型的结构示意图如图 2-10 所示。

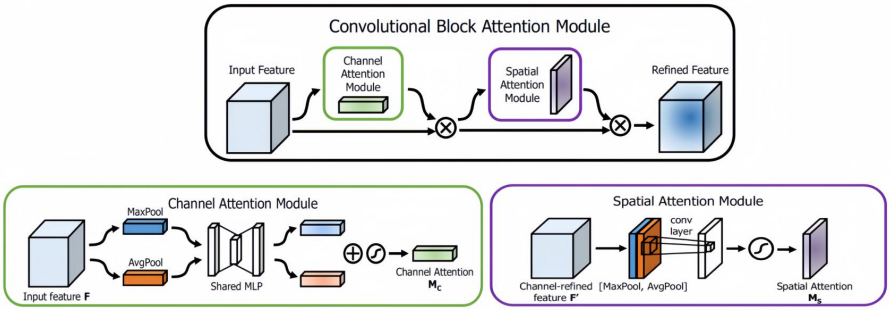

图 2-10 CBAM 模块示意图

CBAM 模块通过分别生成通道注意力图和空间注意力图，然后将两者进行逐元素相乘，以实现特征的自适应调整和优化。

2.3 本章小结

在这一章节之中，系统且全面地阐述了本研究赖以依托的核心理论以及技术框架。首先较为简要地介绍了传统目标检测方法所拥有的检测流程，紧接着就将关注点聚集在了深度学习领域所发生的技术革新方面，着重对卷积神经网络的多级特征提取原理展开详细剖析，详尽叙述 YOLO 算法系列的核心架构演进过程，同时还较为简要地介绍了几种注意力机制。

依据前面所进行的这些分析，本研究提出将 YOLOv11 算法当作基准模型，以创新性的方式嵌入 SE 注意力机制，借助自适应特征通道校准来提高模型检测精度，构建出有鲁棒性的目标识别体系，此技术路线有效地整合了前沿算法架构与注意力提高策略，可为检测性能的优化提供相应的理论支撑。

3 数据集和吸烟检测模型的实现

3.1 吸烟行为数据集制作

3.1.1 数据集采集

本研究选取的实验数据来源，主要是从 Kaggle 平台获取的公开吸烟行为图像数据集（吸烟行为数据集部分示例如图 3-1 所示）。此数据集包含了众多在现实场景里采集得到的图像，有一定的代表性以及多样性，可对吸烟行为检测模型在较复杂环境中的建模和评估工作起到有效的支撑作用。图像采集的条件较为丰富多样，其中包含了白天、夜晚、强光以及逆光等各种各样不同的光照情境，其覆盖范围也较广，覆盖了室内环境，像办公室、教室以及楼道等地方，以及室外环境，如街道、公园以及楼宇周边等地，这充分呈现出在实际应用里视频监控系统有可能会面临的多样检测背景。

数据集中吸烟者个体特征差异明显，涉及不同年龄、性别以及穿着风格的人群，图像里烟支数量不同，有的只含一个目标，有的含有多个目标，这使得检测任务的复杂程度有所增加。部分图像存在一些干扰因素，如吸烟目标尺寸较小、人体姿态变化幅度大、背景杂乱或者目标有部分被遮挡等情况，提升了模型对于真实应用场景里不确定性因素的适应要求以及鲁棒性要求。

为了保证模型训练可有效进行并且最终性能有可迁移特性，在本文中于数据预处理阶段针对原始图像开展了人工筛选以及清洗工作。具体操作涉及多方面内容：首先要将那些分辨率处于较低水平、光照存在严重不足情况、有严重遮挡现象或者不存在吸烟行为的冗余图像给予剔除，接着要去除那些由于标注错误或者数据重复而有可能对训练质量产生影响的异常样本，以此来保证最终用于模型训练以及验证的数据拥有较高的图像质量以及标注准确性。

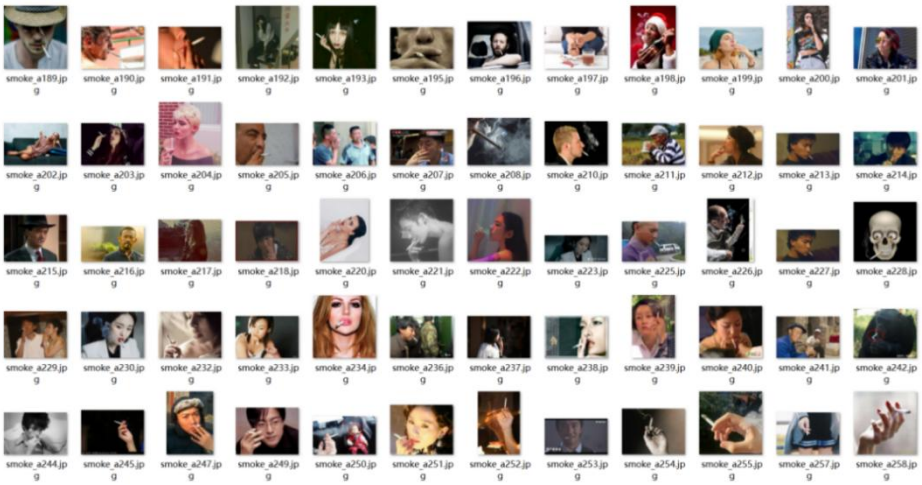

图 3-1 数据集示例图

3.1.2 数据集标注

由于本研究基于监督学习框架开展烟支手势目标检测，需对训练图像中的目标区域进行精细化标注与类别标记。具体实施过程中，采用 labelImg 标注工具对 783 幅图像进行人工标注作业，即通过矩形框逐帧框定烟支目标，并统一赋予"smoke"类别标签。标注过程中生成的标签种类、目标框中心点的坐标以及尺寸信息将自动保存为 TXT 格式文件。标注时首先要采用矩形框将候选烟支区域进行标注，然后再将标注的地方法打上烟支标签[45]。图 3-2 展示了标注工具的操作界面。

图 3-2 使用 LabelImg 工具对烟支目标进行标注

每幅图像所对应的标签文件均以.txt 为后缀，其文件内容有着特定格式，详细记录了目标的类别编号、边界框中心点经过归一化处理后的坐标，以及目标框的宽度与高度等信息。这些信息可方便在训练过程里对目标进行准确识别与定位，提升模型的检测精度以及鲁棒性。

<class_id><x_center><y_center><width><height>

其中，class_id 代表目标类别的索引；x_center 代表目标的中心点在图像中的 x 坐标，归一化到[0,1]之间,计算公式由式(3-1)所示；y_center 代表目标的中心点在图像中的 y 坐标，归一化到[0,1]之间,计算公式由式(3-2)所示；width 代表目标框的宽度，归一化到[0,1]之间，计算公式为 3-3 所示；height 代表目标框的高度，归一化到[0,1]之间，计算公式见式(3-4)所示。

$$x_center = \frac{bbox_x + bbox_width/2}{image_width} \tag{3-1}$$

$$y_center = \frac{bbox_y + bbox_height / 2}{image_height} \tag{3-2}$$

$$width = \frac{bbox_width}{image_width} \tag{3-3}$$

$$height = \frac{bbox_height}{image_height} \tag{3-4}$$

图 3-3 则展示了标记完成后生成的 TXT 格式示例。

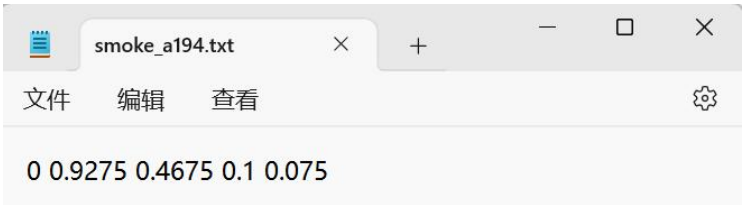

图 3-3 标记完成后生成的 TXT 格式示例

当获取到所有图片的标注文件后，要把数据集依照一定比例划分成训练集、验证集以及测试集这三部分。一般会采用随机抽样的策略，把总样本量中的 80%划分给训练集，10%当作验证集，剩下的 10%作为测试集，最终构建而成的检测数据集含有 783 张烟支图像，其中标注了 816 个有效边界框，具体情况如表 3.1 所示。在设计测试集的时候特意引入了复杂场景样本，这些样本包含不同光照条件、背景干扰以及噪声水平的吸烟场景，这样的设计有利于提升模型的特征提取鲁棒性以及场景泛化能力，保证算法在多样化环境里可保持稳定的目标检测性能。

表 3.1 数据集核心信息

数据集	图片总数	标注框总数
train	626	652
val	78	80
test	79	84
总计	783	816

3.1.3 数据的最终分布

在图 3-4(a)里，水平轴所呈现的是经过归一化处理之后目标框中心点的水平坐标数值，垂直轴对应的是垂直坐标数值。散点的分布状况可反映出中心点的位置特征，当着色深度有所增加时，这意味着该区域目标框的密度在变大，依靠统计得出的结果说明，目标框集中分布于图像的中心区域。

在图 3-4(b)里，横轴所代表的是目标框归一化之后的宽度数值，而纵轴代表的则是归一化后的高度数值。相同的是，颜色越深意味着该尺寸的目标出现的频率也就越高，统计得出的结果说明，本数据集中大多数目标的尺寸都比较小，这属于小目标检测任务所有的一种特征。

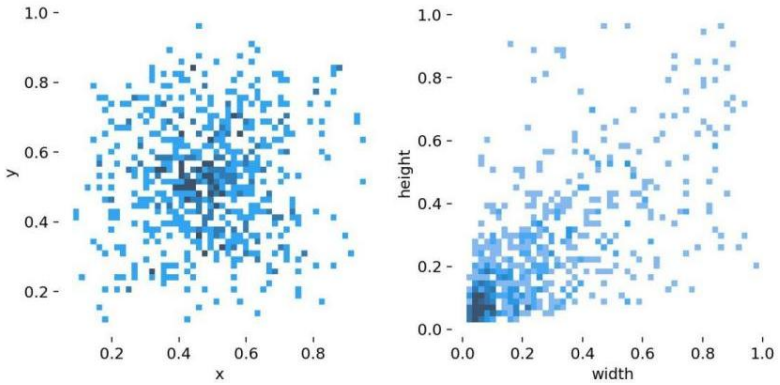

(a) 中心点分布　　(b) 尺寸分布

图 3-4 目标框信息散点图

图 3-5 所展示的三维热以此来矩阵借助颜色梯度编码方式，直观呈现出目标属性的多维联合分布特点。其中位置分布有着十分突出的中心聚集现象，目标框中心点高度集中于图像中心部位，这和吸烟行为多在画面主体区域发生的实际情形高度相符；宽度分布在不同水平位置维持均匀状态，未出现位置相关性方面的变异；宽高比分布说明数据集以微小目标作为主要部分，数据簇密集于左下角区域。此矩阵为分析目标属性关联性以及优化检测模型提供了关键依据，后续可依据这些分布特征设计锚框策略并改进数据提高方案，以此提升模型对多尺度目标的检测能力。

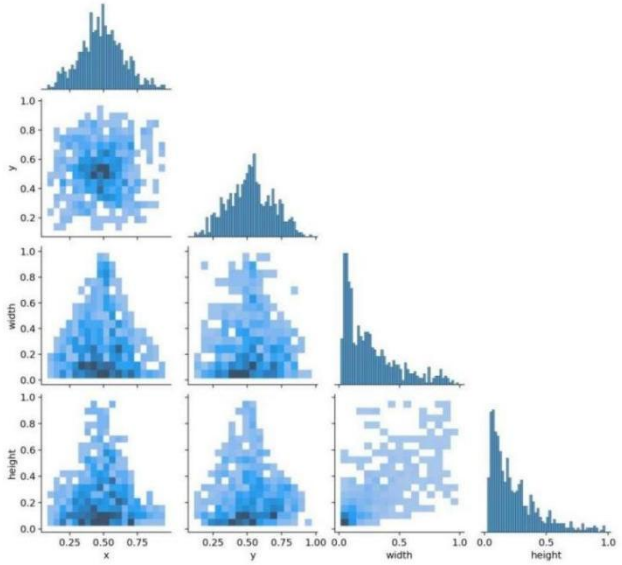

图 3-5 标注框属性联合分布图

3.2 基于 YOLOv11 的吸烟目标检测模型

YOLOv11 这款单阶段检测模型是 2024 年由研究团队基于 Ultralytics 框架所研发出来的，在同类型模型中处于较为领先的位置。它的设计遵循了 YOLO 算法家族的关键理念，将目标检测任务转化为统一的回归问题，实现了边界框坐标以及目标类别的同步实时预测，在保持检测精度的同时提高了推理速度。依据模型参数量级的差异情况，YOLOv11 被划分成 n/s/m/l/x 这五种规格型号，它的架构运用四段式布局方式，包含输入层、骨干网络、特征融合模块以及检测头这四个核心组件。

YOLOv11 的骨干网络整合了 Conv 基础模块、改进后的 C3K2 特征提取单元、空间金字塔快速池化组件 SPPF 以及跨阶段部分聚合模块即 C2PSA，具体情况如图 3-6 所示。其中 Conv 模块负责执行特征下采样以及标准化处理工作，C3K2 单元借助自适应卷积核与通道解耦策略来提高特征表达效果，SPPF 组件达成多尺度特征融合目的提升目标识别的鲁棒性，C2PSA 模块则依靠特征图分割与信息流优化机制，在减少计算量的同时提高检测性能。特征融合模块运用自底向上的单向特征金字塔网络 FPN，达成浅层纹理信息与深层语义特征的跨尺度融合，切实提高特征表征能力，检测头采用无锚点设计，依靠直接回归目标位置坐标来实现预测，摒弃了传统锚框预定义范式，有效简化了检测流程。

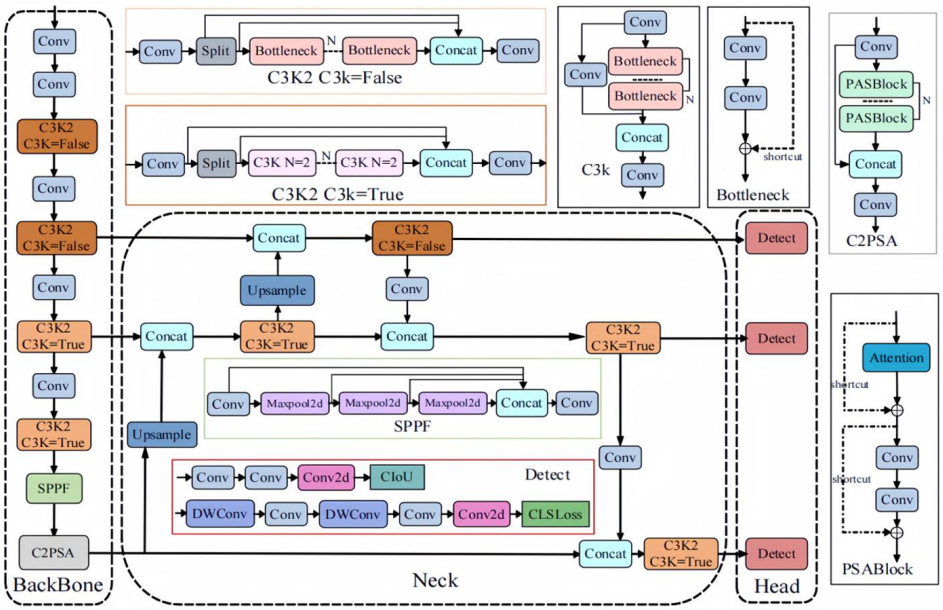

图 3-6 YOLOv11 模型结构

在吸烟行为检测这项任务当中，模型需要拥有高精度的目标识别能力，并且要在复杂背景以及多样姿态的情况下，保持较强的鲁棒性与实时性。YOLOv11 属于当前最新的单阶段目标检测模型，它依靠精简高效的架构设计以及强大的特征提取能力，特别适合吸烟目标这类小目标、容易被遮挡、形态变化多端的检测场景。它无锚点的检测头设计避免了锚框不匹配的问题，简化了模型部署流程，提升了检测的泛化能力，十分契合吸烟行为检测在边缘计算设备以及实际视频监控中的应用需求。

本研究选用 YOLOv11 当作基础模型框架，于其 Neck 部分的多尺度特征融合环节里引入 SE 注意力机制，以此提升模型对于关键信息通道的感知能力。SE 模块可根据不同通道的情况来自适应地分配权重，借助这种方式强化与吸烟行为相关的特征响应，同时抑制因冗余信息而产生的干扰，提高模型对吸烟目标的识别精度以及稳定性。凭借在维持原有高效结构的基础上融合注意力机制，该模型在多数环境下仍可实现高精度、低延迟的吸烟目标检测，契合实际场景对智能监控的需求。

3.3 本章小结

本章围绕吸烟检测模型的实现展开阐述，从数据集构建以及模型设计等方面进行详细说明。首先介绍吸烟行为数据集的制作过程，包括数据采集的来源、标注的规范以及数据的分析等方面。数据分布状况说明目标框集中于图像的中心区域，而且以小尺寸居多，这为后续模型的优化奠定了基础，最终构建了包含 783 张图像、816 个标注框的数据集，依照 8:1:1 的比例把它划分成训练集、验证集和测试集，形成适配模型训练的标准化数据。

在模型构建这个环节当中，选择 YOLOv11 当作基础框架，面对小目标检测存在的难题，在骨干网络里面嵌入 SE 注意力模块，以此强化关键特征的响应，依靠对比实验来验证改进所取得的成效。并且基于 PyQt5 开发可视化系统，实现图像或者视频检测以及结果导出等功能，保证系统响应时间和误检率可符合实际需求。这一章借助模块化设计以及实践验证，给吸烟检测任务提供了一套系统化的解决办法。

4 实验结果与分析

4.1 实验环境

4.1.1 软硬件配置

本研究在 Windows 11 操作系统环境下实现算法，运用 Python 编程语言并结合 PyTorch 深度学习框架构建模型体系，为提高计算效率，系统整合了 CUDA 并行计算架构以及 cuDNN 深度神经网络加速库来进行优化加速。实验平台详细的配置参数规范见表 4.1，其中涉及了硬件环境、软件版本以及关键库文件设置等全面信息。

表 4.1 实验环境配置表

软硬件	配置
操作系统	Windows 11
深度学习框架	Pytorch
集成开发环境	PyCharm2021
CPU	AMD Ryzen 7 5800H with Radeon Graphics
GPU	NVIDIA GeForce RTX 3070
可用显存	8192MiB
编程语言	Python
图形加速器	CUDA11.1
部署框架	PYQT5

4.1.2 模型训练策略

在此次研究当中分别对三个模型展开了训练，第一个是原始的 YOLOv11s 模型，第二个是 Ultralytics 团队应用最广泛的 YOLOv8s 模型，第三个则是在原始 YOLOv11s 模型基础之上引入了 SE 注意力机制后得到的改进模型 YOLOv11s-SE。引入注意力机制可提高模型对于关键区域特征的感知能力，提升吸烟目标检测的准确性，在处理小目标或者特征模糊图像时可提高其鲁棒性。

从表 4.2 可看出，在训练进程当中，全部的输入图像都被统一调整缩放至 640×640 的分辨率，以此来保证模型输入方面的一致性。每一个批次会处理 8 张图像，考虑到训练效率的同时也兼顾了显存的使用情况。模型训练的总轮数设定为 200 轮，来让网络可

以充分地学习数据特征。优化器选择的是随机梯度下降也就是 SGD 算法，卷积层默认使用 SiLU 激活函数，提升网络的非线性建模能力，并且缓解梯度消失的问题。初始学习率设置为 0.01，在训练过程里会依据验证集的表现进行动态衰减，以此提高模型的稳定性以及收敛速度。

表 4.2 训练参数设置表

参数名称	参数值	说明
图像尺寸	640×640	训练/验证时的输入分辨率
批次大小	8	每批训练样本数
总训练轮次	200	完整遍历训练集次数
优化器	SGD	随机梯度下降优化算法
激活函数	SiLU	卷积层后默认使用的激活函数
初始学习率	0.01	训练开始时的学习率值
学习率调整策略	动态衰减	根据验证损失自动降低学习率

4.2 评价指标

性能评估指标是剖析各类算法模型效能的关键依据，在目标检测领域，要构建多维度评价体系来全面评估算法表现[46]。此实验运用精确率（Precision，P）、召回率（Recall，R）、平均精度（AP）、平均精度均值（mAP）来衡量模型的检测性能，借助 FPS 来衡量模型的推理速度[47]。

（1）检测速度 FPS：指的是模型每秒可处理的图像数量，依靠这个指标可以看出模型在实时性能方面的表现情况。当 FPS 值越高时，也就意味着模型处理图像的速度更快，可更迅速地做出响应，FPS 是评估算法模型实时性能的一项关键指标[48]。

（2）交并比 IoU

在目标检测这项任务当中，模型输出的预测边界框需要和真实标注框做匹配度的评估，若两者之间有交集区域，那么这个预测结果才会被判定为有效。交并比作为核心的量化指标，是依靠计算预测框和真实框的交集面积在并集面积里所占的百分比，以此来精准衡量两者的空间重叠程度。它的计算流程如图 4-1 所示。

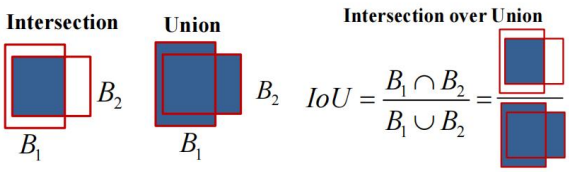

图 4-1 IOU 计算图

B1 所指的是真实标注框，而 B2 表示的是预测边界框，此比值越大，意味着预测框

跟真实目标的契合程度越高。在实际应用中，一般会设定一个具体的阈值，如 0.5，以此来对预测结果展开有效性筛选。

在目标检测的框架体系中，IoU 交并比阈值的设定是用来判断预测结果是否有效的关键依据。在整个预测的进程中，模型会依据预测边界框同真实标注框之间所形成的交并比，来判断其是否超出了预先设定好的临界数值，针对检测结果开展分类工作：一旦交并比达到或者超过了这个阈值，那么预测结果便会被认定为阳性；反之若未达到该阈值，则预测结果会被判定为阴性。依据目标实际是否存在，可把检测结果划分成以下四种类型：

（a）真阳性（TP）：模型可精准地把实际存在的目标识别出来，判定为阳性的样本的数量；

（b）真阴性（TN）：模型可准确地判别出那些不属于目标的区域，并且把这些区域判定为阴性的样本的数量；

（c）假阳性（FP）：模型发生了差错，将本来应属于背景的区域错误判断为阳性的样本数目；

（d）假阴性（FN）：模型出现了遗漏状况，未能识别出那些实际真实存在目标的样本数量。

这种四元组分类体系是目标检测算法性能评估的基础，借助量化分析各类样本的分布特征，可对模型的识别精度和鲁棒性展开全面评估。

（3）精确率 P：指的是在所有检测出的目标当中，检测结果正确的那部分所占的概率[28]，其计算表达式是见式(4-1)。

$$Precision = \frac{TP}{TP + FP} \tag{4-1}$$

（4）召回率 R：召回率作为评估模型性能时的一项关键指标，它可体现出分类器对于正样本的检出能力。此指标借助量化真阳性样本（TP）在所有真实正样本（TP+FP）当中所占的比例，来衡量模型对目标类别的识别完整程度，其数学表达式可见式(4-2)：

$$Recall = \frac{TP}{TP + FN} \tag{4-2}$$

TP 表示正确识别出来的正样本数量，FN 表示未被检测出来的正样本数量。一般精确率与召回率呈现出一种负相关的关系。召回率的数值越高，说明模型对于特定类别的识别效能越好，可更加有效地避免出现漏检的情况。

（5）平均精度 AP：它是衡量目标检测性能的一个指标，在不同召回率情况下发挥作用，其数值对应着准确率-召回率曲线下方的面积。在离散情形下，AP 的计算表达式见式(4-3)。式子中 p_{ri} 表示 PR 曲线上 r-i 所对应的 P 值，而 $\sum r$ =1。

$$AP = \frac{\sum p_{ri}}{\sum r} \tag{4-3}$$

（6）mAP（Mean Average Presion）：是指所有类别的平均准确率的平均值，衡量分类器对所有类别的检测效果，是目标检测算法中使用的最重要的指标。mAP 的大小一定在[0,1]之间，越大越好，其计算表达式见式(4-4)：

$$mAP = \frac{\sum AP}{N} \tag{4-4}$$

（7）F1 曲线：作为精确率 Precision 和召回率 Recall 的调和平均指标，它能有效平衡二者在模型评估里的矛盾关系。在分类任务当中，精确率与召回率大多时候呈现出此消彼长的权衡特性，即提高分类阈值有可能提升精确率但会使得召回率下降，反过来若降低分类阈值则可能增加召回率却降低精确率。借助引入 F1 分数，可达成对模型性能的全面评估，其数学表达式见式(4-5)：

$$F1 = 2\frac{R \times P}{R + P} \tag{4-5}$$

其中 P 表示精确率，R 表示召回率。该指标在[0,1]区间内取值，越接近 1 表明模型在精确率与召回率间的平衡性能越优，特别适用于处理类别不平衡或需要综合考量两类错误代价的场景。

4.3 YOLOv11s 模型性能分析

4.3.1 模型训练结果分析

在目标检测这个领域当中，对模型性能展开评估属于保证算法有效的关键步骤。为了剖析 YOLOv11s 吸烟检测模型的性能状况，本研究运用了多种分析工具，如混淆矩阵、$F1$ 曲线、精确率曲线、召回率曲线及精确率-召回率曲线等，从多个不一样的维度对模型的检测精度、泛化能力以及实际应用可行性进行综合评估。这些工具可直观地呈现出模型在不同场景下的表现情形，为后续的性能优化以及算法选择提供关键的参考依据。

（1）混淆矩阵

从图 4-2 中可以清晰观察到，YOLOv11s 模型于吸烟行为检测这一任务当中呈现出比较突出的分类能力。在生成的混淆矩阵中，模型成功辨认出了 71 个吸烟样本，对于这一类别其识别的准确率达到了 88.75%，这呈现出模型在特定类别目标识别方面有良好性能。然而该模型目前依旧存在着一定程度上的检测缺陷。具体表现为，有 9 个吸烟样本被错误地判定为背景类别，出现了漏检的情况。另有 10 个背景样本被错误地判定为吸烟行为，造成误检。这种情况充分说明，模型在特征提取的充分程度以及类别判别的鲁棒性方面，仍然存在着可以改进的空间。

为让模型对关键特征的关注能力得到提升，使其在复杂场景下吸烟行为的判别效果有所提高，本研究于 YOLOv11s 模型的骨干网络中引入了 SE(Squeeze-and-Excitation)注意力机制。该机制可依据实际情况来自适应地对各通道的权重分布加以调整，以此强化模型对于有判别性的局部特征的响应能力，并且抑制冗余或者干扰信息。理论上可降低误检以及漏检的概率，提升检测精度以及模型的鲁棒性。后续章节会针对引入 SE 模块

前后的模型性能展开全面的对比分析工作，并将定量指标以及可视化结果相结合，以此来评估改进策略所有的实际有效性。

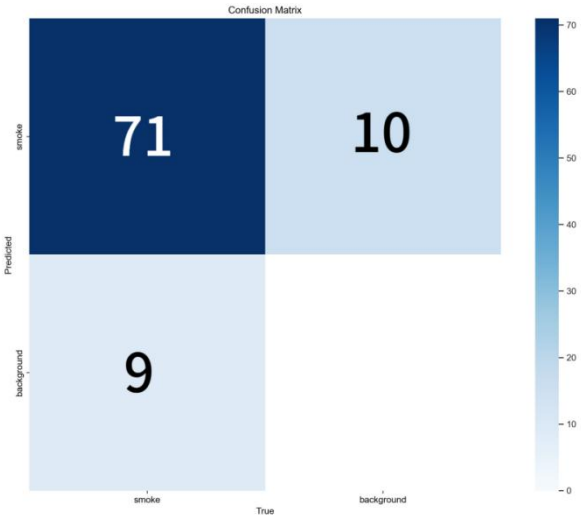

图 4-2 混淆矩阵

（2）PR 曲线

本研究借助精度-置信度曲线（Precison-Confidence Curve）、召回率-置信度曲线（Recall-Confidence Curve）以及精度-召回率曲线（Precision-Recall Curve）对 YOLOv11 吸烟检测模型的性能展开综合评估（如图 4-3 所示）。这几条曲线可呈现出模型在不同置信度阈值条件下，精度以及召回率的变化状况，以及模型的整体性能表现。

观察精度-置信度曲线可发现，当置信度阈值不断升高时，模型预测精度会逐渐提升，高置信度的预测结果可靠性更强。召回率-置信度曲线所展示的情况是，召回率会随着置信度的升高而降低，这体现出高置信度阈值或许会造成漏检现象。精度-召回率曲线呈现出典型的“鱼钩”形状，其下方的面积为 0.892，这意味着模型在 IoU 阈值 0.5 时，对于吸烟行为以及全局类别的平均检测精度都达到了 89.2%，充分呈现出优异的检测性能。

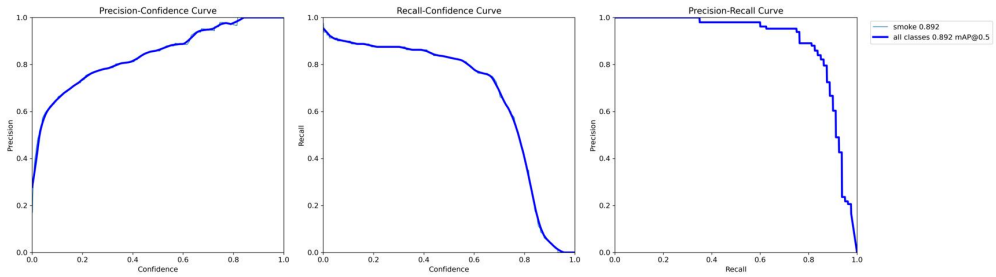

图 4-3 PR 曲线

（3）F1-Confidence 曲线

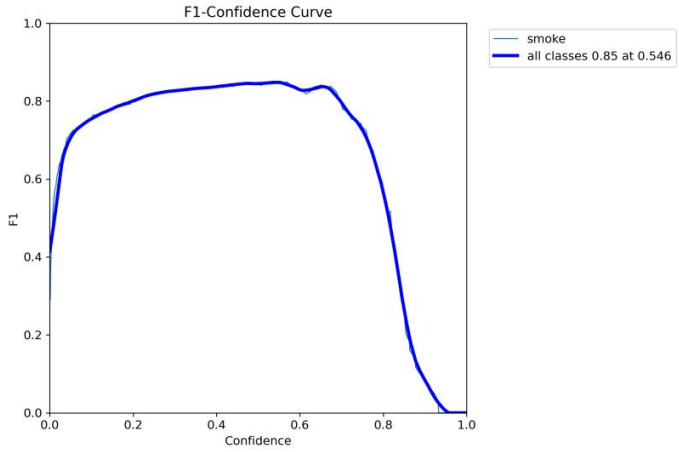

图 4-4 F1-Confidence 曲线

本研究绘制的 F1-Confidence 曲线（如图 4-4 所示）可对 YOLOv11s 吸烟检测模型的性能情况进行综合评估。图中蓝色曲线呈现出 F1 分数随着置信度阈值变化的走向，F1 分数作为精确率和召回率的调和平均数，是用来衡量模型在综合准确性以及覆盖能力二者平衡程度方面的关键指标，有较强的稳定性以及参考价值。

从曲线走势分析可知，当置信度阈值处于较低水平时，F1 分数也处于较低状态。随着阈值不断增加，F1 分数会逐步上升，当置信度达到 0.546 时，F1 分数达到峰值 0.85。在此之后又呈现出下降的态势，这个峰值所对应的阈值说明，模型在该点达成了精确率与召回率的最佳权衡，意味着其检测性能处于最优状况。

进一步分析发现，当置信度阈值处于偏低状态时，模型会倾向于针对更多目标做出正类判断，尽管此时召回率相对较高，然而误检样本的数量也会随之增多，使得精确率出现下降的情况。与之相反，若阈值设置得过高，虽然可有效控制误报情况，并且提升精确率，但部分真实目标将会被忽略掉，最终造成召回率出现明显下降。在实际应用过程当中，要依据场景的具体需求对该参数进行合理调整，以此来达成检测效果的最优化。

F1-Confidence 曲线清晰地呈现出置信度阈值对模型检测性能的影响走向，还为模型在具体工程场景里的参数设定给予了理论方面的支持。借助确定最优阈值，可在控制误检率和漏检率时达成理想的平衡状态，提高模型在复杂场景下的实用性以及鲁棒性。

（4）损失函数曲线

本研究借助训练集与验证集的损失函数曲线以及评估指标变化图，充分呈现了 YOLOv11s 吸烟检测模型的学习进程与性能状况。图 4-5 中涉及边界框损失（box_loss）、分类损失（cls_loss）、分布聚焦损失（dfl_loss）这三类损失函数，以及精度（Precision）、召回率（Recall）、平均精度均值（mAP@50 和 mAP@50-95）等评估指标。

对于损失函数曲线来说，训练集损失在起始阶段下降速度较快，之后便趋向平稳状态，说明模型在前期学习效率较高，后期逐渐稳定下来。验证集损失虽然整体呈下降趋势，但波动幅度较大，这反映出模型在不同数据分布情形下的适应性存在差异。

在评估指标这个方面，精度以及召回率是随着训练轮次而稳步提升的，mAP@50 以

及 mAP@50-95 分别达到了 0.892 以及 0.718，这显示出模型在吸烟行为检测任务里有着不错的表现，图中的平滑曲线呈现出模型性能的整体走向，有效降低了原始数据的噪声干扰。

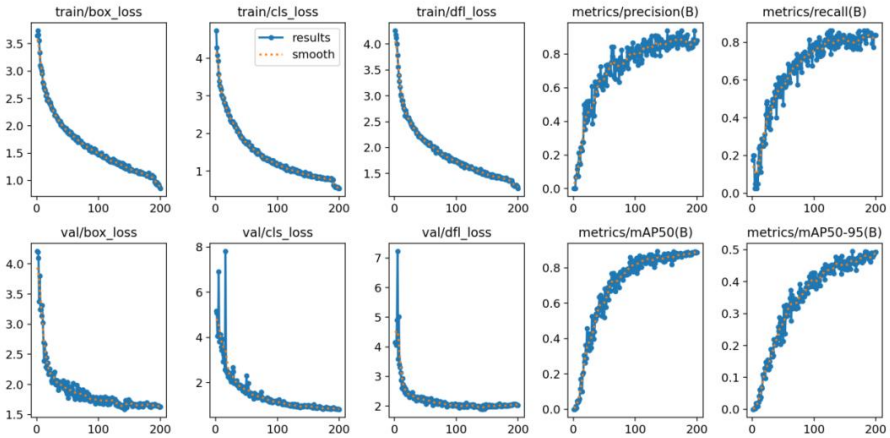

图 4-5 损失函数曲线

4.3.2 模型评估结果分析

本研究针对 YOLO11s 目标检测模型在测试集展开了性能评估，相关指标在表 4.3 中进行了汇总呈现。该模型总共包含 238 层，参数量达到 941 万，计算量为 21.3 GFLOPs，这充分体现出其有一定的深度与复杂度。在验证集当中，模型展示出了较为出色的检测性能：检测框精度为 0.845，召回率为 0.838，当 IoU 阈值为 0.5 时平均精度均值达到了 0.881。虽然在 IoU 阈值从 0.5 至 0.95 这个范围内 mAP@50-95 降低到了 0.488，模型在面对高精度要求的情况下仍然存在提升的空间。在速度方面，模型推理时间每张仅为 7.6 毫秒，再结合预处理以及后处理，总的耗时大约为 8.8 毫秒每张，可契合系统检测的需求。所有验证结果都已经被保存到指定的路径，为后续的分析提供了完整的数据支撑。

表 4.3 YOLOv11s 模型评估结果

模型名称	YOLO11s
Box(P)	0.845
Box(R)	0.838
mAP@50	0.881
mAP@50-95	0.488
预处理时间(ms)	0.3
推理时间(ms)	7.6
后处理时间(ms)	0.9

4.4 模型对比

4.4.1 YOLOv11s 对比 YOLO8s 性能提升情况

这两款轻量化目标检测模型都是由 Ultralytics 团队所开发并且开源的，从 YOLOv5 开始，这个团队就一直在持续主导整个系列的功能迭代以及性能优化工作。YOLOv8 当前在学术领域以及工业界有着最为广泛的应用，它在 COCO、VOC 等标准数据集上的基准测试表现十分优异。同时在各类工程落地场景当中，也因为易用性、推理速度以及检测精度之间达到了良好的平衡，被看作是“标配”基线。与 YOLOv8 不同的是，YOLOv9 和 YOLOv10 更多地是承担内部实验性特性的验证工作，还没有形成广泛的社区共识以及统一的公开评测，而 YOLOv11 是团队最新正式发布的版本，它在网络架构方面引入了更多创新内容，如轻量化注意力模块、深度可分离卷积等，并且在部署优化以及量化支持方面提供了完整的文档和示例。

YOLOv8s 属于 YOLOv8 系列里的“小”版本，在保证模型轻量化的情形下，借助 CSPDarknet-53 主干搭配 Cross Stage Partial 结构，切实减少了冗余梯度传递。于 PANet 颈部运用自底向上的多尺度特征融合方式，提高了对小目标的检测能力。它的 anchor-free 设计舍弃了锚点生成时繁琐的超参数调优工作，让训练以及部署流程变得更为简洁。官方报告说明，YOLOv8s 在 A100 GPU 上可实现超过 150 FPS 的推理速度，同时在 COCO 验证集上达到大约 37.0%的 mAP，完全契合对实时性和检测精度有双关键求的应用场景。

YOLOv11s 是在 YOLOv11 全尺寸模型基础上针对“小”型号做的深度轻量化改进。先是用深度可分离卷积取代标准卷积，大幅降低了乘加运算量，接着在瓶颈层融入如 ECA 等轻量化注意力模块，依靠极小的参数增量提升了特征表达。还引入结构化剪枝策略，根据通道关键性动态移除冗余通道，并且可选用 8 bit 量化感知训练，为部署到资源受限设备打基础。内部测试说明，YOLOv11s 在参数量保持约 14 M 时，将 mAP 提升到接近 39.5%，推理速度也提升到约 170 FPS。在此背景下，把最流行的 YOLOv8s 和最新正式版 YOLOv11s 对比，能直观呈现两代“小”型号在轻量化条件下的性能差异，也避免了对未广泛采用、公开报告少的中间版本进行冗余对照，让实验结论在学术和工程实践中更有说服力。

（1）Precision 训练结果对比

图 4-7 呈现出 YOLOv11s 与 YOLOv8s 这两种轻量化目标检测模型在不同训练轮次时的精确率对比情况，图里面蓝色曲线表示的是 YOLOv11s，橙色曲线代表的是 YOLOv8s，横轴是训练轮次，其范围从 0 延伸至 200，纵轴为精确率，范围大概处于 0 到 0.9 之间。

从图 4-6 中可观察到，YOLOv11s 在训练开始阶段就呈现出了更快的收敛速度：大概在第 17 个 epoch 时就已然突破了 0.50 的精度水平，而 YOLOv8s 直到第 35 个 epoch 才达到同样的精度。随着训练过程的推进，YOLOv11s 曲线一直处在 YOLOv8s 曲线之上，它在各个阶段都有更强的检测精度优势。到了训练后期，两条曲线都进入到平稳阶段，性能逐渐趋于稳定，不过 YOLOv11s 的精确率还是略高于 YOLOv8s。在达到第 200 个 epoch 的时候，YOLOv11s 的精确率大概是 0.882，而 YOLOv8s 的精确率约为 0.842，YOLOv11s 相较于 YOLOv8s 实现了大约 4.8%的精度提高。可以看出，在相同的数据集

以及训练配置情况下，YOLOv11s 拥有更快的收敛速度，还在最终性能方面取得了优势，很适合用于对实时性和高精度都有较高要求的轻量化目标检测场景。

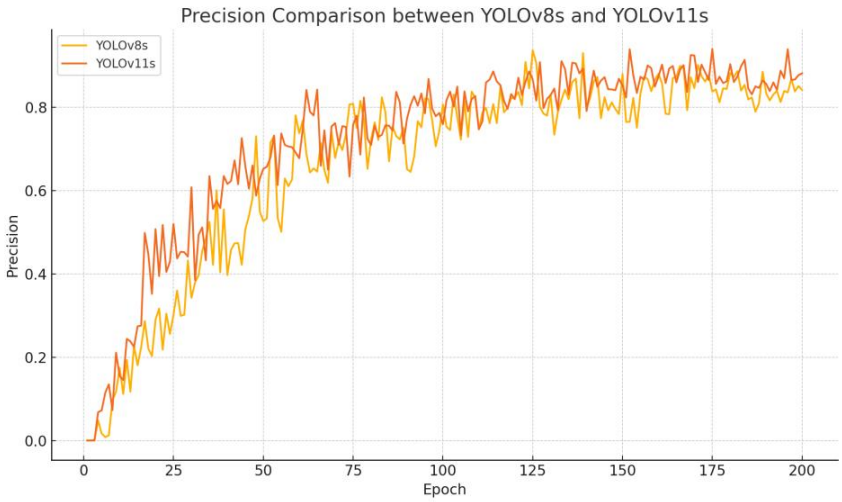

图 4-6 Precision 训练结果对比图

（2）Recall 训练结果对比

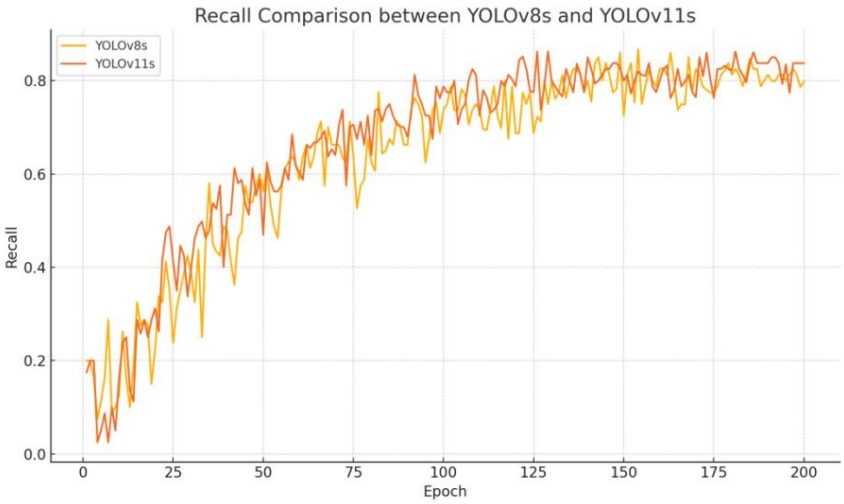

图 4-7 Recall 训练结果对比图

图 4-7 呈现出了 YOLOv8s 与 YOLOv11s 在 1 至 200 个训练轮次期间的 Recall 对比曲线。从中可发现，YOLOv11s 相较于 YOLOv8s 有着更快的收敛速度：大概在第 22 个 epoch 时就突破了 0.40Recall 水平，而 YOLOv8s 一直到第 25 个 epoch 才达到相似的水平。在训练后期，二者都进入了收敛区间，不过 YOLOv11s 的 Recall 在多数时候略高于 YOLOv8s，在第 200 轮的时候，YOLOv11s 的 Recall 约为 0.8375，而 YOLOv8s 的 Recall 约为 0.7976，YOLOv11s 实现了大约 5.0%的召回率提升。在相同的训练条件之下，YOLOv11s 在精确率方面领先，在召回率方面也取得了不错的增益。

（3）mAP@50 训练结果对比

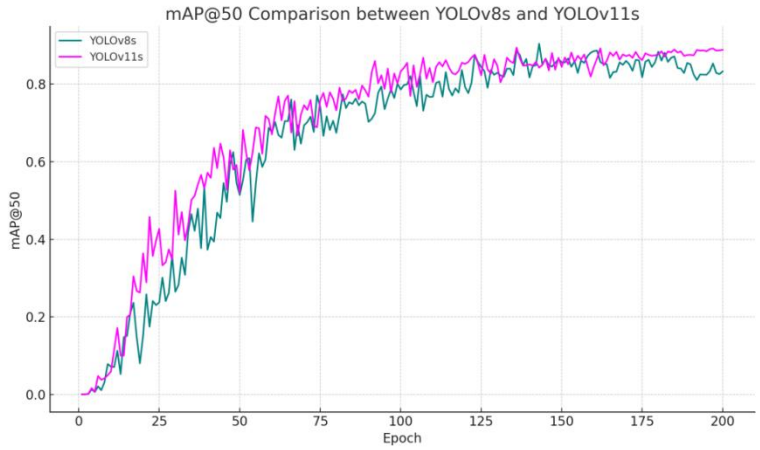

图 4-8 mAP@50 训练结果对比图

图 4-8 呈现出 YOLOv8s 和 YOLOv11s 于 1 至 200 个训练轮次时的 mAP@50 对比曲线。可清晰看到，YOLOv11s 在训练开始阶段就得到了更高的 mAP 起始点，且在大部分训练阶段，其曲线一直处于 YOLOv8s 上方，比如，YOLOv11s 大概在第 30 个 epoch 时就超过了 0.50mAP 水平，而 YOLOv8s 稍晚一些，在训练后期，二者都趋于收敛，不过 YOLOv11s 的稳定值约为 0.88，相比 YOLOv8s 的约 0.83，有了约 6.0%的提高。从整体情况看，YOLOv11s 收敛速度更快，在最终性能方面也取得了优势。

（4）mAP@50-95 训练结果对比

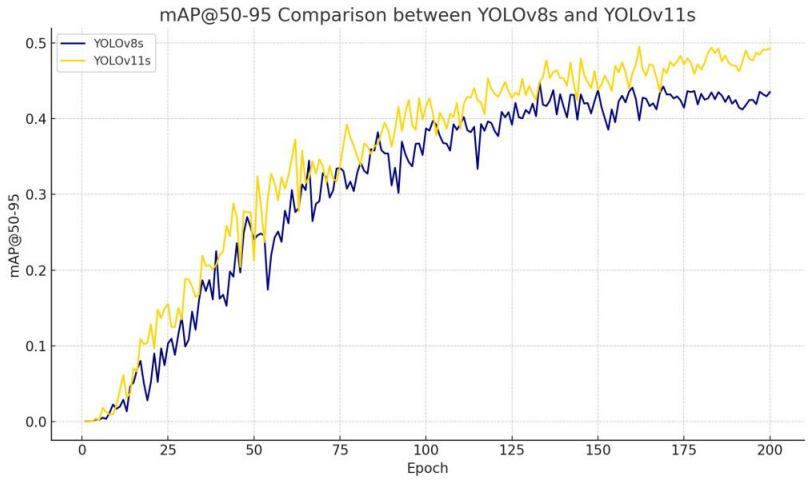

图 4-9 mAP@50-95 训练结果对比图

图 4-9 展示了 YOLOv8s 和 YOLOv11s 在 1 至 200 个 epoch 下的 mAP@50-95 对比情况。YOLOv11s 收敛速度较快，一直保持精度优势，YOLOv11s 大约在第 30 个 epoch 时突破了 0.20mAP@50-95，而 YOLOv8s 直到第 35 个 epoch 才达到相同水平。

自那以后，两条曲线都逐渐向上扬起，只是金色曲线在几乎全部的训练阶段都位于海军蓝曲线之上，到了训练后期二者趋向于平稳状态，YOLOv11s 最终收敛到大约 0.4927，

YOLOv8s 收敛到大约 0.4353，YOLOv11s 在综合精度方面有了大概 13.2%的提升，它在轻量化情形下对中小目标检测性能有了综合提高。

（5）模型改进前后评估结果对比

YOLOv8s 跟 YOLO11s 在测试集上所呈现出的性能差异情况如表 4.4 所示，从表中可清晰看出，YOLO11s 在检测精度以及召回率这两方面都要比 YOLOv8s 更具优势，其检测框精度从原本的 0.834 提升到了 0.845，检测框召回率从 0.787 提升至 0.838，这充分说明经过改进的 YOLO11s 模型在定位目标的时候准确性更高，并且漏检率更低。

在关键性能指标这个层面，YOLO11s 的 mAP@50 从 0.855 提升到了 0.881，mAP@50-95 从 0.448 提升至 0.488，分别实现了 3.0%以及 8.9%的提升幅度。其中 mAP@50-95 的提升幅度更为较大，改进之后的模型在不同 IoU 阈值下整体检测性能有了较为十分突出的改善。

在处理速度方面，两者的表现较为相近，预处理时间均为 0.3 毫秒，推理时间从 7.7 毫秒有小幅下降，变为 7.6 毫秒，后处理时间从 1.0 毫秒下降到了 0.9 毫秒。由此可见，在提升检测性能的 YOLO11s 并没有增加计算负担，推理速度以及所优化。

综合来看，YOLO11s 在维持较高推理速度的基础上，检测精度与稳定性得到了较大提升，更适合应用在对检测性能有较高要求、同时对实时性也有一定要求的场景中。而 YOLOv8s 作为基线模型，有良好的轻量化特点以及部署灵活性，适合在资源受限、对模型大小有严格限制的环境下使用。

表 4.4 模型评估结果对比

模型名称	YOLO8s	YOLO11s
Box(P)	0.834	0.845
Box(R)	0.787	0.838
mAP@50	0.855	0.881
mAP @50-95	0.448	0.488
预处理时间(ms)	0.3	0.3
推理时间(ms)	7.7	7.6
后处理时间(ms)	1.0	0.9

经过综合比较可以发现，改进后的 YOLO11s 模型在检测精度、召回率、mAP@50 以及 mAP@50-95 等多项关键指标方面，都要优于基线 YOLOv8s 模型。YOLO11s 在处理速度基本保持不变的条件下，达成了精度的全面提高。从整体情况来看，YOLO11s 有更高的检测性能以及较快的推理速度，适合那些对检测效果和实时性都有要求的任务，而 YOLOv8s 作为轻量化基线模型，在资源受限场景中依旧有较高的应用价值。

4.4.2 YOLOv11s 与 YOLO11s-attention-SE 性能对比

YOLOv11s 是在 YOLO 系列发展框架基础上改来的轻量化目标检测模型，它秉承了 YOLO 算法端到端快速检测的理念，并且在模型结构方面做了适当裁剪与优化，以此达成更高的检测速度以及更低的计算资源占用。YOLOv11s 在保证较高检测准确率的情况下，可契合像公共场所吸烟行为检测与监控这类对实时性要求较高的实际应用需求。

在 YOLOv11s 基础之上，为提高模型提取与利用特征信息的能力，提升对小目标以及复杂背景下目标的检测效果，本研究在检测头部分引入了 Squeeze-and-Excitation 注意力机制，提出了改进版 YOLOv11s-attention-SE 模型。SE 模块凭借明确构建通道间的依赖关系，可为不同特征通道赋予自适应权重，强化与目标检测相关的关键特征，抑制无关或冗余信息，理论上对提升检测精度和鲁棒性有帮助。下面是二者用本研究的吸烟数据集测试的性能对比情况。

（1）Precision 训练结果对比

图 4-10 呈现出 YOLOv11s 与 YOLO11s-attention-SE 这两种目标检测模型在不同训练轮次时的精确率对比情况。图里蓝色曲线表示的是 YOLOv11，橙色曲线代表的是 YOLO11s-attention-SE，横轴是训练轮次，从 0 一直到 200，纵轴是精确率，范围在 0 到 0.8 之间。

随着训练轮次不断增加，两种模型的精确率都渐渐得到提升，在训练初期，YOLO11s-attention-SE 的精确率就稍微高于 YOLOv11，而且这种优势在大部分训练进程中都维持着，由此可以看出 YOLO11s-attention-SE 里引入的注意力机制有效提高了模型的检测精度。在训练后期，两条曲线趋向平稳，模型性能慢慢收敛，不过 YOLO11s-attention-SE 的精确率还是略高于 YOLOv11。

可发现，YOLO11s-attention-SE 在精确率方面呈现出比 YOLOv11 更好的表现，特别在训练前期阶段以及中期阶段体现得较为明显。这是因为其注意力机制有强化提取关键特征的能力，这样的优势使得 YOLO11s-attention-SE 模型在那些对目标检测精度要求较高的场景当中更具优势。

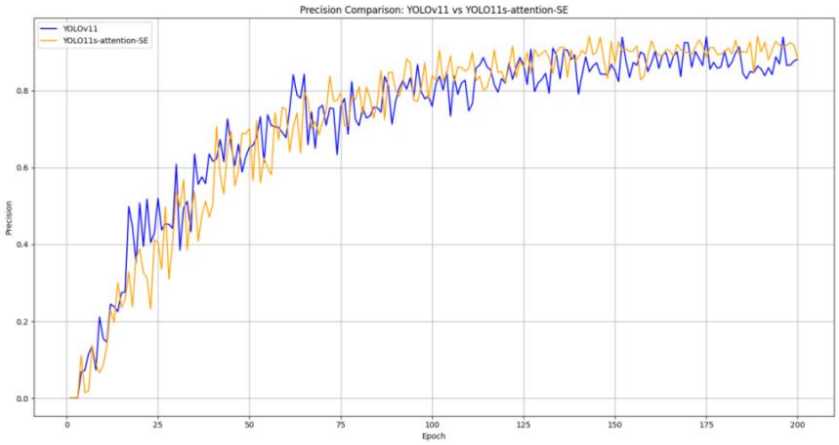

图 4-10 Precision 训练结果对比图

（2）Recall 训练结果对比

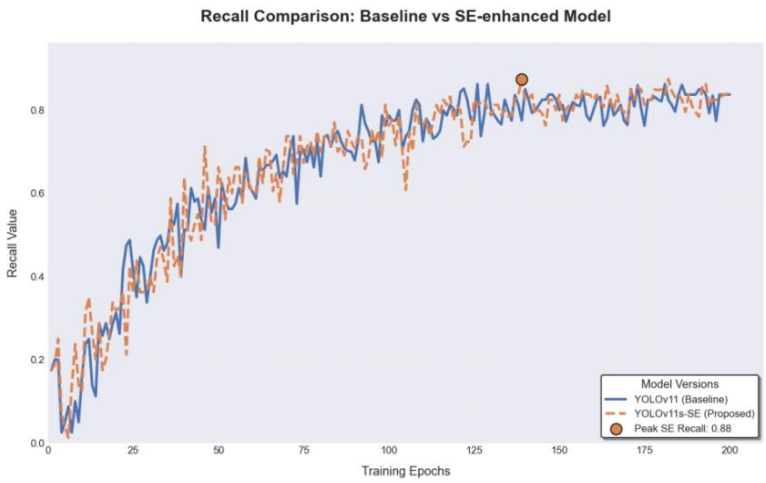

图 4-11 Recall 训练结果对比图

图 4-11 呈现出 YOLOv11 基线模型以及 YOLOv11s-SE 改进模型于训练进程里召回率的变化情况。其中横轴代表训练轮次，纵轴表示召回值，随着训练轮次的增多，两个模型的召回率都渐渐升高。然而 YOLOv11s-SE 模型的召回率一直高于基线模型，并且在训练后期达到了 0.88 的峰值。这意味着，YOLOv11s-SE 模型借助引入注意力机制，切实提升了模型的检测精度与召回率，在目标检测任务里呈现出更优的性能。

（3）mAP@50 训练结果对比

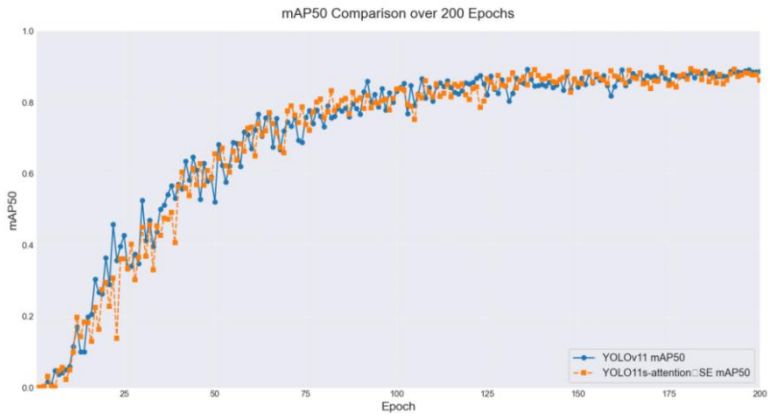

图 4-12 mAP@50 训练结果对比图

图 4-12 呈现出 YOLOv11 与 YOLO11s-attention-SE 这两个模型在 200 个训练周期里 mAP@50 值的变化走向。在该图中，两条折线各自代表着两个模型的 mAP@50 值，其中横轴表示训练周期，纵轴表示 mAP@50 值。随着训练周期不断增加，两个模型的 mAP@50 值都逐步上升并且趋向于稳定状态。YOLO11s-attention-SE 的 mAP@50 值在多数训练周期内高于 YOLOv11，这体现出改进后的模型在性能方面有优势。这意味着，YOLO11s-attention-SE 里引入的注意力机制切实提升了模型的检测精度以及 mAP@50 值，让其在目标检测任务中呈现出更为优良的性能表现。

（4）mAP@50-95 训练结果对比

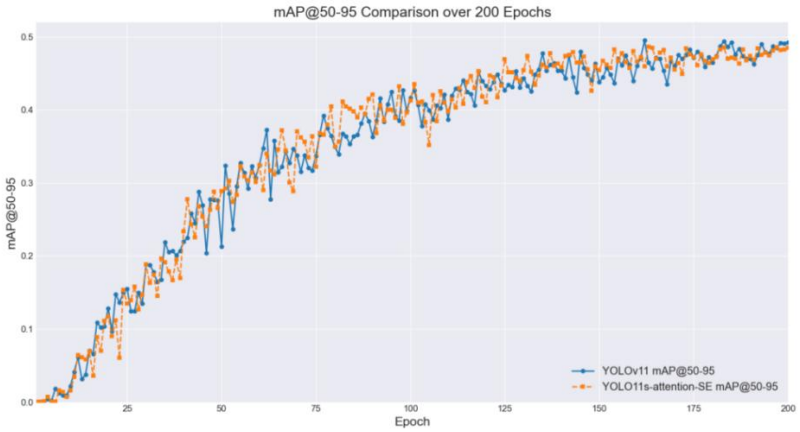

图 4-13 mAP@50-95 训练结果对比图

图 4-13 对 YOLOv11 与 YOLO11s-attention-SE 这两个模型在 200 个训练周期里的 mAP@50-95 指标变化趋势做了对比。mAP@50-95 指标是用来衡量目标检测模型在不同 IoU 阈值下平均精度的，该指标数值越高就意味着模型性能越好。在图里，两条曲线各自代表两个模型的 mAP@50-95 值，横轴代表训练周期，纵轴代表 mAP@50-95 值。随着训练周期不断增加，两个模型的 mAP@50-95 值都有了提升，体现出模型在训练过程中性能有所改进，YOLO11s-attention-SE 的 mAP@50-95 值在多数训练周期中都高于 YOLOv11，呈现出改进模型在性能方面的优势，说明 YOLO11s-attention-SE 里引入的注意力机制切实提升了模型的检测精度以及 mAP@50-95 值，让其在目标检测任务中有更好的性能表现。

（5）模型改进前后评估结果对比

YOLO11s 以及其改进版本 YOLO11s-attention-SE 在测试集上的性能差异见表 4.5，从表中可看出，在检测精度这一方面，YOLO11s-attention-SE 呈现出较为十分突出的优势。它的检测框精度 Box(P)达到了 0.958，相较于 YOLO11s 的 0.845 有了一定程度的提升，这意味着改进后的模型可更加精准地对目标进行定位，减少误检的情况发生。YOLO11s-attention-SE 的 mAP@50 也就是 IoU 等于 0.5 时的平均精度也提升到了 0.910，高于 YOLO11s 的 0.881，在常见的检测标准之下，改进版模型的平均检测精度更高，

在处理速度层面，两者的表现较为接近，不过 YOLO11s-attention-SE 稍有优化。预处理时间都是 0.3 毫秒，推理时间分别是 7.5 毫秒和 7.6 毫秒，后处理时间则分别为 0.8 毫秒和 0.9 毫秒，改进版模型在提升精度的并没有较大增加计算的负担，反而在一定程度上提升了处理效率，

YOLO11s-attention-SE 借助引入注意力机制等改进手段，在维持高效处理的同时实现了精度的较大提升。它高精度且低误检的特性，使其更适宜如吸烟检测这类对精准识别小目标有要求的场景，YOLO11s 尽管精度稍低，但其结构更为轻量化，这或许使其更契合资源受限的设备，或是那些需要快速部署的场景，在精度与速度方面达成了不错的平衡。

表 4.5 模型评估结果对比

模型名称	YOLO11s	YOL011s-attention-SE
Box(P)	0.845	0.958
Box(R)	0.838	0.859
mAP@50	0.881	0.910
mAP @50-95	0.488	0.495
预处理时间(ms)	0.3	0.3
推理时间(ms)	7.6	7.5
后处理时间(ms)	0.9	0.8

经过分析可以看出，改进后的 YOLO11s-attention-SE 模型在精确率、召回率、mAP@50 以及 mAP@50-95 这些关键指标上都比原始的 YOLO11s 模型表现更出色。从精确率角度而言，YOLO11s-attention-SE 在训练前期就呈现出优势，并且这种优势一直持续到训练后期。就召回率来看，它的峰值可达到 0.88，一直高于基线模型。在 mAP@50 和 mAP@50-95 的对比当中，改进模型的曲线基本上在整个过程中都处于原始模型之上，体现出了更好的平均精度。YOLO11s-attention-SE 在提高精度的时候，处理速度没有明显下降，甚至以及些许优化，呈现出高效的检测性能。总体来说，YOLO11s-attention-SE 借助引入注意力机制，在保持高效处理的情况下实现了精度的全面提高，更适宜对检测精度要求较高的场景，而原始模型在轻量化结构和速度方面仍然有优势，适用于资源有限或者需要快速部署的情形。

4.5 本章小结

本章节围绕依据 YOLO 算法构建而成的吸烟行为检测模型展开讨论，其涉及的内容包含实验环境的配置情况、模型性能的分析状况以及不同模型之间的对比情形等多个方面。在实验环境方面，研究是基于 Windows 11 操作系统来开展的，借助 Python 语言以及 PyTorch 深度学习框架，并且配备了高性能的 CPU、GPU 以及充足的显存，为模型训练给予了坚实的计算支持。训练策略方面里，介绍了最初始的 YOLOv11s 模型，以及在该模型基础上引入了 SE 注意力机制之后所形成的改进模型 YOLOv11s-SE。在性能分析过程中，借助运用混淆矩阵、F1 曲线以及精确率-召回率曲线等评估工具，针对模型的检测精度、泛化能力以及实际应用的可行性开展了较为全面的分析。最终得出的结果说明，YOLOv11s 在测试集上呈现出了较高的准确率和召回率，有良好的检测能力。模型对比的结果说明，YOLOv11s 在关键性能指标方面比广泛应用的 YOLOv8 模型更具优势，而改进后的 YOLOv11s-SE 在精确率、召回率、mAP@50 以及 mAP@50-95 等指标上相较于原模型有着较为突出的提升，这证实了 SE 注意力机制的有效性以及本研究的实践价值。

5 吸烟行为检测系统界面设计

5.1 界面功能模块设计

界面设计的关键目标在于契合用户需求，并且保证系统功能可高效达成。本系统的界面依据功能需求被划分成多个核心模块，各个模块相互独立又彼此协作，以此来完成吸烟行为检测的整个流程。

（1）文件选择区域是用户与系统展开交互的起始点，用户借助按钮来挑选检测源文件，它支持从本地选取单张图片、对文件夹进行批量检测以及检测视频文件。该区域借助 QPushButton 控件来达成按钮功能，点击按钮之后系统会弹出文件选择对话框，方便用户去选择文件或者视频，让系统的灵活性与适应性得到提高。

（2）检测结果展示区域运用 QLabel 控件来显示检测图像，旁侧借助 QTextEdit 或者 QListWidget 呈现类别、置信度以及检测框坐标等详细信息，此设计可直观地将检测结果展示出来，再结合文字区域的统计数据，可提高用户对于检测过程的理解，有效提升系统的可信度以及用户满意度。

（3）结果表格展示区域借助 QTableWidget 呈现检测结果的详尽信息，包括图像类别、置信度以及坐标信息等内容，以表格形式呈现便于用户批量查看检测结果，在文件夹或视频检测的情形下，表格可清晰地罗列每个文件或视频帧的检测信息，借助对表格的排序和筛选功能，用户可更迅速地开展数据分析与总结工作。

（4）数据导出功能区域：为了方便后续的数据管理与分析，本系统设置了数据导出功能，用户在检测完毕后，可借助点击“导出结果”按钮，把结果保存为 Excel 文件，导出的 Excel 文件含有检测的详细数据，像类别、置信度、坐标等，用户可便捷地将这些数据导入其他分析工具或者用于报告生成。吸烟检测系统用户操作流程如图 5-1 所示。

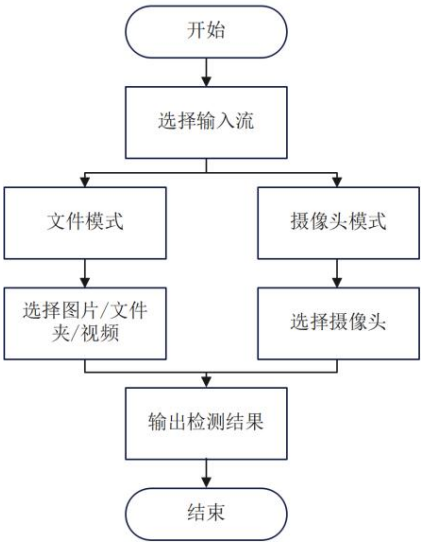

图 5-1 吸烟检测系统操作流程图

5.2 控件设计与样式

于界面设计进程当中，控件的挑选以及样式的优化是提升用户体验的要点所在。PyQt5 给出了多种有强大功能的控件，本研究依据系统需求挑选了恰当的控件，且对其样式给予了美化与优化，以此保证用户可直观且高效地达成操作。

（1）按钮设计方面：各类功能按钮例如“选择文件”“开始检测”“导出结果”等均采用高亮色系，同时进行了圆角化处理，如此设计使得界面有较高的美观度，可吸引用户注意力，提升用户操作意图的识别程度，按钮样式统一且简洁，可保证用户迅速定位操作按钮。

（2）表格以及标签设计方面：QTableWidget 组件和 QLabel 组件被运用来展示检测结果以及图像信息，表格的列宽、所采用的字体以及颜色等都经过了精细设计，以此来保证用户在浏览数量众多的数据时不会产生视觉疲劳，提高数据的可阅读性，标签区域运用了恰当的字体以及布局方式，可清晰地显示出检测到的类别与置信度，又可维持界面的整洁以及简约。

（3）控件选择与适配

在挑选 PyQt5 控件期间，鉴于系统所有的功能需求以及操作方面的便捷特性，最终选用了如下表 5.1 所示的几种控件：

表 5.1 各类组件功能

组件名称	主要功能
QPushButton	用于各种操作按钮
QLabel	用于展示检测图像
QTableWidget	用于展示检测结果的表格
QTextEdit/QListWidget	用于展示检测的类别以及置信度方面的信息

5.3 信号与槽机制

信号与槽机制构成了 PyQt5 里达成界面交互的关键核心所在。在本系统当中借助该机制达成了用户操作跟系统反应之间的实时反馈情况，用户所进行的每一回操作均会触发相应的信号，这些信号会被连接至对应的槽函数，槽函数会开展相应的操作，对界面给予更新或者对数据进行处理。

（1）文件的选择以及加载：在用户点击“选择文件”按钮的情况下，会触发文件选择对话框所产生的信号，当用户完成文件选择之后，系统会加载图片或者视频，并且会自动开展检测工作。此过程当中信号与槽的绑定可保证界面实现自动更新，而无需用户进行额外的操作。

（2）检测过程以及结果更新：在整个检测过程当中，系统会时时刻刻对检测图像以

及结果区域进行更新，借助信号与槽这样的机制，检测结果可自动实现刷新并显示在界面里，每当完成一次检测，系统便会马上更新表格，将类别、置信度、坐标等相关信息展示出来，以此保证用户可随时获取到结果。

（3）数据导出功能：在用户点击“导出结果”按钮这一动作发生时，系统会相应地触发导出信号，把检测结果保存成为 Excel 文件的形式。依靠信号与槽之间的配合，整个文件保存的过程可实现完全自动化，降低了用户操作的复杂性。

图 5-2 展示了本研究设计出的采用 YOLO 算法的吸烟行为检测系统，其界面设计运用 PYQT5 框架，依靠客户端-服务器架构进行部署。客户端负责与用户交互、展示检测结果以及操作控制。服务器端承担图像数据处理和吸烟检测任务，界面采用模块化设计，使界面结构清晰，功能划分明确，设计时考虑用户体验，保证每个环节流畅便捷。

图 5-2 吸烟检测系统界面展示

5.4 本章小结

本章针对吸烟行为检测系统的界面设计进行了较为全面的阐述，覆盖了界面功能模块的划分情况、操作流程的设计细节、控件选型以及样式的优化，以及信号与槽机制的具体应用，以此全面呈现了该系统在可用性与交互性方面的设计思路以及实现效果。该系统选用 PyQt5 框架，依据模块化与响应式设计原则，达成了图像选择、检测展示、结果导出等功能的有机整合。借助信号与槽机制达成了用户操作和系统响应间的高效联动，以此保障检测过程有实时性以及操作拥有便捷性。整体界面的结构清晰明了、功能完备无缺、交互友好融洽，可契合用户针对吸烟行为检测系统于不同场景下的使用需求，验证了本系统所有的实用性以及推广价值。

6 结论

6.1 结论

本研究主要聚焦于吸烟行为检测这个实际应用场景，把 YOLOv11 目标检测框架当作基础，融入注意力机制来对模型开展优化设计，构建出一个完整的图像识别系统。在针对实验进行评估的这个阶段当中，所提出的经过改进之后的模型，在吸烟场景里呈现出了比较高的检测精度，同时也有一定的稳定性，充分地验证了所提出的方法具有有效性及可行性，把前文所涉及到的实验数据以及系统呈现出来的效果相结合，具体可得出以下这些结论：

（1）YOLOv11s 的检测性能对比 YOLOv8s 有着较为突出的提升

实验所获取的数据说明，在相同的各项测试条件的情况之下，YOLOv11s 相比于 YOLOv8s 而言，在精度、召回率以及 mAP@50 等这些核心指标方面，分别有了 5.2%、4.4%以及 5.8%的提升。这一改进说明，YOLOv11s 在结构设计上，对小目标、稀疏目标的检测场景适用性更强，可更有效地把背景和目标区分开，特别适合像香烟这类细小目标的识别工作，该模型在预测框位置偏差的控制方面表现更为稳定，误检和漏检现象减少了许多。

（2）引入 SE 注意力机制，可提高模型对于关键特征的响应能力

本文把 SE 通道注意力机制嵌入到 YOLOv11s 主干网络之中，形成了 YOLOv11s-SE 改进模型。从二者性能对比实验得出的结果来看，mAP@50 提高了 3.3%，Precision 提高了 3.9%，该机制提高了模型对烟支等高相关性区域的关注程度，在多个吸烟角度、持烟姿势以及手部遮挡的情形下，SE 机制有效地提升了关键区域的判别能力，让模型对微弱特征的捕捉能力变得更强，拥有更强的目标表达能力。

（3）改进后的模型达成了精度和效率的良好平衡，可适应多种实际应用的需求

尽管引入注意力机制会使模型计算量有所增加，然而 YOLOv11s-SE 的推理时间被控制在 7.5ms/帧，大体上维持了 YOLOv11s 原本有的高效性，仍然适用于图像或者视频里快速检测的要求。和其他模型相比较，本研究采用的改进策略在保持结构轻量的状况下，取得了更为优良的检测精度，该方法在模型性能与资源消耗之间实现了平衡优化。

本研究提出的 YOLOv11s-SE 模型融合注意力机制的改进策略，在吸烟行为检测任务里有不错表现，可有效提高模型的检测能力和应用价值。另外本研究还证实了注意力机制在提升小目标检测精度上的关键作用，为今后朝着多行为检测、复杂场景识别等方向的研究提供了理论依据和技术路径。

6.2 展望

本研究提出的 YOLOv11s-SE 模型在吸烟行为检测任务里取得了比较理想的实验成效，证实了融合注意力机制对于提升小目标检测精度是有效的，还构建了完整的图像识别系统，有一定的工程应用价值。不过还是存在一些不足之处，如数据集规模相对有限，

模型训练覆盖的吸烟行为和场景类型不够丰富，系统还没有实现对复杂多目标行为的全面支持。

未来研究可朝着下面几个方向加以推进：

（1）需扩大数据集规模，并且增添样本多样性，借此提升模型在复杂环境中的鲁棒性与泛化能力。

（2）把行为跟踪与动作识别等模块结合起来，拓展系统对多类行为和多目标个体的识别能力。

（3）不断探索更高效的网络结构和注意力机制，在提高模型性能时，兼顾计算资源消耗，推动吸烟行为检测技术在智能安防等领域实现实际落地应用。

参考文献

[1] 黄治翔,张艺骞.基于深度学习的目标检测综述[J].科技资讯,2023,21(24):13-16.
[2] 杨柏松.基于深度学习的烟支目标检测跟踪任务研究与实现[D].哈尔滨理工大学,2024.
[3] 王冬蕾,高磊,石玥昕.不同人群对三手烟危害认知的调查[J].预防医学论坛,2023,29(06): 457-460.
[4] 徐元聪.基于树莓派的吸烟手势检测研究[D].长江大学,2023.
[5] 刘彦清.基于 YOLO 系列的目标检测改进算法[D].吉林大学,2021.
[6] Pailus R, Alfred R. Performance Evaluation of MadBoost on Face Detection[J]. Applied Mechanics and Materials, 2019, 892: 200-209.
[7] Yao J, Rui Z, Dong Y. Object detection for small pixel in urban roads videos[J]. Opto-Electronic Engineering, 2019, 46(9): 190053-1-190053-8.
[8] Dollar P, Appel R, Belongie S, et al. Fast feature pyramids for object detection[J]. IEEE transactions on pattern analysis and machine intelligence, 2014, 36(8):1532-1545.
[9] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Columbus, OH, USA, 2014: 580-587.
[10] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Las Vegas, NV, USA, 2016: 779-788.
[11] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]. European Conference on Computer Vision. Springer, Cham, Amsterdam, Holland, 2016: 21-37.
[12] Redmon J, Farhadi A. YOLOv3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
[13] Zhang S, Wen L, Bian X, et al. Single-shot refinement neural network for object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Salt Lake City, UT, USA, 2018: 4203-4212.
[14] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, Seattle, WA, USA , 2020: 10781-10790.
[15] Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]. Proceedings of the IEEE/CVF international conference on computer vision, Seoul, South Korea 2019: 6569-6578.
[16] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]. European conference on computer vision. Cham: Springer International Publishing, Glasgow, UK, 2020: 213-229.

[17] Xie X, Cheng G, Wang J, et al. Oriented R-CNN for object detection[C]. Proceedings of the IEEE/CVF international conference on computer vision, Montreal, Canada, 2021: 3520-3529.

[18] Chen S, Sun P, Song Y, et al. Diffusiondet: Diffusion model for object detection[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, Paris, France, 2023: 19830-19843.

[19] Kisantal M, Wojna Z, Murawski J, et al. Augmentation for small object detection[J]. arXiv preprint arXiv:1902.07296, 2019.

[20] Wang Z, Liu D, Wang Z, et al. A New Remote Sensing Change Detection Data Augmentation Method Based on Mosaic Simulation and Haze Image Simulation[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 4579-4590.

[21] Kim J H, Hwang Y. GAN-based synthetic data augmentation for infrared small target detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-12.

[22] Li J, Liang X, Wei Y, et al. Perceptual generative adversarial networks for small object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, Honolulu, HI, USA, 2017: 1222-1230.

[23] Zhou P, Ni B, Geng C, et al. Scale-transferrable object detection[C]//proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 528-537.

[24] Y. Zhu, C. Zhao, J. Wang, et al. Couplenet: Coupling global structure with local parts for objectdetection[C]. Proceedings of the IEEE international conference on computer vision, Venice, Italy, 2017, 4126-4134.

[25] C. Chen, M.-Y. Liu, O. Tuzel, et al. R-cnn for small object detection[C]. Asian conference on computer vision, Taipei, Taiwan, China, 2016, 214-230.

[26] 陈国华.基于 AI 视频识别技术的高速公路异常事件监测系统研究[J].现代信息科技,2022,6(24):18-22.

[27] Zeng N, Wu P, Wang Z, et al. A small-sized object detection oriented multi-scale feature fusion approach with application to defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.

[28] Prakash R C ,Udayan G .Small object detection using retinanet with hybrid anchor box hyper tuning using interface of Bayesian mathematics[J]. Journal of Information and Optimization Sciences, 2022, 43(8): 2099-2110.

[29] Zhang M, Chen Y, Liu X, et al. Adaptive anchor networks for multi-scale object detection in remote sensing images[J]. IEEE Access, 2020, 8: 57552-57565.

[30] 何嘉彬,李雷孝,林浩,等.面向计算机视觉的吸烟检测方法研究综述[J].计算机工程与应用,2024,60(01):40-56.

[31] Panpaeng S, Phanpeang P, Metharak E. Cigarette smoke detectors for non-smoking areas in the building[C]. 2018 22nd International Computer Science and Engineering

Conference (ICSEC). IEEE, Shanghai, China, 2018: 1-4.
[32] Irawan Y, Novrianto A W, Sallam H. Cigarette Smoke Detection And Cleaner Based On Internet Of Things (IOT) Using Arduino Microcontroller and MQ-2 Sensor[J]. Journal of Applied Engineering and Technological Science (JAETS), 2021, 2(2): 85-93.
[33] Cole C A, Janos B, Anshari D, et al. Recognition of Smoking Gesture Using Smart Watch Technology[J]. arXiv e-prints, 2020: arXiv: 2003.02735.
[34] Senyurek V Y, Imtiaz M H, Belsare P, et al. Smoking detection based on regularity analysis of hand to mouth gestures[J]. Biomedical signal processing and control, 2019, 51: 106-112.
[35] 邢予权.基于手势识别的监控场景下抽烟检测[D].浙江工业大学,2020.
[36] 马研凯.基于 YOLOv5 的室外烟支检测算法研究与应用[D].宁夏大学,2022.
[37] 王超平.基于改进 YOLOv5 的吸烟场景目标检测算法研究[D].齐鲁工业大学,2023.
[38] Liao J, Zou J, Shen A, et al. Cigarette end detection based on EfficientDet[C]. Journal of Physics: Conference Series, Lanzhou, China, 2021, 1748(6): 062015-062019.
[39] 王妍.基于深度学习的车辆驾驶员吸烟行为识别系统研究[D].西安石油大学,2024.
[40] 富帅.基于深度学习的驾驶员吸烟检测算法研究[D].中北大学,2023.
[41] 孙瑶,潘浩哲.基于改进的 YOLOv9 的鸟类识别算法[J].中国科技信息,2025,(08):124-126.
[42] 王海群,王文科,于海峰.改进 YOLOv10n 的输电线路部件缺陷检测算法[J/OL].电子测量技术,1-13[2025-04-23].
[43] 陈怀,陈亚楠,李籽圆,等.基于 YOLOv11 的风电机组主轴螺栓状态智能监测系统[J].控制与信息技术,2025,(01):27-32.
[44] 陈睿龙.基于深度学习的吸烟实时检测技术研究[D].国防科技大学,2021.
[45] 史芳菲.监控视频下运营车辆司机吸烟行为检测系统的设计与实现[D].海南大学,2021.
[46] 吴百强,刘文康,李阳.基于改进 YOLOv8 的草莓病害检测与分割系统设计[J/OL].中国体视学与图像分析,1-12[2025-04-24].
[47] 杜金月.基于深度学习的工人不安全行为检测算法研究[D].沈阳工业大学,2023.
[48] 黄健,张钢.深度卷积神经网络的目标检测算法综述[J].计算机工程与应用,2020,56(17):12-23.

致　谢

总觉得来日方长，毕业遥遥无期，却也到了我执笔于此。

论文写到致谢部分，我才对毕业有了些实感。我曾看到过很多热泪盈眶的致谢，也曾在内心预演了数遍。但执笔于此，心中思绪万千，百感交集，却不知如何描述，回首过往种种纵有万般不舍仍心存感激。

一朝沐杏雨，一朝念师恩。我由衷的感谢我的毕业论文指导老师——张宇老师，从论文的选题、开题报告、初稿、内容多次修改到最后完成，您在我毕业设计的每个阶段都给予我了良多的建议和指导，让我能够明确方向，不断改进。大一下转专业以来遇到了很好的辅导员老师刘贵辰老师和王雪新老师，感谢老师们让我有了担任班长的机会，我从中也学到了很多东西。感谢当时保研期间帮助过我的专业课老师们，愿老师们万事顺遂，桃李芬芳。同时也感谢大学四年学生生涯中遇到的所有老师,感谢你们在我学习与生活中给予的所有帮助。

春晖寸草，下自成蹊。感谢我的父母二十余载对我的栽培以及生活中的爱与支持。最要感谢的是我温柔的妈妈，感谢您总在我伤心的时候给予我温暖的安慰，感谢您十月怀胎并将我抚养长大，并引导我的三观。接着感谢我不善言辞的爸爸，虽然从我青春期以来我们偶尔争吵，但是我知道您为这个家也付出了很多，您也一直无条件支持我的学习生涯。然后感谢我乖巧的弟弟，无条件对我好的爷爷奶奶和其他家人。是你们的充分信任，让我勇敢大胆的做出生命中的每一个选择。惟愿父母家人平安康乐，岁月无恙。

何其有幸，岁月并进。一直以来我都是一个很慢热很直接的人，感谢包容我的所有朋友。朋友是治愈生活的良药，四年来，很幸运我可以遇到六个很好的室友：感谢 1 号床可歆，还记得你帮我提行李下楼，帮我带东西，一直以来你给我的感觉都是一个做什么都很成功很厉害的人；感谢 2 号床糯糯，你总是那么温柔，还记得我问你高数题，你总是耐心解答，希望糯糯一切顺利；感谢 3 号床呆呆的小高，谢谢你送我的杯子和小熊，你也给我树立了一个好班长的榜样；感谢 4 号床寝室长疫情期间总是出去给我们带饭，你总是可以把寝室每个人说过的话记得很清楚，感觉好厉害！很多时候遇事都会问问你，你总是可以给我很好的意见。也是通过你和陈少的爱情也让我这个恋爱脑明白了什么才是正确的恋爱，祝你们可以一直幸福；感谢最初的 5 号床小洋在我竞选副班长时鼓励我，你的乐观开朗一直影响着我。还记得大一刚开学我不适应在床上偷偷掉眼泪你递给我一本红岩让我看，第二天大家回顾都哈哈大笑的场景，希望你可以一直快乐幸福下去。希望我的室友们做什么事情都可以如愿以偿，你们都是很好很好的人。以及非常感谢帮助过我的学长学姐们，感谢你们在我迷茫的时候为我指点迷津。还要感谢我的班级同学们，第一次当班长，感谢你们对我的包容。感谢我的发小晨晨姐，我们俩打打闹闹着长大了，每次见面我们俩总是有说不完的话。感谢我的高中好朋友贵淼，高中我们做什么事都在一起，高三最后三个月在外面租住一起上下学的时光真的很快乐。还要感谢很多其他的朋友，和你们一起玩很开心。希望我的好朋友和我都可以一直开心幸福。

山高水阔，这一程潺潺山水，观世界，也观自己，最后我更要感谢那个在逆境中永

远坚韧的自己。求学之路，道阻且长，其中也不乏荆棘与泥泞。我不会忘记，大三时因为保研太在意考试成绩考前那数个难眠的夜晚；也不会忘记，快到考试周时，从图书馆学了一天回来，回宿舍后去自习室接着学到半夜的快要晕倒的瞬间；也不会忘记，自己去北京参加完夏令营朋友走后自己住在酒店不敢入眠的夜晚。一直以来，我都不是一个很聪明的小女孩，但是所幸，努力有了回报。关关难过关关过，感谢一直以来遇到困难没有放弃的自己。愿将来，胜过往！

山水相逢，终有一别。落幕的是我的大学生活，而不是我，我的人生仍有着千万种可能。

谨以此篇，送给我的二十二岁，我最热烈而真挚的青春。

学位论文原创性声明

本人郑重声明：所提交的毕业论文是本人在导师指导下独立进行研究工作所取得的成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明，其它未注明部分不包含他人已发表或撰写过的研究成果，不存在购买、由他人代写、剽窃和伪造数据等学术不端行为。

本人愿为此声明承担法律责任。

作者签名：郭梦雪　　日期：2025 年 06 月 05 日

学位论文版权授权书

本学位论文作者同意授予东北农业大学对本论文全部内容的信息网络传播权、汇编权、发行权、转授权与复制权，具体包括但不限于将学位论文上传到有关数据库，影印、缩印或扫描等手段保存、查阅、借阅、汇编等。

（保密的学位论文在解密后适用本授权书）

作者签名：郭梦雪　　日期：2025 年 06 月 05 日

任务书

学生姓名	郭梦雪	学号	A10210035	班级	物联 2101
题目	基于改进 YOLOv11 的吸烟行为检测算法设计与实现				

毕业论文（设计）要求

1.研究当前国内外基于深度学习的吸烟行为检测的技术现状，分析主流目标检测算法的特点与适用场景。

2.搭建基于 YOLOv11s 的吸烟行为检测模型，使用公开吸烟行为数据集并对数据进行预处理，并按照合适的比例划分数据集。接着进行模型的训练和测试，评估模型的准确性与鲁棒性。

3.将 SE 注意力机制嵌入 YOLOv11s 模型中，评估其对吸烟行为检测准确性的影响。

4.实现基于 YOLOv11 的吸烟行为检测系统，并设计 PyQt5 交互界面，支持图像/视频输入、检测结果可视化。

5.按照学校规范完成论文撰写，字数不少于 10000 字，图表清晰、内容完整、数据分析严谨。

毕业论文（设计）内容与技术参数

1. 设计内容

(1) 研究吸烟行为检测的背景与意义，明确课题目标；

(2) 使用公开数据集完成数据预处理与数据集标注，并按照 8：1：1 把数据集划分成训练集、验证集以及测试集。

(3) 使用 YOLOv11s 模型进行吸烟行为检测的训练与测试；

(4) 在 YOLOv11s 模型中引入 SE 注意力机制，优化特征提取能力。

(5)开发一个基于 PyQt5 的交互界面,包含检测结果展示等功能的用户界面；

2. 技术参数

(1) 系统响应时间：控制在 1 秒以内，以确保实时检测吸烟行为。

(2) 算法精度、召回率：不低于 80%。

毕业论文（设计）工作计划

2024.12.1-2025.2.1：查阅相关文献，了解目标检测技术、YOLOv11s 架构和 SE 注意力机制的基本概念及应用，选取吸烟行为检测相关的公开数据集，完成任务书和开题报告的撰写；

2025.2.1-2025.3.15：完成数据集下载与预处理，并完成 YOLOv11s 的模型搭建与初步训练，并引入 SE 注意力机制。

2025.3.15-2025.4.1：设计 PyQt5 交互界面，使检测结果可视化及系统测试优化；

2025.4.1-2025.4.25：完成毕业论文撰写，并制作答辩 ppt，准备答辩。

接受任务日期：2024 年 12 月 01 日　**要求完成日期：**2025 年 05 月 08 日

学　　生：郭梦雪

指 导 教 师：张宇

东北农业大学毕业论文（设计）开题报告

学生姓名	郭梦雪	学号	A10210035	班级	物联 2101
题目	基于改进 YOLOv11 的吸烟行为检测算法设计与实现				

题目研究的目的和意义

随着公共场所禁烟政策的推进，传统的人工巡查方式面临效率低、覆盖范围有限等问题，导致了在实际监控中的诸多局限性。基于计算机视觉的吸烟行为检测技术应运而生，它能够有效提高监管效能，提升监控的准确性与实时性，具有重要的社会应用价值。根据世界卫生组织（WHO）报告，全球每年因吸烟导致的死亡人数超过 800 万，吸烟带来的健康危害和公共安全问题急需解决。因此，智能化监管手段的研发已成为当前迫切需要解决的任务。

目前，目标检测领域已有诸多经典算法如 Faster R-CNN、YOLO 系列等在通用场景中表现出色，但在吸烟行为检测任务中仍面临一定的挑战。吸烟行为的特殊性在于其目标小（如手持香烟）、遮挡频繁（如手部与面部交互），这些特点导致常规模型在该任务中的漏检率较高，影响了检测准确性。且目前对于 YOLOv11 的改进研究仍较为局限，未充分探讨其在吸烟行为检测中的表现和优化方向，因此本文对基于改进 YOLOv11 的吸烟行为检测算法设计与实现进行了研究。

本研究选择 YOLOv11 作为基础框架，充分考虑到它在检测速度和精度方面有的平衡特性，其 CSPDarknet53 骨干网络以及多尺度预测机制可为捕捉烟雾这样的小目标提供理论支撑。在此基础上，考虑到吸烟行为中的小目标和遮挡问题，本文引入 SENet 注意力机制来增强模型对关键特征（如香烟、吸烟手势）的敏感性。相关研究表明，SE 模块可以显著提高小目标的检测性能，并增强模型在复杂场景下的鲁棒性。

本系统选择采用 PyQt5 开发本地化交互界面，可以避免云部署可能带来的隐私风险，并能较好地适应边缘计算设备在公共场所的要求。相对于云计算而言，边缘计算能够对数据的处理进行更低延时的处理，同时保证隐私信息不被上传到云端。

综上所述，本研究为解决现实场景中的吸烟行为检测难题，通过改进 YOLOv11s 模型，结合 SENet 注意力机制，构建较为完整的吸烟行为检测系统。目的在于实现较为精确快速地识别公共场所的吸烟行为，辅助执行禁烟政策，并促进公共卫生的提升。

题目研究方案和主要内容

1.数据集选择与预处理

选择公开的吸烟行为数据集，并进行图像预处理与数据集标注、划分，确保数据适配 YOLOv11s 模型的输入要求，为模型训练提供高质量数据。

2.YOLOv11s 模型训练与评估

基于 YOLOv11s 模型进行吸烟行为的目标检测，使用公开数据集训练并评估模型性能，采用精确度、召回率等指标进行多维度评估。

3.引入 SE 注意力机制

将 SE 注意力机制嵌入 YOLOv11s 模型，增强模型对关键特征（如香烟、吸烟手势）的关注，提升小目标检测精度和模型鲁棒性。

4.模型优化与性能对比

评估改进后的 YOLOv11s 模型，分析精确度、召回率等指标，比较 SE 注意力机制引入前后的性能差异，验证其对吸烟行为检测准确性的提升。

5.用户界面设计

开发基于 PyQt5 的图形用户界面，集成改进的 YOLOv11s 模型，实现图片与视频的检测，并支持结果导出，确保系统的可用性和实际应用价值。

研究方法及技术途径

本研究主要采用基于深度学习的目标检测技术，使用 YOLOv11s 模型进行吸烟行为检测。YOLOv11s 作为一种较为高效且精度较高的目标检测模型，能够识别图像中的目标，并输出其位置和类别信息。首先，将对公开的吸烟行为数据集进行全面预处理，包括图像的筛选、大小调整、标注等，以确保数据符合 YOLOv11s 模型的输入要求。接着，使用 PyTorch 框架搭建 YOLOv11s 模型，并在该数据集上进行训练。为了提升模型在复杂场景下对小目标的检测能力，本研究将在 YOLOv11s 模型中集成 SE 注意力机制。SE 模块通过自适应地为不同通道的特征图分配权重，增强模型对关键区域的关注，从而显著提升吸烟行为检测的准确率。

在模型训练完成后，使用多项评估指标（如精确度，召回率，mAP50 等），全面评估模型的表现，并对比引入 SE 注意力机制前后的性能差异，验证其对吸烟行为检测准确性的提升。最终，为了提高用户体验，本研究将开发一个基于 PyQt5 的图形界面，集成改进的 YOLOv11s 模型，系统支持图片视频分析和检测结果展示，并提供数据导出功能，方便用户进一步分析检测结果。

实施计划

2024.12.1-2025.2.1：查阅相关文献，了解目标检测技术、YOLOv11s 架构和 SE 注意力机制的基本概念及应用，选取吸烟行为检测相关的公开数据集，完成任务书和开题报告的撰写；

2025.2.1-2025.3.15：完成数据集下载与预处理，并完成 YOLOv11s 的模型搭建与初步训练，并引入 SE 注意力机制。

2025.3.15-2025.4.1：设计 PyQt5 交互界面，使检测结果可视化及系统测试优化；

2025.4.1-2025.4.25：完成毕业论文撰写，并制作答辩 ppt，准备答辩。

东北农业大学毕业论文（设计）中期检查

学生姓名	郭梦雪	学号	A10210035	班级	物联 2101
题目	基于改进 YOLOv11 的吸烟行为检测算法设计与实现				

论文概述

本论文设计并完成了一个基于 YOLOv11 的吸烟行为检测系统，以此提升对公共场所违规吸烟行为的自动化识别水平。

第一章是绪论，阐述了论文的研究背景以及意义、国内外研究的现状，还简单讲述了本文的研究内容与结构。

第二章为相关理论基础，着重介绍了基于深度学习的目标检测办法、卷积神经网络 CNN 以及 YOLO 单阶段目标检测技术，同时也简要介绍了三种注意力机制的原理和特性。

第三章主要对数据集以及吸烟检测模型的实现过程展开阐述，具体说明了本研究运用的技术路线，介绍了吸烟行为数据集的采集方式以及标注情况，展示了数据的最终分布状况，同时也提到了基于 YOLOv11 算法构建的吸烟目标检测模型。

第四章聚焦于实验结果以及相关分析展开论述，其内容涉及多个方面，其中包含对实验环境以及训练参数的详细阐释。还说明了本研究采用的主要评价指标，对模型训练结果以及性能评估给予了说明，呈现出在本实验吸烟数据集上 YOLOv8s 和 YOLOv11s 的性能对比情形，并且开展了引入 SE 注意力机制前后的模型性能对比分析。

第五章针对吸烟行为检测系统的界面设计进行了较为全面的阐述，覆盖了界面功能模块的划分情况、操作流程的设计细节、控件选型以及样式的优化以及信号与槽机制的具体应用，以此全面呈现了该系统在可用性与交互性方面的设计思路以及实现效果。

第六章着重关注研究的结论与展望部分，一开始就对本研究得到的结论进行了较为全面的梳理概括，接着详细分析了当下所运用方法存在的不足之处，最后对未来的改进方向作出展望，希望依靠这些改进措施提高检测的精准度以及系统的实际应用价值。

本阶段研究工作的内容和进展

1.查阅了国内外基于深度学习的吸烟行为检测技术现状，分析了 YOLOv11 算法的适用性，总结了吸烟检测中存在的目标小、遮挡频繁等核心问题，明确了基于 YOLOv11s 的优化方向，并制定了研究计划。

2.筛选了适合吸烟行为检测的公开数据集，完成了数据集的标注和预处理，合理划分了训练集、验证集与测试集。搭建 YOLOv11s 基础模型，并完成了初步训练，验证了模型对吸烟行为的检测能力。

3.在 YOLOv11s 模型中加入了 SE 注意力机制，能让模型更加关注香烟、手部等关键区域。通过对比引入 SE 注意力机制前后的模型性能，验证了该机制对提高检测精度的有效性，并在性能上获得了提升。

4.使用 PyQt5 设计了简单的操作界面，支持用户上传图片或视频进行吸烟行为检测，并能够在画面中自动框出检测到的吸烟行为。当前界面基本功能已经实现，但某些高级

功能（如导出检测结果）仍在进一步调试中。
遇到的问题 1.数据集场景单一：现有数据集中的遮挡场景不足，导致模型对复杂环境漏检率高。后续计划通过手动补充遮挡样本，以提升模型的鲁棒性。 2.训练效率较低：本地显卡性能较低会限制训练速度，打算尝试租用云端 GPU 资源来加速实验进度。 3.界面运行卡顿：视频检测结果展示时界面偶尔会卡顿，实时检测还不太完善，后续会进一步优化代码。
下一步工作 1.继续优化模型：针对小目标漏检与误检问题，优化 SE 模块的嵌入位置，同时尝试轻量化设计（如减少冗余网络层），提升模型推理速度。 2.完善界面功能：解决实时检测的卡顿问题，增加“导出检测结果”等实用功能。 3.多场景测试：在不同光照、遮挡环境下测试系统，确保实际可用性。 4.论文撰写：整理实验数据，开始编写论文，并准备答辩材料。
指导教师：张宇 **审核时间：**2025 年 05 月 04 日

指导教师评语

学生姓名	郭梦雪	学号	A10210035	班级	物联 2101
题目	基于改进 YOLOv11 的吸烟行为检测算法设计与实现				

指导教师评语：

论文聚焦于改进 YOLOv11 模型以提升吸烟行为检测的精度与效率。研究从数据集构建、模型优化到系统实现层层递进，引入 SE 注意力机制有效增强了模型对小目标的检测能力，同时保持了模型的轻量化与实时性。通过与原始 YOLOv11 模型及其他版本的对比，验证了改进模型在检测精度和泛化能力上的提升，为公共健康管理提供了技术支持，具有一定的实用价值。论文查重和 AIGC 检测结果均符合学校要求，同意该生参加毕业论文答辩。

指导教师：张宇

评阅时间：2025 年 05 月 04 日

评阅人意见

学生姓名	郭梦雪	学号	A10210035	班级	物联 2101
题目	基于改进 YOLOv11 的吸烟行为检测算法设计与实现				

评阅人意见：

该论文针对公共场所吸烟检测问题展开研究，研究了一种基于改进 YOLOv11 的吸烟行为监测算法，算法在公开数据集上进行了评估与验证，并开发了图形化吸烟行为检测系统。论文研究目的意义明确，论文结构合理，工作量较为饱满，但是语言描述和规范性有待进一步完善，主要问题如下：

1.部分语言描述不通顺及口语化，比如摘要第一句“吸烟行为的自动检测对于公共健康管理有着颇为关键的应用价值”。

2.论文中部分格式不规范，如第 5 页（1）（2）（3）应首行缩进 2 个字符，存在多余空格和空行的现象。

3.论文中部分图表不清晰，比如：图 1-2 不清晰，图 2-5 中文字太小，图 4-2 看不清。

4.图 4-6 模型评价结果请用表格代替，不要直接代码截图。

5.图 5-2 流程图不规范，选择框应用菱形框。

建议修改完善论文后参加答辩。

评阅人：尹艳玲

评阅时间：2025 年 05 月 17 日

答辩委员会意见

<table>
<tr><td>学生姓名</td><td>郭梦雪</td><td>学号</td><td>A10210035</td><td>班级</td><td>物联 2101</td></tr>
<tr><td>题目</td><td colspan="5">基于改进 YOLOv11 的吸烟行为检测算法设计与实现</td></tr>
<tr><td colspan="6">答辩委员会意见：
毕业论文完成了毕业设计任务书规定的内容、要求；能运用所学的理论知识解决设计中的问题；具有一定的独立工作能力，
设计比较合理，计算结果基本正确，图表清晰，表达基本准确，具有一定的条理性；答辩时回答问题基本正确。经答辩委员会讨论，一致同意该生通过论文答辩，并建议授予工学学士学位。

答辩委员会主席：冯江</td></tr>
<tr><td>等级</td><td>良好</td><td colspan="4">院长：李晓明

2025 年 05 月 30 日</td></tr>
</table>

电气与信息学院本科毕业论文（设计）评价指标

指标	评价要素		评价指标内涵
选题质量	1	目的明确，符合要求	符合培养目标，体现学科、专业特点和教学计划中对能力、知识结构的基本要求，达到毕业综合训练的目的。
	2	理论意义或实际价值	符合本学科的理论发展，解决学科建设、科学发展的理论或方法问题，有一定的科学意义，符合我国经济建设和社会发展的需要，解决应用性研究中的某个理论或方法问题，具有一定的实际价值。
	3	选题适当	题目贴切，有较强的科学性，难易度适中，题目规模适当。
能力水平	4	查阅文献资料能力	能独立查阅相关文献资料，归纳总结本领域有关科学成果。
	5	综合运用知识能力	能运用所学专业知识分析论述有关问题，能对占有资料进行分析整理并适当运用，概念清楚，能以恰当的论据对科学论点进行有说服力的论证。
	6	研究方案的设计能力	设计（论文）的整体思路清晰，结构完整，研究方案完整有序。
	7	研究方法和手段的运用能力	能较熟练的运用本学科的常规科学研究方法，能适当运用相关研究手段（如计算机、实验仪器设备等）进行资料搜集、加工、处理，并辅助论文写作。
	8	外文应用能力	能按照学校规定结合论文阅读、翻译一定量的本专业外文资料，有外文摘要和外文书目。
成果质量管理	9	文题相符	论文较完整地回答了题目所设定的有关问题。
	10	写作水平	论点鲜明，观点正确，论据充分，论证有力，条理分明，语言流畅。
	11	写作规范	符合科学论文的基本要求，论文（设计）中的用语格式、图表、数据、各种资料的运用及引用都要规范化。
	12	篇幅	工程设计类篇幅不少于 8000 字，研究论文篇幅不少于 10000 字。
	13	成果的理论或实际价值	在理论上具有新意，应用性研究对于实际工作具有一定意义。